Universidad Politécnica de Madrid

Escuela Técnica Superior de Ingeniería de Sistemas Informáticos



Modelado del proceso de deducción humana mediante pistas generadas por modelos de lenguaje en un entorno de juego

Proyecto Fin de Grado

Grado en Ciencia de Datos e Inteligencia Artificial

Curso académico 2025-2026

Autor:

Alonso Ruiz Palomo

Tutor:

Carlos Badenes Olmedo

Agradecimientos

Este trabajo no habría sido posible sin las personas que, de una forma u otra, dejaron su huella en él.

En primer lugar, quiero expresar mi más sincero agradecimiento a **Carlos Badenes**, tutor de este proyecto, cuyo apoyo ha ido mucho más allá de la orientación académica. Su interés genuino por el trabajo, su disponibilidad constante y su capacidad para ver en SpyGame algo más que un Trabajo de Fin de Grado han sido, en muchos momentos, el impulso necesario para seguir adelante. Gracias por hacer de este TFG una experiencia que merece la pena recordar.

En segundo lugar, quiero dedicar un reconocimiento especial a todos los **jugadores** que participaron en SpyGame y que, quizás sin saberlo, se convirtieron en parte fundamental de esta investigación. Cada partida, cada pista solicitada, cada intento fallido y cada acierto celebrado fueron los datos que le dieron vida a este trabajo. Sin vuestra participación desinteresada, este proyecto habría sido poco más que una idea sobre el papel. Gracias a todos por vuestra contribución.

Resumen

Este trabajo presenta un marco para el análisis de la calidad de pistas en sistemas interactivos de deducción basados en lenguaje natural. Para ello, se propone **QUILL** (*Quality Index for Ludic Learning Hints*), una función compuesta que modela distintas dimensiones semánticas y cognitivas de las pistas, como su capacidad discriminativa, ambigüedad o ganancia de información.

Como entorno experimental, se ha desarrollado *Spygame*, una plataforma interactiva que permite generar pistas automáticamente a partir de contenido estructurado (e.g., Wikipedia) y registrar la interacción de los usuarios. El sistema ha sido evaluado mediante más de 3.400 interacciones reales en dos escenarios diferenciados: un entorno de evocación libre (*mundo abierto*) y un entorno de reconocimiento con espacio de búsqueda acotado (*mundo cerrado*).

A partir de los datos recogidos, se analiza la relación entre las características de las pistas y su efectividad, permitiendo ajustar la función propuesta en función del comportamiento real de los usuarios. Los resultados muestran que la calidad de una pista depende principalmente de su capacidad para reducir el espacio de hipótesis de forma precisa, más que de su complejidad lingüística.

Abstract

This work presents *Spygame*, an interactive game platform designed to study human deductive reasoning under partial information conditions. A corpus of 360 hints was generated automatically using the Meta-Llama-3.1-70B-Instruct model over 45 public figures extracted from Wikipedia, and a formal framework — **QUILL** (*Quality Index for Ludic Learning hints*) — is proposed and evaluated to analyse the quality of LLM-generated hints.

QUILL integrates five semantic metrics: Discriminative Power (PD), Relative Ambiguity (AMB), Normalised Information Gain (nGAIN), Internal Semantic Consistency (CONS), and Readability (LEC). These metrics are combined through an empirically calibrated weighted sum, modulated by a data-driven CLAMP function based on the corpus distribution of direct hint-to-target cosine similarity.

Empirical validation was conducted across two experimental phases totalling 3,412 real user interactions: an open-world phase ($N = 2{,}293$) requiring free-recall responses, and a closed-world phase ($N = 1{,}119$) in which players selected from a visible candidate list. Logistic regression over the interaction logs was used to estimate the relative contribution of each metric to the probability of a correct guess, yielding empirically adjusted variants of QUILL for each modality.

Results show that Discriminative Power is the most robust predictor of success in both phases, with its coefficient tripling in the closed-world condition ($\beta = +0{,}333$). Ordinary least squares regression over linguistic features of the corpus reveals that verb density penalises four of the five quality metrics, while the presence of named entities significantly increases information gain. These findings support a concrete design principle: hint quality depends primarily on nominal specificity rather than narrative fluency.

Índice

Agradecimientos I

Resumen II

Abstract III

1. Introducción **1**

1.1. Contexto 1

1.2. Motivación 2

1.3. Objetivos 3

1.3.1. Objetivo general 3

1.3.2. Objetivos específicos 3

1.4. Estructura del documento 3

2. Estado del arte **5**

2.1. Sistemas de tutoría inteligente y generación de pistas 5

2.1.1. Intelligent Tutoring Systems clásicos 5

2.1.2. Estructura y diseño de pistas en ITS 5

2.1.3. Modelado del estudiante y decisión de ayuda 6

2.1.4. Limitaciones de los enfoques tradicionales 6

2.2. Generación automática de pistas mediante modelos de lenguaje 6

2.2.1. Uso de modelos de lenguaje en la generación de ayuda 6

2.2.2. Evaluación de LLMs en la generación de pistas 7

2.2.3. Comparación entre pistas humanas y pistas generadas 7

2.2.4. Generación de múltiples niveles de pistas 8

2.3. Modelado cognitivo del usuario mediante estados latentes 8

2.3.1. Bayesian Knowledge Tracing y modelos ocultos de Markov 8

2.3.2. Estados cognitivos como procesos dinámicos 9

2.3.3. Limitaciones del estado del arte 9

2.4. Evaluación automática de la calidad de las pistas 10

2.4.1. Evaluación de la utilidad de las pistas 10

2.4.2. Ambigüedad, redundancia y trampas semánticas 10

2.4.3. Evaluación basada en comportamiento del usuario 11
2.5. Resumen de limitaciones y objetivos del TFG 11

3. Metodología **13**

3.1. Metodología 13
3.1.1. Extracción de datos 14
3.1.2. Generación de pistas 16
3.1.3. Caracterización de las pistas 17
3.1.4. Recogida de interacciones reales 18
3.1.5. Validación y ajuste por inferencia 19

4. Evaluación **21**

4.1. Métricas para la evaluación y selección de pistas 21
4.1.1. Poder Discriminativo (PD) 21
4.1.2. Ambigüedad Relativa (AMB) 22
4.1.3. Ganancia de Información Normalizada (nGAIN) 22
4.1.4. Consistencia Semántica Interna (CONS) 23
4.1.5. Lecturabilidad y Carga Cognitiva (LEC) 23
4.1.6. Restricción de Proximidad (CLAMP) 24
4.1.7. Score Final de Calidad: QUILL 24
4.1.8. Métricas Sintáctico-Lingüísticas 25
4.1.9. Relación entre métricas semánticas y lingüísticas 27
4.1.10. Ejemplo numérico: cálculo de QUILL 27

5. Resultados **30**

5.1. Resultados obtenidos 30
5.1.1. Descripción general del experimento 30
5.1.2. H1 — Poder predictivo de QUILL 34
5.1.3. H2 — Predominio del Poder Discriminativo 37
5.1.4. H3 — Propiedades lingüísticas y calidad semántica 39
5.1.5. H4 — Efecto de la modalidad experimental 49

6. Conclusiones y trabajos futuros **57**

6.1. Conclusiones 57

6.1.1. Consecución de los objetivos planteados 57
6.1.2. El verbo como determinante negativo de la calidad 58
6.1.3. La carga atributiva y la eficiencia cognitiva 59
6.1.4. El valor del anclaje factual y la profundidad estructural 59
6.1.5. La naturaleza inmanente de la ambigüedad 59
6.1.6. Perfil empírico y el principio de especificidad nominal 60
6.1.7. Consideraciones metodológicas y limitaciones 60
6.2. Impacto social y medioambiental 61
6.3. Líneas futuras 62

Bibliografía **64**

Índice de tablas

2.1. Limitaciones del estado del arte y objetivos específicos del TFG que las abordan. 12

3.1. Número de artículos de la Wikipedia en inglés con enlace entrante a cada personaje seleccionado, ordenados de mayor a menor. Todos superan el umbral mínimo de 200 enlaces. Los nombres son hipervínculos al artículo correspondiente en Wikipedia en inglés. 14

3.2. Muestra de pistas del corpus a distintos niveles de dificultad. 17

4.1. Las 8 pistas de Isaac Newton del corpus, ordenadas por puntuación QUILL descendente. La dificultad asignada no predice el valor Q, lo que justifica la necesidad de una métrica formal de calidad. 29

5.1. Pistas con mayor puntuación QUILL del corpus (pesos iniciales, $N = 360$). 36

5.2. Coeficientes estandarizados de la regresión logística ($N = 2293$). 37

5.3. Pistas con menor puntuación QUILL del corpus (pesos iniciales, $N = 360$). 38

5.4. Coeficientes estandarizados del modelo OLS para PD (errores robustos HC3). 42

5.5. Coeficientes estandarizados del modelo OLS para AMB (errores robustos HC3). 43

5.6. Coeficientes estandarizados del modelo OLS para nGAIN (errores robustos HC3). 45

5.7. Coeficientes estandarizados del modelo OLS para LEC (errores robustos HC3). 46

5.8. Coeficientes estandarizados del modelo OLS para CONS (errores robustos HC3). 48

5.9. Distribución de clases en el conjunto de datos de Fase 2. 50

5.10. Comparación de bondad de ajuste del modelo logístico entre ambas fases. 50

5.11. Coeficientes β estandarizados del modelo logístico (sklearn, L2) en Fase 2, comparados con los de Fase 1. Los pesos normalizados derivados sitúan PD en el 53.2 %, CONS en el 25.9 %, nGAIN en el 9.8 %, AMB en el 8.1 % y LEC en el 3.7 %. 52

5.12. Estadísticos descriptivos de las tres variantes de Q sobre las 360 pistas del corpus, con correlaciones de Pearson entre pares ($N = 360$). 56

6.1. Impacto estandarizado de la densidad verbal sobre las métricas de calidad. 59

6.2. Perfil empírico de la pista óptima según los modelos OLS. Los umbrales VERB_Ratio y ADJ_Ratio corresponden al primer cuartil del corpus. 61

Índice de figuras

3.1. Flujo de trabajo de la metodología propuesta: desde la extracción de datos hasta la validación estadística del marco QUILL. 13

3.2. Pantalla de inicio de Spygame con formulario de registro y acceso. 19

3.3. Flujo de juego en Spygame: partida activa (a) y pantalla de resultado (b). 19

5.1. Distribución de frecuencias de las métricas individuales y el Score Q. 31

5.2. Matriz de correlación de Pearson entre las métricas de evaluación. 33

5.3. Izquierda: histograma de PROX en el corpus de 360 pistas, con $\mu = 0{,}273$ y el umbral $\mu + 2\sigma = 0{,}579$ marcados. Derecha: función CLAMP sigmoide calibrada sobre el rango empírico, con los 360 puntos del corpus superpuestos. 34

5.4. Curva ROC media en validación cruzada 5-fold con banda de desviación estándar. 35

5.5. Histogramas superpuestos de Q Inicial (pesos teóricos) y Q Mundo Abierto (pesos empíricos derivados de la Fase 1). La ligera diferencia en las distribuciones refleja el rebalanceo de pesos inducido por la regresión logística. 38

5.6. Coeficientes estandarizados del modelo OLS para PD. 42

5.7. Coeficientes estandarizados del modelo OLS para AMB. 43

5.8. Coeficientes estandarizados del modelo OLS para nGAIN. 45

5.9. Coeficientes estandarizados del modelo OLS para LEC. 47

5.10. Coeficientes estandarizados del modelo OLS para CONS. 48

5.11. Validación completa del modelo logístico en Fase 2. Se incluyen la curva ROC sobre el conjunto de prueba, las métricas de validación cruzada estratificada (accuracy, AUC, F1, log-loss) y el reporte de clasificación. La curva ROC muestra capacidad discriminativa modesta pero consistentemente superior al azar. 51

5.12. Curva ROC con validación cruzada de 5 pliegues (Fase 2). La banda sombreada representa la desviación estándar entre pliegues. El AUC medio de $0{,}548 \pm 0{,}058$ es inferior al obtenido en mundo abierto ($0{,}565 \pm 0{,}027$) y presenta mayor varianza entre pliegues, reflejo del menor tamaño muestral. 51

5.13. Importancia relativa de las métricas de calidad en el modelo logístico de Fase 2 (pesos normalizados a partir de $|\beta|$). PD absorbe más del 53 % del peso total, mientras que en Fase 1 su contribución era de aproximadamente el 34 %. CONS emerge como segundo factor relevante (25.9 %) desde una posición prácticamente irrelevante en mundo abierto (2 %). . 52

5.14. Panel resumen (2×3) con las seis comparaciones entre las tres variantes de Q. Fila superior: histogramas superpuestos, box plots y violin plots. Fila inferior: diagramas de dispersión para cada par de variantes (Q Inicial vs Q M.Abierto, Q Inicial vs Q M.Cerrado, Q M.Abierto vs Q M.Cerrado). Azul: Q Inicial; morado: Q Mundo Abierto; verde: Q Mundo Cerrado. 53

5.15. Histogramas superpuestos de las tres variantes de Q sobre las 360 pistas. La Q Inicial (azul) concentra masa en una banda estrecha centrada en valores medios, reflejo de que todos los pesos eran moderados. La Q Mundo Abierto (morado) se desplaza según la doble dominancia de PD y LEC. La Q Mundo Cerrado (verde) muestra la mayor dispersión, consecuencia del dominio extremo de PD (53 %): las pistas con PD alto se separan claramente del resto. 54

5.16. Diagramas de caja comparativos de las tres variantes de Q. La comparación de medianas y rangos intercuartílicos revela cómo el rebalanceo de pesos entre variantes desplaza la tendencia central y modifica la asimetría de la distribución. La mayor varianza de Q Mundo Cerrado es consistente con la polarización inducida por el peso dominante de PD. 54

5.17. Diagramas de violín de las tres variantes de Q. La forma del violín revela la densidad de probabilidad en cada punto del rango de valores. La Q Inicial muestra una forma más compacta y simétrica; la Q Mundo Cerrado presenta una forma más elongada con un pico pronunciado en valores medios-bajos y cola más larga en los valores altos, asociada a las pistas con PD excepcional. 55

5.18. Diagramas de dispersión para cada par de variantes. *Izquierda*: Q Inicial vs Q Mundo Abierto — la correlación es moderada; las pistas con LEC alta ganan posición respecto a la Q Inicial. *Centro*: Q Inicial vs Q Mundo Cerrado — la dispersión alrededor de la diagonal es mayor, indicando un reordenamiento más profundo inducido por el peso dominante de PD. *Derecha*: Q Mundo Abierto vs Q Mundo Cerrado — el tercer scatter muestra directamente cuánto difiere el ordenamiento de las pistas entre las dos fórmulas empíricas: las pistas que tienen PD alto pero LEC baja suben en mundo cerrado y bajan en mundo abierto, y viceversa. 55

6.1. ODS 4: Educación de calidad. 61

6.2. ODS 9: Industria, innovación e infraestructura. 62

6.3. ODS 12: Producción y consumo responsables. 62

Capítulo 1

Introducción

1.1. Contexto

Históricamente, la provisión de pistas o retroalimentación incremental ha constituido el núcleo de los *Intelligent Tutoring Systems* (ITS) y de los sistemas interactivos orientados al aprendizaje. Desde sus inicios, el objetivo de estos sistemas ha sido guiar al usuario mediante estímulos progresivos que logren mitigar la carga de trabajo mental sin suprimir el esfuerzo necesario para la resolución del problema. Este delicado equilibrio entre apoyo y desafío es fundamental para fomentar una comprensión profunda, evitando caer tanto en la frustración por falta de ayuda como en la dependencia excesiva de la misma (*gaming the system*).

No obstante, la literatura evidencia que la eficacia de una pista no reside únicamente en su contenido semántico, sino también en su formulación, su nivel de abstracción y, crucialmente, en la oportunidad de su presentación (*timing*). Una misma información puede detonar efectos dispares según la fase de resolución en la que se encuentre el usuario o la manera en que se enuncie, condicionando cómo este integra el dato y reajusta su estrategia. En este sentido, los ITS han funcionado como entornos experimentales para observar cómo variaciones sutiles en el diseño de la ayuda alteran significativamente el desempeño del estudiante.

En este escenario, múltiples investigaciones han abordado las consecuencias del uso de pistas, documentando fenómenos como la evitación de ayuda (*help avoidance*) o la pérdida de iniciativa en la resolución. La evidencia en tutoría inteligente señala que una intervención mal diseñada, o presentada a destiempo, puede resultar inocua o incluso entorpecer el razonamiento del usuario, mientras que una pista pertinente acelera la convergencia hacia la solución sin sacrificar el aprendizaje subyacente [15]. Estos hallazgos corroboran que la utilidad de una ayuda es una propiedad eminentemente contextual y no intrínseca.

Paralelamente, el campo del modelado de usuario ha integrado enfoques de minería de datos educativos para inferir el nivel de conocimiento del aprendiz a partir de su conducta observable. Técnicas como el *Bayesian Knowledge Tracing* (BKT) estiman la probabilidad de que un aprendiz domine una habilidad basándose en su historial de éxitos y errores, consolidándose como referencia en entornos estructurados [7]. No obstante, su aplicación en dominios no procedimentales (como el razonamiento deductivo o la resolución de enigmas) plantea desafíos específicos: la ausencia de una definición canónica de *habilidad* y la no linealidad de las trayectorias de resolución dificultan la proyección directa de estos modelos sobre datos de interacción heterogéneos [18].

Más allá de los ejercicios procedimentales, la minería de datos educativos ha extendido su alcance a los entornos de juego educativo (*game-based learning*), donde las interacciones son ricas en señal implícita [13]. En estos contextos, el análisis de secuencias de uso de pistas, intentos de respuesta y patrones de error permite obtener una visión granular del proceso deductivo sin necesidad de autoreporte explícito. La naturaleza lúdica del entorno genera datos de interacción naturales y en mayor volumen que los ejercicios convencionales, lo que lo convierte en un banco de pruebas idóneo para evaluar la eficacia funcional de las ayudas generadas automáticamente y detectar deficiencias en su formulación [29].

Recientemente, la irrupción de los modelos de lenguaje de gran escala (*Large Language Models*, LLMs) ha transformado las posibilidades de generación automática de *feedback*. Diversos estudios han comenzado a explorar el uso de LLMs para producir pistas contextualizadas en tiempo real, aprovechando su fluidez para generar explicaciones en lenguaje natural [28]. Esta capacidad promete resolver el problema de la escalabilidad en la creación de contenido de ayuda.

Sin embargo, las revisiones más actuales sobre la integración de LLMs en sistemas tutoriales advierten

de una limitación crítica: aunque estos modelos simulan con gran fidelidad un rol instructivo, carecen de mecanismos internos para validar la utilidad pedagógica o funcional de la información que emiten [16]. Por consiguiente, su adopción en sistemas adaptativos exige capas de supervisión y modelado externo. El estado del arte nos presenta, así, un panorama rico en técnicas de generación, pero fragmentado por la ausencia de métricas formales que permitan auditar la calidad de dicha ayuda de manera sistemática.

1.2. Motivación

A pesar del extenso volumen de investigación sobre *feedback* adaptativo, persiste una brecha notable entre la capacidad técnica de generar pistas automáticamente y la capacidad metodológica de evaluar su impacto real en el proceso deductivo del usuario. En gran parte de los sistemas interactivos actuales, se opera bajo la asunción implícita de que una pista factualmente correcta es, por extensión, útil. Esta premisa ignora factores determinantes como la ambigüedad semántica, la sobrecarga informativa o la falta de alineación con el estado mental actual del usuario.

Esta deficiencia se vuelve crítica en los sistemas potenciados por LLMs. Si bien la generación de contenido es virtualmente ilimitada, su calidad funcional es heterogénea. Una pista puede ser técnicamente válida y, sin embargo, fallar en reducir el espacio de búsqueda del usuario, inducir a falsas interpretaciones o simplemente añadir ruido a la interacción. En la práctica, esto deriva en experiencias en las que el usuario recibe información que, aunque veraz, no contribuye a desbloquear su razonamiento ni a avanzar en la tarea.

La carencia de criterios formales para distinguir entre pistas útiles, neutras o disruptivas obstaculiza la mejora iterativa de estos sistemas. Generalmente, la eficacia de la ayuda se mide mediante indicadores agregados y finalistas, como bien pueden ser la tasa de aciertos o el tiempo total de resolución. Sin embargo, estas métricas son insuficientes para comprender la dinámica de la interacción: no nos dicen si una pista específica clarificó una duda o si el usuario resolvió el problema a pesar de la pista y no gracias a ella.

Como consecuencia, se pierde la oportunidad de analizar con precisión el proceso de razonamiento subyacente e identificar transiciones clave en la interacción, como momentos de exploración, convergencia o estancamiento. Esta falta de granularidad limita severamente la capacidad del sistema para adaptarse de forma inteligente y explicar el éxito o fracaso de sus intervenciones en distintos contextos de uso.

Ante el problema presentado, este proyecto propone avanzar hacia un marco que formalice la noción de *buena pista*, integrando dimensiones como su poder discriminativo y su capacidad para activar el razonamiento. La literatura sugiere que una personalización efectiva debe considerar tanto el perfil del usuario como el contexto inmediato de la tarea [18], lo que justifica la necesidad de métricas observables que vinculen las pistas individuales con cambios medibles en el comportamiento del usuario.

La validación empírica de estas métricas en escenarios reales de juego permite cerrar el ciclo de evaluación: los datos de interacción de los usuarios no solo sirven para medir el impacto de las pistas en el acierto, sino también para estimar empíricamente los pesos relativos de cada dimensión de calidad. Este enfoque cobra especial relevancia en dominios donde el razonamiento es incremental y menos lineal que en los ejercicios escolares tradicionales, como ocurre en los juegos de deducción. En estos entornos, el análisis del comportamiento observable (solicitudes de pista, intentos fallidos, tasa de acierto) actúa como señal directa de la fricción cognitiva introducida por el contenido generado por el LLM, habilitando la detección de patrones subóptimos a partir de datos reales de interacción.

1.3. Objetivos

1.3.1. Objetivo general

El objetivo general de este trabajo es proponer y evaluar un marco formal que permita analizar y optimizar la calidad de las pistas generadas automáticamente por modelos de lenguaje de gran tamaño (LLMs) en sistemas interactivos de deducción, combinando métricas semánticas intrínsecas al texto con validación empírica sobre datos reales de interacción de usuarios.

1.3.2. Objetivos específicos

- **Establecer métricas observables para evaluar la contribución individual de cada pista al proceso de razonamiento del usuario**, atendiendo a aspectos como su poder discriminativo, su redundancia o su posible efecto confusor.
- **Integrar modelos de lenguaje de gran tamaño como generadores automáticos de pistas en lenguaje natural**, analizando de forma sistemática las limitaciones de este enfoque en términos de ambigüedad semántica y utilidad cognitiva.
- **Analizar experimentalmente el impacto de diferentes tipos de pistas sobre la dinámica de interacción del usuario**, estudiando cómo influyen en la tasa de acierto del jugador y en los patrones de comportamiento observados en distintas modalidades de respuesta.
- **Identificar patrones recurrentes de generación subóptima de pistas por parte de los LLMs**, empleando el análisis estadístico de los datos de interacción real como herramienta para detectar ruido cognitivo, falta de discriminación o ambigüedades persistentes.

En este contexto, este trabajo propone QUILL, un marco formal para caracterizar y evaluar la calidad de pistas en función de su impacto funcional sobre el razonamiento del usuario, y lo valida mediante Spygame, un sistema interactivo con datos reales de interacción.

1.4. Estructura del documento

Este documento se estructura en varios capítulos, cada uno orientado a desarrollar las distintas fases del proyecto realizado. A continuación, se detalla el contenido de cada uno de ellos:

- **Capítulo 1 - Introducción:** Describe el contexto en el que se desarrolla el trabajo, expone la motivación que justifica su realización y define tanto el objetivo general como los objetivos específicos planteados.
- **Capítulo 2 - Estado del arte:** Revisa los enfoques existentes en la generación de pistas adaptativas, el modelado del estudiante en sistemas de tutoría inteligente y la integración de LLMs en contextos interactivos, situando el trabajo en el marco de la investigación actual.
- **Capítulo 3 - Metodología:** Describe en detalle el diseño experimental seguido. Se introduce el juego SpyGame y la aplicación empleada para recopilar los datos, el proceso de generación de pistas mediante LLM y las métricas de calidad definidas para evaluar su utilidad.
- **Capítulo 4 - Evaluación:** Presenta el marco formal de evaluación de pistas, describiendo las métricas semánticas empleadas (PD, AMB, nGAIN, LEC, CONS), su fundamentación teórica y la función de calidad compuesta **QUILL** (*Quality Index for Ludic Learning hints*).
- **Capítulo 5 - Resultados:** Expone los resultados empíricos obtenidos en las dos fases experimentales, incluyendo el análisis descriptivo del corpus de pistas, la validación con usuarios en modalidad abierta y cerrada, y el análisis de regresión sobre las propiedades lingüísticas de las pistas.

- **Capítulo 6 - Conclusiones y trabajos futuros:** Resume los hallazgos principales del proyecto, evalúa el grado de cumplimiento de los objetivos y propone líneas de investigación para trabajos futuros.
- **Bibliografía:** Compila las fuentes bibliográficas y los trabajos previos que han servido como fundamento para el desarrollo del proyecto.

Capítulo 2

Estado del arte

El objetivo de este capítulo es situar el trabajo desarrollado en un marco amplio de investigación, analizando los avances recientes en la provisión de pistas, retroalimentación adaptativa, modelado del usuario y generación automática de contenido mediante modelos de lenguaje.

2.1. Sistemas de tutoría inteligente y generación de pistas

2.1.1. Intelligent Tutoring Systems clásicos

Los *Intelligent Tutoring Systems* (ITS) constituyen una de las primeras y más consolidadas aplicaciones de la inteligencia artificial en el ámbito educativo. Su objetivo principal es proporcionar instrucción personalizada mediante la adaptación dinámica de contenidos, ejercicios y mecanismos de ayuda en función del estado cognitivo del estudiante. Desde sus primeras formulaciones, los ITS han buscado modelar explícitamente tanto el dominio de conocimiento como al aprendiz, permitiendo al sistema razonar sobre qué sabe el usuario, qué errores comete y qué tipo de intervención resulta más adecuada en cada momento [4, 8].

Una de las contribuciones más influyentes en este campo es la introducción de los denominados *Cognitive Tutors*, basados en modelos cognitivos que representan las habilidades subyacentes necesarias para resolver un conjunto de problemas. Estos sistemas emplean reglas de producción para simular el razonamiento humano paso a paso y permiten detectar errores específicos durante la resolución de una tarea, lo que facilita la provisión de retroalimentación inmediata y contextualizada [4]. Este enfoque ha demostrado ser especialmente eficaz en dominios estructurados como las matemáticas, la física o la programación introductoria.

La adaptación en los ITS clásicos no se limita a la selección de tareas, sino que también se extiende a la gestión de la ayuda. En este contexto, las pistas se convierten en un elemento central del diseño pedagógico, actuando como un mecanismo intermedio entre la completa autonomía del estudiante y la provisión directa de la solución. La literatura muestra que el uso adecuado de pistas puede mejorar tanto el rendimiento inmediato como la comprensión a largo plazo, siempre que estas se integren de manera coherente dentro del modelo cognitivo del sistema [12, 29].

2.1.2. Estructura y diseño de pistas en ITS

Tradicionalmente, las pistas en los ITS se diseñan siguiendo una estructura jerárquica y progresiva. Este enfoque se basa en la idea de que la ayuda debe proporcionarse de forma incremental, aumentando su especificidad únicamente cuando el estudiante no progresa por sí mismo. En este esquema, se distinguen comúnmente tres niveles principales: pistas de orientación, que ofrecen indicaciones generales sobre el enfoque a seguir; pistas instrumentales, que sugieren pasos intermedios más concretos; y pistas *bottom-out*, que proporcionan directamente la acción o respuesta correcta necesaria para avanzar [1, 12].

Este modelo de múltiples niveles ha sido ampliamente adoptado en sistemas como *ASSISTments*[1] y otros tutores basados en el enfoque de *mastery learning*. Estudios empíricos muestran que la disponibilidad de pistas escalonadas puede reducir la frustración del estudiante y favorecer una resolución más eficiente de los problemas, siempre que el uso de las pistas no derive en una dependencia excesiva del sistema [11].

[1] `https://new.assistments.org/`

En este sentido, el diseño cuidadoso de cada pista resulta crucial, ya que una pista demasiado explícita puede inhibir el razonamiento, mientras que una demasiado vaga puede resultar inútil.

No obstante, un rasgo común de estos sistemas es que las pistas se codifican manualmente como parte del modelo cognitivo del tutor. Esto implica que expertos humanos deben anticipar los errores posibles, definir los distintos niveles de ayuda y redactar cada pista de forma individual. Si bien este enfoque garantiza un alto control pedagógico, también introduce una importante limitación en términos de escalabilidad y coste de desarrollo [29].

2.1.3. Modelado del estudiante y decisión de ayuda

La provisión de pistas en los ITS clásicos no depende únicamente de su diseño, sino también del momento en el que se presentan. Para ello, muchos sistemas incorporan modelos de seguimiento del conocimiento del estudiante, siendo el *Bayesian Knowledge Tracing* (BKT) uno de los métodos más influyentes. BKT utiliza una red bayesiana dinámica para estimar la probabilidad de que un estudiante haya adquirido una habilidad concreta a partir de observaciones discretas como aciertos o errores [8].

Este tipo de modelos permite al sistema tomar decisiones adaptativas sobre cuándo ofrecer ayuda adicional, evitando tanto la sobreasistencia como el abandono del estudiante ante tareas excesivamente complejas. Sin embargo, estos enfoques suelen operar sobre representaciones simplificadas del conocimiento, en las que las pistas se tratan como eventos homogéneos sin una evaluación explícita de su contenido semántico o su impacto cognitivo específico [29].

Como consecuencia, aunque los ITS clásicos pueden decidir *cuándo* ofrecer una pista, rara vez evalúan *qué tan buena* es esa pista desde un punto de vista cognitivo. La calidad de la ayuda se mide de forma indirecta mediante métricas agregadas como el rendimiento final o el número de errores, sin analizar cómo cada pista contribuye a la evolución del razonamiento del estudiante a lo largo del tiempo.

2.1.4. Limitaciones de los enfoques tradicionales

A pesar de su éxito empírico, los enfoques clásicos de los ITS presentan limitaciones claras que han motivado investigaciones posteriores. En primer lugar, la dependencia de reglas y pistas diseñadas manualmente dificulta la extensión del sistema a nuevos dominios o contextos menos estructurados [12]. En segundo lugar, la estructura jerárquica de pistas, aunque ampliamente aceptada, no garantiza por sí misma que una pista sea cognitivamente útil o informativa para un estudiante concreto [3].

Además, los sistemas tradicionales tienden a tratar las pistas como elementos estáticos, sin capacidad de adaptación semántica al contexto específico del error cometido o al historial previo del usuario. Esta rigidez contrasta con la creciente demanda de sistemas educativos capaces de ofrecer explicaciones más flexibles, personalizadas y alineadas con el razonamiento humano.

En conjunto, el estado del arte en ITS establece un marco sólido para el uso de pistas como mecanismo de apoyo al aprendizaje, pero deja abierta la cuestión de cómo generar, adaptar y evaluar pistas de forma automática sin depender exclusivamente del diseño manual. Esta brecha resulta especialmente relevante en escenarios donde el espacio de soluciones es amplio o donde se desea escalar el sistema sin un esfuerzo humano proporcional.

2.2. Generación automática de pistas mediante modelos de lenguaje

2.2.1. Uso de modelos de lenguaje en la generación de ayuda

La reciente irrupción de los *Large Language Models* (LLMs) ha supuesto un punto de inflexión en el diseño de sistemas interactivos de aprendizaje basados en lenguaje natural, incluyendo los *Intelligent*

Tutoring Systems. A diferencia de los enfoques tradicionales, donde las pistas se codifican manualmente como parte del modelo cognitivo del tutor, los LLMs permiten generar explicaciones, sugerencias y pistas de forma automática a partir de descripciones textuales del problema o del estado del usuario.

Este cambio ha despertado un creciente interés en la comunidad investigadora, ya que los LLMs son capaces de producir lenguaje fluido, contextualizado y, en muchos casos, alineado con las expectativas humanas. En el ámbito educativo, esto abre la posibilidad de reducir drásticamente el esfuerzo de diseño humano requerido para construir sistemas de tutoría, especialmente en dominios complejos o poco estructurados. Sin embargo, esta capacidad generativa plantea nuevas preguntas sobre la fiabilidad, la interpretabilidad y la utilidad cognitiva real de las pistas producidas automáticamente.

2.2.2. Evaluación de LLMs en la generación de pistas

Uno de los primeros trabajos en analizar de forma sistemática el uso de LLMs para la generación de pistas es *The Promise and Limits of Large Language Models in Constructing Proofs and Hints* [10]. En este estudio, los autores evalúan la capacidad de distintos modelos de lenguaje para generar pasos intermedios y pistas en problemas de lógica formal y demostración matemática.

Los resultados muestran que los LLMs pueden generar explicaciones y sugerencias plausibles desde un punto de vista sintáctico y semántico, y que, en ciertos casos, estas pistas pueden facilitar el avance del usuario. No obstante, el trabajo también pone de manifiesto limitaciones importantes: las pistas generadas no siempre justifican por qué se ofrecen en un momento concreto, ni contextualizan la pista dentro de la secuencia de razonamiento del usuario ni especifican qué estado cognitivo se espera activar con ella. En consecuencia, la calidad pedagógica de las pistas resulta altamente variable y difícil de garantizar sin mecanismos adicionales de validación [20].

Este tipo de resultados subraya una diferencia fundamental entre los ITS clásicos y los sistemas basados en LLMs. Mientras que en los primeros la pista forma parte explícita de un modelo cognitivo diseñado a priori, en los segundos la pista emerge como un producto probabilístico del modelo, sin una noción explícita de intención pedagógica. La literatura coincide en que esta falta de control dificulta la integración directa de los LLMs en sistemas de tutoría adaptativos sin capas adicionales de evaluación y filtrado [10, 23].

2.2.3. Comparación entre pistas humanas y pistas generadas

Otro eje relevante dentro del estado del arte es la comparación entre pistas generadas automáticamente y aquellas diseñadas por expertos humanos. Diversos estudios empíricos han analizado si modelos como ChatGPT[2] pueden sustituir, total o parcialmente, a las pistas humanas en contextos educativos reales. En dominios como el álgebra o la resolución de problemas estructurados, Pardos y Bhandari observaron que las pistas generadas por ChatGPT superaron controles de calidad en un 70 % de los casos [19].

Sin embargo, aunque ambas condiciones produjeron ganancias de aprendizaje positivas, únicamente las pistas del tutor humano alcanzaron significación estadística [19]. Este resultado es coherente con marcos teóricos del aprendizaje activo, como el modelo ICAP, que establece una relación directa entre el nivel de compromiso cognitivo inducido por una intervención y las ganancias de aprendizaje observadas [6]. Las pistas humanas suelen estar mejor alineadas con el razonamiento esperado, evitan ambigüedades innecesarias y se adaptan de forma implícita al contexto del error cometido. Por el contrario, las pistas generadas por LLMs pueden ser correctas pero poco discriminativas, excesivamente generales o redundantes respecto a información ya conocida por el estudiante.

Esta evidencia sugiere que la cuestión no reside únicamente en la capacidad de los LLMs para generar pistas correctas, sino en la ausencia de criterios claros para determinar cuándo una pista resulta cognitivamente útil. A día de hoy, no existe un análisis sistemático que relacione las propiedades internas de una pista generada con su impacto real sobre el proceso de razonamiento del usuario, lo que constituye una limitación significativa del estado del arte. Esta carencia motiva directamente el primer objetivo

[2]ChatGPT: `https://chat.openai.com`

específico de este trabajo, que propone establecer métricas observables para evaluar la contribución individual de cada pista, y el cuarto, que busca identificar patrones recurrentes de generación subóptima mediante análisis estadístico.

2.2.4. Generación de múltiples niveles de pistas

Siguiendo la tradición de los ITS clásicos en el diseño de ayuda jerárquica, donde las pistas se estructuran de forma progresiva desde orientaciones generales hasta ayudas *bottom-out* [2], algunos trabajos recientes han explorado el uso de LLMs para generar múltiples niveles de pistas de forma automática [28].

Los resultados de estos estudios son dispares. Por un lado, se observa que las pistas demasiado generales pueden resultar inútiles o incluso engañosas, ya que no reducen el espacio de hipótesis del usuario. Por otro lado, las pistas excesivamente específicas pueden trivializar la tarea y reducir el esfuerzo cognitivo necesario para consolidar el aprendizaje. En algunos casos, la inclusión de ejemplos concretos o reformulaciones explícitas mejora el soporte ofrecido al usuario, pero estos efectos no son consistentes entre distintos perfiles de estudiantes.

Un aspecto común en esta línea de investigación es la ausencia de una formalización clara de qué características hacen que una pista sea "buena" desde un punto de vista cognitivo. La mayoría de los trabajos evalúan el impacto de las pistas mediante métricas agregadas como el rendimiento final o el número de aciertos, sin analizar cómo cada pista contribuye a la evolución del razonamiento a lo largo del tiempo. Como resultado, el estado del arte carece de métricas explícitas que permitan evaluar, comparar o seleccionar pistas generadas automáticamente en función de su utilidad funcional real. Esta limitación es la motivación directa del primer objetivo específico de este trabajo, que propone un conjunto de métricas observables —integradas en la función QUILL— capaces de capturar dimensiones como el poder discriminativo, la ambigüedad o la ganancia de información a nivel de pista individual.

En conjunto, la literatura muestra que los LLMs ofrecen un potencial significativo para la generación automática de pistas, pero también revela una brecha clara entre la capacidad generativa del modelo y la capacidad de evaluación cognitiva de las pistas producidas. Esta brecha limita la integración efectiva de los LLMs en sistemas de tutoría adaptativos y pone de manifiesto la necesidad de marcos formales que permitan analizar la utilidad de las pistas más allá de su corrección superficial.

2.3. Modelado cognitivo del usuario mediante estados latentes

Una de las líneas históricamente más relevantes dentro de los *Intelligent Tutoring Systems* es el modelado explícito del estado cognitivo del usuario. Dado que procesos como la comprensión, la adquisición de conocimiento o la certeza sobre una hipótesis no son directamente observables, los ITS han recurrido tradicionalmente a modelos latentes que permiten inferir dichos estados a partir de interacciones observadas, como respuestas correctas o incorrectas, tiempos de reacción o secuencias de acciones.

Este enfoque parte de la premisa de que el comportamiento observable del usuario es una manifestación imperfecta de un estado cognitivo interno subyacente. En consecuencia, el objetivo del sistema no es únicamente reaccionar ante acciones aisladas, sino inferir la evolución del conocimiento o razonamiento del usuario a lo largo del tiempo. Esta perspectiva ha sido ampliamente adoptada en minería de datos educativos y aprendizaje adaptativo, constituyendo uno de los pilares teóricos de los sistemas de tutoría inteligente modernos.

2.3.1. Bayesian Knowledge Tracing y modelos ocultos de Markov

Uno de los modelos más influyentes en este ámbito es el *Bayesian Knowledge Tracing* (BKT), introducido como un mecanismo probabilístico para estimar si un estudiante ha adquirido una habilidad específica en función de su historial de interacciones. BKT modela el proceso de aprendizaje como una

red bayesiana dinámica, formalmente equivalente a un modelo oculto de Markov (HMM), donde el estado oculto representa el dominio o no de una habilidad, y las observaciones corresponden a respuestas correctas o incorrectas [7].

A pesar de su simplicidad, BKT ha demostrado ser eficaz en múltiples dominios educativos y ha servido como base para numerosos sistemas de tutoría adaptativa. No obstante, su formulación clásica asume estados cognitivos discretos y bien definidos, así como observaciones igualmente discretas, lo que limita su capacidad para capturar procesos cognitivos más complejos, graduales o exploratorios.

Trabajos posteriores han extendido este enfoque incorporando variantes de HMM más generales para analizar trayectorias temporales de interacción en entornos educativos y juegos serios. En particular, Tadayon y Pottie utilizan modelos ocultos de Markov para predecir el rendimiento de estudiantes en un juego educativo, mostrando que las secuencias de estados latentes permiten capturar patrones de exploración, aprendizaje y consolidación que no son evidentes a partir de métricas agregadas [27]. Este tipo de resultados refuerza la utilidad de los modelos secuenciales para representar la dinámica del razonamiento del usuario a lo largo del tiempo.

2.3.2. Estados cognitivos como procesos dinámicos

Más allá de la estimación de conocimiento factual, la literatura ha comenzado a explorar representaciones más ricas del proceso cognitivo, en las que los estados latentes no se interpretan únicamente como “sabe” o “no sabe”, sino como fases del razonamiento. Algunos trabajos proponen modelar transiciones entre estados como exploración, convergencia o confirmación, especialmente en tareas abiertas o de resolución de problemas complejos [21].

Este tipo de modelado resulta particularmente relevante en sistemas interactivos donde el usuario formula hipótesis, prueba alternativas y refina progresivamente su comprensión. En estos escenarios, el interés no reside tanto en el resultado final como en la trayectoria seguida para alcanzarlo. Los modelos basados en estados latentes permiten analizar si el usuario progresa de forma consistente hacia la solución, si presenta comportamientos erráticos o si se estanca en fases tempranas del razonamiento.

Desde esta perspectiva, las observaciones no se limitan a respuestas binarias, sino que pueden incluir secuencias de acciones, cambios en las hipótesis planteadas o incluso la distancia semántica entre intentos sucesivos. La incorporación de este tipo de señales observables amplía significativamente el poder descriptivo de los modelos cognitivos, aunque también incrementa su complejidad.

2.3.3. Limitaciones del estado del arte

A pesar de los avances en modelado cognitivo, el estado del arte presenta limitaciones relevantes cuando se combina con sistemas de ayuda o generación de pistas. En muchos enfoques, los modelos latentes se utilizan para estimar el conocimiento global del usuario, pero no para analizar el impacto específico de cada intervención o pista sobre la evolución del razonamiento. Como resultado, se pierde información valiosa sobre cómo una pista concreta contribuye, o no, a la transición entre estados cognitivos.

Además, la mayoría de los modelos existentes operan sobre observaciones discretas y bien definidas, lo que dificulta su aplicación directa a entornos donde las interacciones son abiertas y basadas en lenguaje natural. En estos contextos, las señales observables son más ruidosas y requieren mecanismos adicionales de representación, como embeddings semánticos, para poder integrarse en un modelo probabilístico coherente.

En conjunto, la literatura pone de manifiesto que los modelos ocultos de Markov y sus extensiones constituyen una herramienta sólida para representar procesos cognitivos latentes, pero su integración con sistemas de generación automática de pistas sigue siendo limitada. En particular, no existe un marco consolidado que permita analizar de forma explícita cómo las pistas afectan a la trayectoria cognitiva del usuario, ni cómo esta información puede utilizarse para evaluar la utilidad real de dichas pistas en sistemas interactivos complejos. Esta limitación constituye la motivación directa del tercer objetivo específico de

este trabajo, que propone analizar experimentalmente el impacto de diferentes tipos de pistas sobre la dinámica de interacción del usuario, estudiando cómo influyen en la tasa de acierto y en los patrones de comportamiento observados.

2.4. Evaluación automática de la calidad de las pistas

La evaluación de la ayuda y las pistas en sistemas interactivos ha estado tradicionalmente ligada a métricas globales de rendimiento, como el porcentaje de aciertos, el tiempo total de resolución o las ganancias de aprendizaje medidas mediante pruebas pre y post. Si bien estos indicadores resultan útiles para evaluar el comportamiento general de un sistema, presentan limitaciones significativas cuando se pretende analizar el impacto específico de una pista individual sobre el proceso cognitivo del usuario.

En particular, estas métricas agregadas no permiten aislar la contribución de cada pista dentro de una secuencia de interacción, ni capturar cómo una intervención concreta afecta a la trayectoria de razonamiento del usuario. Como consecuencia, una pista puede considerarse exitosa o fallida únicamente en función del resultado final, sin atender a si ha reducido el espacio de hipótesis, activado procesos de reflexión o inducido confusión temporal.

Esta limitación se vuelve especialmente problemática en sistemas complejos donde el usuario recibe múltiples pistas a lo largo del tiempo, ya que el efecto de una pista concreta puede manifestarse de forma diferida o interactuar con intervenciones posteriores. La literatura reconoce que la evaluación de la ayuda sigue siendo uno de los aspectos menos formalizados dentro de los *Intelligent Tutoring Systems* [29].

2.4.1. Evaluación de la utilidad de las pistas

Algunos trabajos han intentado avanzar hacia métricas más finas que permitan evaluar la utilidad de una pista más allá de su corrección factual. En este contexto, VanLehn introduce el concepto de *help effectiveness*, analizando si la ayuda proporcionada conduce a un progreso observable en el razonamiento del estudiante [29]. No obstante, estos enfoques suelen basarse en observaciones discretas y en dominios altamente estructurados, lo que limita su generalización.

Investigaciones posteriores han propuesto evaluar la utilidad de la ayuda midiendo cambios en el comportamiento inmediatamente posteriores a la pista, como la reducción del número de errores repetidos o la aceleración del progreso hacia la solución. Sin embargo, estos indicadores siguen siendo indirectos y no capturan de forma explícita los mecanismos cognitivos subyacentes. En particular, no distinguen entre pistas que simplemente guían al usuario por ensayo y error y aquellas que fomentan una comprensión más profunda del problema.

En consecuencia, el estado del arte carece de una definición operativa consensuada de qué constituye una "buena pista" desde un punto de vista cognitivo, especialmente en entornos abiertos donde el usuario formula hipótesis, explora alternativas y ajusta progresivamente su razonamiento. Esta limitación constituye la motivación central del primer objetivo específico de este trabajo, que propone un conjunto de métricas formales para evaluar la contribución individual de cada pista al proceso de razonamiento del usuario.

2.4.2. Ambigüedad, redundancia y trampas semánticas

Con la introducción de LLMs en la generación de pistas, han emergido nuevas fuentes de error que no estaban presentes en los sistemas tradicionales. Aunque los modelos de lenguaje pueden generar pistas gramaticalmente correctas y aparentemente relevantes, diversos estudios han mostrado que estas pueden ser cognitivamente ambiguas, redundantes o incluso engañosas [17].

Estas denominadas *trampas semánticas* se producen cuando una pista es técnicamente correcta pero no reduce el espacio de hipótesis del usuario, induce interpretaciones múltiples o refuerza asociaciones

incorrectas. En el contexto educativo, este tipo de pistas puede generar ruido cognitivo, ralentizar el proceso de convergencia o aumentar la frustración del usuario.

La literatura sobre evaluación de explicaciones generadas automáticamente señala que la fluidez lingüística no es un indicador fiable de calidad semántica o utilidad cognitiva [30]. Sin embargo, la mayoría de estos trabajos se centran en tareas de *natural language processing* y no abordan directamente el impacto de las explicaciones o pistas sobre el comportamiento de un usuario humano en una tarea interactiva.

2.4.3. Evaluación basada en comportamiento del usuario

Una línea emergente de investigación propone evaluar la calidad de las pistas a partir del comportamiento observable del usuario tras recibirlas. Desde esta perspectiva, una pista se considera útil si provoca cambios sistemáticos en el razonamiento del usuario, como la generación de hipótesis más cercanas a la solución, una reducción de la exploración errática o una mayor coherencia en las respuestas sucesivas [13].

Este enfoque conecta de forma natural con el uso de modelos secuenciales y estados latentes, ya que permite analizar cómo una pista contribuye a transiciones entre estados cognitivos. No obstante, la mayoría de los trabajos existentes se limitan a dominios cerrados y observaciones discretas, como respuestas correctas o incorrectas, sin incorporar señales más ricas como la similitud semántica entre intentos o la evolución del contenido de las hipótesis formuladas por el usuario.

En sistemas basados en lenguaje natural, esta limitación se acentúa, ya que la evaluación requiere mecanismos adicionales para representar el contenido semántico de las interacciones. Aunque los embeddings distribucionales ofrecen una posible solución, su integración en marcos formales de evaluación cognitiva sigue siendo un problema abierto.

En síntesis, el estado del arte muestra un interés creciente por la evaluación automática de la ayuda y las pistas, pero carece de marcos formales que integren generación, evaluación y adaptación de forma coherente. Las métricas existentes son mayoritariamente indirectas, agregadas o dependientes del dominio, y no permiten caracterizar la utilidad funcional de una pista individual dentro de una secuencia de interacción compleja. Esta carencia es especialmente evidente en sistemas que emplean LLMs, donde la capacidad de generar pistas supera ampliamente la capacidad de evaluarlas. Dar respuesta a esta limitación es el objetivo transversal de este trabajo, que propone QUILL como marco formal para evaluar pistas en función de su impacto observable sobre el razonamiento del usuario.

2.5. Resumen de limitaciones y objetivos del TFG

A partir del análisis de los tres bloques anteriores, es posible identificar las principales limitaciones del estado del arte y establecer su correspondencia con los objetivos específicos planteados en este trabajo. La tabla siguiente sintetiza esta relación:

Limitación identificada	**Sección**	**Objetivo específico del TFG que la aborda**
Ausencia de métricas explícitas para evaluar la utilidad funcional de pistas individuales generadas automáticamente	§2.2, §2.4	OE1: Establecer métricas observables para evaluar la contribución individual de cada pista al proceso de razonamiento del usuario
Los LLMs carecen de mecanismos internos para validar la utilidad pedagógica del texto que generan; la calidad de las pistas es heterogénea	§2.2	OE2: Integrar LLMs como generadores automáticos de pistas analizando sus limitaciones en ambigüedad y utilidad cognitiva
Los modelos de seguimiento cognitivo no analizan el impacto específico de cada pista sobre la trayectoria de razonamiento del usuario	§2.3	OE3: Analizar experimentalmente el impacto de diferentes tipos de pistas sobre la dinámica de interacción del usuario
No se han identificado empíricamente los patrones de generación subóptima de pistas ni sus consecuencias sobre el comportamiento del usuario	§2.2	OE4: Identificar patrones recurrentes de generación subóptima de pistas mediante análisis estadístico de datos reales de interacción

Tabla 2.1: Limitaciones del estado del arte y objetivos específicos del TFG que las abordan.

Capítulo 3

Metodología

3.1. Metodología

La metodología seguida en este trabajo adopta un enfoque empírico basado en datos para la evaluación de la calidad de pistas, combinando modelado formal y validación experimental con usuarios. En este marco, se propone un proceso estructurado en varias etapas. En primer lugar, se parte de una fuente de conocimiento estructurada (Wikipedia) a partir de la cual se generan automáticamente pistas mediante modelos de lenguaje. Estas pistas constituyen la unidad fundamental de análisis y sobre ellas se calculan un conjunto de métricas diseñadas para capturar distintas dimensiones de calidad, integradas posteriormente en la función QUILL. A continuación, las pistas se presentan a usuarios en un entorno interactivo (*Spygame*[1]), donde se registran sus interacciones y respuestas, generando datos de comportamiento. Estos datos permiten analizar empíricamente la relación entre las propiedades de las pistas y su efectividad, mediante modelos estadísticos que estiman el impacto de cada métrica en el éxito del usuario. Finalmente, los resultados obtenidos se utilizan para validar y ajustar la función propuesta, cerrando así el ciclo entre generación, evaluación y validación de las pistas.

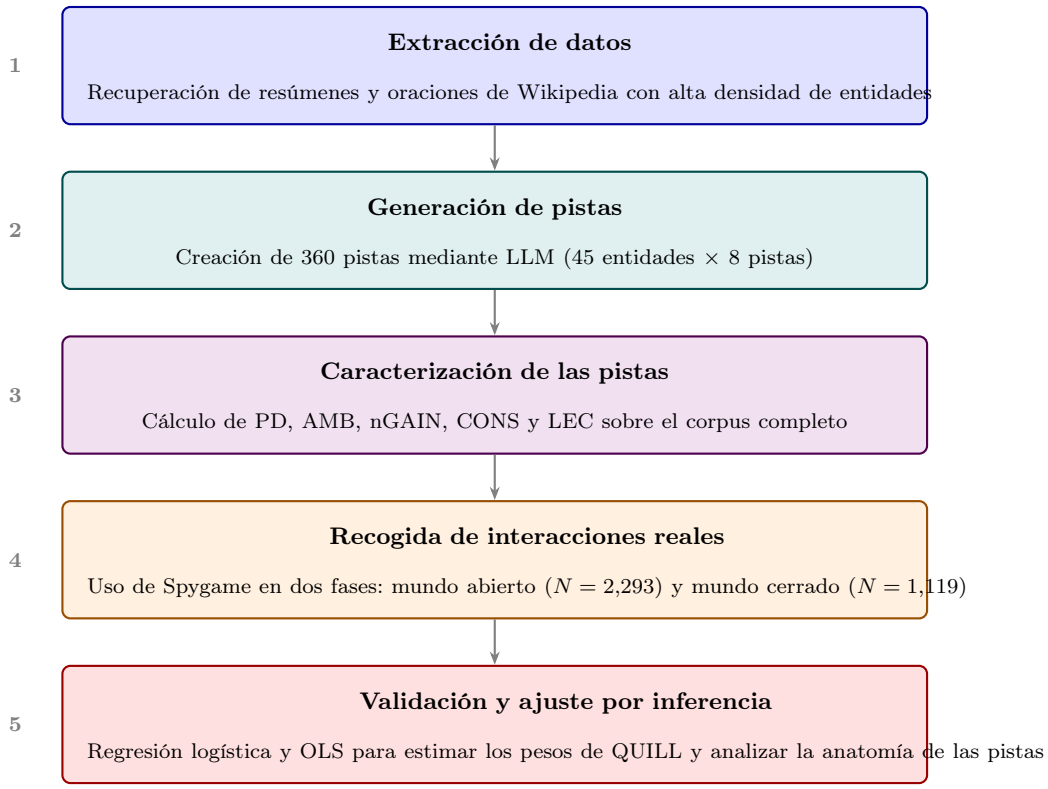


Figura 3.1: Flujo de trabajo de la metodología propuesta: desde la extracción de datos hasta la validación estadística del marco QUILL.

El estudio se articula en torno a cuatro hipótesis falsables:

[1] `https://wiig.dia.fi.upm.es/spygame`

- **H1:** La función QUILL presenta una asociación estadísticamente significativa con la probabilidad de acierto del usuario (AUC $> 0{,}5$, test de razón de verosimilitud $p < 0{,}05$).
- **H2:** El poder discriminativo (PD) tiene una contribución significativamente mayor que el resto de métricas en la predicción del éxito del usuario (coeficiente de regresión logística superior y estadísticamente significativo frente a los demás).
- **H3:** Al menos una propiedad lingüística superficial presenta un coeficiente de regresión estadísticamente significativo ($p < 0{,}05$) en los modelos OLS que predicen las métricas de calidad semántica.
- **H4:** La transición de mundo abierto a mundo cerrado produce un cambio estadísticamente significativo en el rendimiento general de los usuarios y en los coeficientes de las métricas de calidad en el modelo logístico.

3.1.1. Extracción de datos

Para garantizar un conjunto de objetivos homogéneo y replicable, se seleccionaron 45 figuras públicas a partir de Wikipedia. La definición operativa de "fama" se estableció mediante el número de enlaces entrantes a la página principal del individuo en la Wikipedia en inglés, que presenta mayor cobertura global. Se fijó un umbral mínimo de 200 enlaces y la selección final se realizó de manera aleatoria entre los candidatos elegibles, reduciendo la intervención manual y posibles sesgos subjetivos. La Tabla 3.1 muestra los 45 personajes seleccionados ordenados por popularidad decreciente; todos superan el umbral mínimo establecido, con Corbin Bleu como caso de menor popularidad (297 enlaces).

Tabla 3.1: Número de artículos de la Wikipedia en inglés con enlace entrante a cada personaje seleccionado, ordenados de mayor a menor. Todos superan el umbral mínimo de 200 enlaces. Los nombres son hipervínculos al artículo correspondiente en Wikipedia en inglés.

#	**Personaje (Wikipedia en inglés)**	**Nº de enlaces**
1	Ronald Reagan	13.990
2	Adolf Hitler	13.274
3	Franklin D. Roosevelt	11.909
4	William Shakespeare	11.621
5	Abraham Lincoln	11.348
6	Jesús de Nazaret	10.788
7	Napoleón Bonaparte	10.530
8	Winston Churchill	10.478
9	Vladímir Putin	10.044
10	Iósif Stalin	8.307
11	Aristóteles	7.280
12	Mahoma	7.004
13	Mahatma Gandhi	6.634
14	Karl Marx	6.358
15	Platón	6.056
16	Agustín de Hipona	6.017
17	Julio César	5.857

Continúa en la página siguiente

#	**Personaje (Wikipedia en inglés)**	**Nº de enlaces**
18	Alejandro Magno	5.760
19	Ludwig van Beethoven	5.600
20	Benjamin Franklin	5.476
21	Albert Einstein	5.176
22	Charles Dickens	5.161
23	Nelson Mandela	5.104
24	Oscar Wilde	4.241
25	Immanuel Kant	4.146
26	Pablo Picasso	4.127
27	Charles Chaplin	4.033
28	Isaac Newton	3.769
29	Leonardo da Vinci	3.536
30	Cristóbal Colón	3.454
31	Buda Gautama	3.400
32	Rabindranath Tagore	3.346
33	Victor Hugo	3.294
34	Antón Chéjov	2.861
35	Dante Alighieri	2.782
36	Nikola Tesla	2.624
37	Vincent van Gogh	2.576
38	Miguel Ángel	2.480
39	Sócrates	2.465
40	René Descartes	2.420
41	Franz Kafka	2.175
42	Molière	2.091
43	Galileo Galilei	1.946
44	Marie Curie	1.653
45	Corbin Bleu	297

De cada persona seleccionada se extrajeron dos tipos de información:

- El *summary* inicial del artículo, que proporciona una descripción contextual general.
- Oraciones con alta densidad de entidades nombradas (fechas, organizaciones, ubicaciones), identificadas automáticamente.

El proceso de extracción se realizó automáticamente mediante **spaCy** (`es_core_news_sm`), asignando a cada oración una puntuación de densidad de entidades según el siguiente esquema: la presencia de una entidad temporal (`DATE`) aporta +2 puntos; las entidades de tipo localización (`LOC`) u organización (`ORG`) contribuyen +1 punto cada una; la referencia al sujeto del personaje aporta +2 puntos si se trata del

nombre propio y +1 si es un pronombre. Se descartaron las oraciones con menos de seis o más de ochenta palabras, y solo se retuvieron las que alcanzaron una puntuación ≥ 1, seleccionando finalmente las treinta de mayor puntuación por artículo.

Estas últimas se consideran especialmente adecuadas como unidades informativas breves, dado su alto contenido factual y su potencial discriminativo como pistas.

3.1.2. Generación de pistas

A partir del material extraído de Wikipedia, se generaron pistas utilizando el modelo `Meta-Llama-3.1-70B-Instruct`, accedido mediante la API de HuggingFace[2]. Este modelo pertenece a la familia de grandes modelos de lenguaje (*Large Language Models*, LLMs), cuyo comportamiento emergente en tareas de generación textual ha sido ampliamente documentado [5]. Se eligió este modelo por su acceso gratuito mediante la API de inferencia de HuggingFace, su capacidad de 70B parámetros que garantiza una generación textual de alta calidad, su naturaleza multilingüe —adecuada para la generación de pistas en español—, y su disponibilidad pública sin restricciones de uso para investigación.

El proceso empleó técnicas de *context learning*, proporcionando ejemplos estructurados que especificaban el formato de salida, la longitud esperada y el grado relativo de dificultad. Este enfoque permite guiar el comportamiento del modelo sin necesidad de ajuste fino adicional. A continuación se reproducen las reglas principales del prompt de generación utilizado:

Reglas críticas de redacción:

1. **Anonimato absoluto:** No mencionar el nombre del personaje bajo ninguna circunstancia, ni sustituirlo por títulos obvios (*"el famoso físico"*).
2. **Diversidad temática:** Prohibido generar más de una pista sobre el mismo evento biográfico; igualmente prohibido el uso de sinónimos para duplicar pistas.
3. **Estructura y longitud:** Sujeto tácito; longitud exacta de 15 a 25 palabras por pista; variedad de inicio entre pistas consecutivas.
4. **Contenido:** Usar exclusivamente la información del texto proporcionado; prohibidas las alucinaciones.
5. **Jerarquía de dificultad 5 → 1:** nivel 5 = dato oscuro o trivial; nivel 4 = detalle previo a la fama; nivel 3 = obras o logros secundarios; nivel 2 = datos biográficos generales; nivel 1 = profesión principal o logro mundialmente conocido.
6. **Formato de salida:** JSON estricto: `{"pistas": [{"dificultad": N, "pista": "..."}]}`; sin texto adicional fuera del JSON.

Para cada persona se generaron ocho pistas, organizadas ordinalmente por dificultad decreciente (etiquetadas de 5 a 1). La dificultad fue determinada por el grado de especificidad de la información incluida en el prompt: el nivel 5 corresponde a datos muy poco conocidos o especializados del personaje, mientras que el nivel 1 alude a rasgos ampliamente conocidos que permiten una identificación directa. La distribución no es uniforme: una pista de nivel 5, una de nivel 4 y dos pistas para cada uno de los niveles restantes. Este diseño experimental busca incrementar progresivamente la especificidad informativa a lo largo de la partida, permitiendo observar cómo varía la toma de decisiones del usuario en función del grado de ambigüedad del estímulo.

El corpus final está compuesto por 360 pistas (45 personas × 8 pistas). La tabla siguiente muestra una muestra representativa de pistas de tres personas, ilustrando cómo varía el contenido en función del nivel de dificultad asignado:

[2] `https://huggingface.co/inference-api`

Persona	Dificultad	Pista generada
Isaac Newton	5	"Escribió una lista de sus pecados, incluyendo amenazar a sus padres con quemar su casa."
Galileo Galilei	3	"Observó manchas en el Sol y demostró que están en su superficie."
Ludwig van Beethoven	1	"Fue un compositor y pianista alemán que influyó en la música del siglo XIX."

Tabla 3.2: Muestra de pistas del corpus a distintos niveles de dificultad.

3.1.3. Caracterización de las pistas

Para cuantificar la similitud semántica entre pistas, objetivos y respuestas del usuario sin depender de coincidencia léxica exacta, es necesario representar los textos como vectores en un espacio de alta dimensionalidad donde la proximidad geométrica refleje la proximidad conceptual. Esta representación permite calcular métricas como el poder discriminativo o la ambigüedad relativa de forma continua y sensible al contenido semántico.

Se empleó el modelo `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2`, basado en la arquitectura SBERT [22]. Este modelo fue seleccionado por su soporte multilingüe nativo —que garantiza representaciones adecuadas del español—, su tamaño reducido que permite una inferencia eficiente, y su disponibilidad en la librería `sentence-transformers`. El modelo proyecta textos en un espacio vectorial de 384 dimensiones donde la similitud del coseno aproxima la proximidad semántica entre representaciones.

Los *guesses* son las respuestas en lenguaje natural introducidas por el jugador para indicar su hipótesis sobre la identidad del objetivo. Se generaron embeddings para:

- Los nombres de las 45 personas.
- Las 360 pistas generadas.
- Los *guesses* textuales introducidos por los usuarios.

Estos vectores permiten cuantificar relaciones semánticas entre pistas, objetivos y respuestas de los jugadores, constituyendo la base para el cálculo posterior de métricas informativas.

Además de las métricas semánticas, resulta relevante analizar qué propiedades superficiales del texto —morfológicas, sintácticas y léxicas— se asocian con cada dimensión de calidad. Para ello, se extrajeron las siguientes características de cada pista: proporciones de categorías gramaticales (nombres propios, verbos, adjetivos, numerales), número de entidades nombradas reconocidas, profundidad máxima del árbol de dependencias sintácticas, valor máximo de frecuencia inversa de documento (IDF) como indicador de rareza léxica, y el índice de lecturabilidad adaptado al español. Estas características son relevantes porque cada una captura una dimensión estructural distinta: la densidad verbal puede relacionarse con la carga cognitiva, la presencia de entidades nombradas con el anclaje factual, y la rareza léxica con la especificidad informativa.

Con el objetivo de extraer estas características de forma automática, se emplearon las siguientes herramientas:

- **spaCy** (`es_core_news_sm`) para etiquetado morfosintáctico, análisis de dependencias y reconocimiento de entidades.
- **TF-IDF** (scikit-learn) para estimar la rareza léxica relativa.

- **textstat** (índice Fernández-Huerta) para medir la lecturabilidad adaptada al español.

Todas las proporciones se calcularon respecto al número total de tokens válidos, neutralizando el efecto de la longitud del texto.

3.1.4. Recogida de interacciones reales

Spygame fue diseñado como entorno experimental que permite validar empíricamente las pistas generadas a través del comportamiento real de usuarios, recogiendo señales observables del proceso de razonamiento —intentos de respuesta, solicitudes de pistas adicionales y abandonos— sin necesidad de autoreporte. Este enfoque cierra el ciclo metodológico: las pistas evaluadas intrínsecamente mediante QUILL se someten aquí a validación extrínseca, vinculando cada métrica de calidad con una señal de comportamiento medible.

La plataforma *Spygame* fue concebida como un entorno experimental interactivo que permite registrar el comportamiento real de usuarios ante estímulos lingüísticos controlados, garantizando la trazabilidad completa de cada decisión tomada durante la partida. La aplicación está operativa desde el 17 de diciembre de 2025 y se sustenta en una arquitectura basada en MongoDB, empleando una base de datos documental para almacenar pistas, usuarios y sesiones en formato JSON.

Los usuarios requieren registro previo con nombre de usuario y contraseña para acceder a la funcionalidad completa. Existe además un modo invitado con funcionalidad limitada y sin persistencia del historial de partidas. Durante el proceso de registro, cada usuario completa un breve cuestionario de autoevaluación que recoge información sobre cultura general, aptitudes informáticas y habilidades de búsqueda de información. Estas variables se almacenan como atributos del usuario y permiten estudiar la posible interacción entre el perfil cognitivo declarado y la utilidad efectiva de las pistas. La aplicación incorpora también una tabla de clasificación pública (*leaderboard*) que introduce un componente competitivo, incrementando el número de sesiones y, por tanto, el tamaño muestral disponible.

El despliegue de la herramienta se estructuró metodológicamente en dos fases diferenciadas para evaluar el impacto del contexto de decisión en la eficacia de las pistas. La primera fase operó bajo un paradigma de "mundo abierto", donde los usuarios debían inferir la identidad objetivo apoyándose exclusivamente en su conocimiento previo y estrategias de búsqueda libre. Posteriormente, se implementó una segunda fase bajo un paradigma de "mundo cerrado", en el cual se proporcionó a los jugadores el listado completo de los 45 objetivos posibles. Esta modificación metodológica permite contrastar el rendimiento de las pistas cuando la tarea cognitiva principal transita de la evocación libre al reconocimiento deductivo acotado.

En cada partida, el sistema selecciona una persona de forma pseudoaleatoria, priorizando aquellas no mostradas previamente al usuario. Este mecanismo reduce la repetición de contenido y evita sesgos de aprendizaje derivados de la familiaridad con los datos.

El orden de presentación de las pistas se aleatoriza en cada sesión, desacoplando la dificultad teórica del orden temporal y permitiendo analizar la influencia independiente de ambos factores.

Durante una sesión, el usuario puede solicitar una pista adicional, intentar adivinar la persona o abandonar la partida. Cada respuesta explícita tras la presentación de una pista se define como una *acción*. Formalmente:

$$a_i = \langle h_i, u, t_i, r_i \rangle$$

donde h_i representa la pista mostrada, u identifica al usuario, t_i el instante temporal y r_i la reacción observada. El subíndice i denota el turno dentro de la sesión, no el índice del usuario. Los valores posibles de r_i son: *acierto* (el usuario identifica correctamente el objetivo), *fallo* (respuesta incorrecta), *solicitar_pista* (el usuario pide una pista adicional) y *abandonar* (el usuario finaliza la partida sin resolver).

Una sesión se modela como una secuencia ordenada de acciones $\{a_1, \ldots, a_n\}$. Para dar soporte a la fase de mundo cerrado, la interfaz de usuario se actualizó integrando un panel visual accesible que listaba el elenco completo de candidatos, limitando el espacio de búsqueda del jugador. En el momento del análisis, el dataset consolidado contiene un total de 3.412 interacciones registradas. De estas, 2.293 corresponden a la fase inicial de mundo abierto y 1.119 fueron recolectadas durante la fase experimental de mundo cerrado.

Se distinguen explícitamente dos niveles conceptuales de análisis. El primero es el **nivel pista** ($N = 360$), que constituye la unidad fundamental del proyecto: sobre cada pista se calculan las métricas de calidad definidas formalmente en la sección siguiente. El segundo es el **nivel interacción** ($N = 3{,}412$), la unidad empírica de validación: cada interacción pista–usuario se considera una observación independiente y se utiliza para estimar la relación entre las métricas y el comportamiento real. Cada interacción se encuentra etiquetada según la fase metodológica a la que pertenece (mundo abierto o cerrado), lo que permite aislar el efecto del diseño de la interfaz sobre el rendimiento.

No se modelaron efectos aleatorios por usuario, por lo que múltiples interacciones de un mismo individuo se tratan como independientes. Este enfoque puede introducir pseudorreplicación y se reconoce como limitación metodológica. Un tratamiento más riguroso requeriría modelos mixtos con efectos aleatorios por usuario.

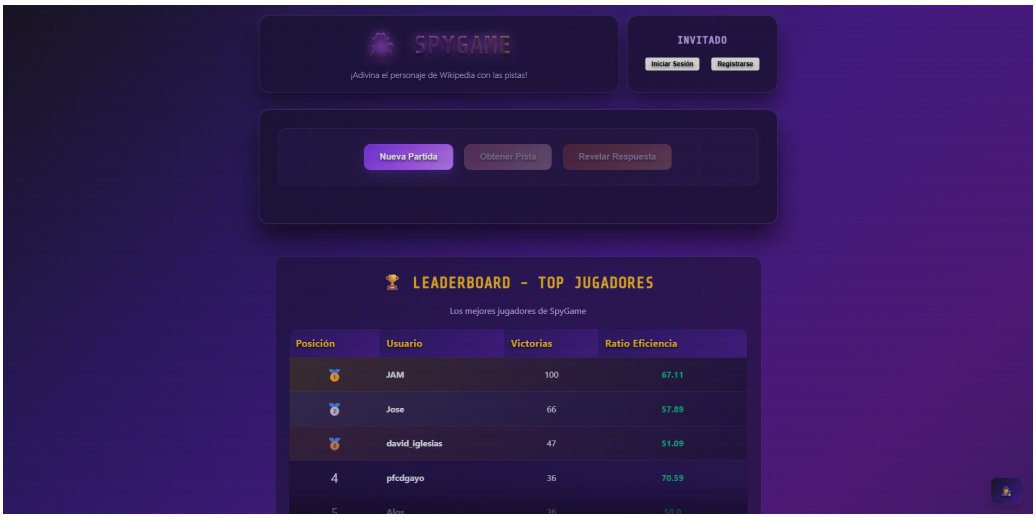
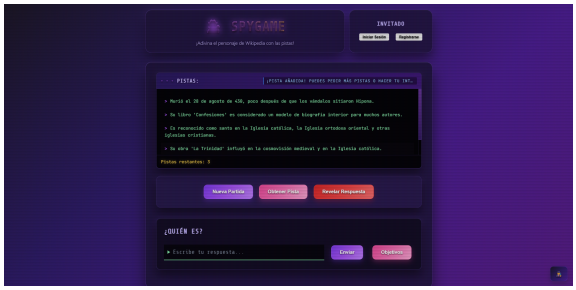
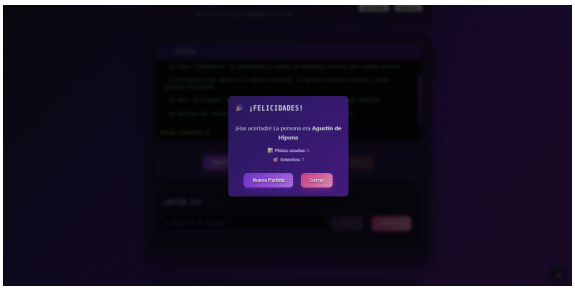


Figura 3.2: Pantalla de inicio de Spygame con formulario de registro y acceso.



(a) Interfaz de partida activa: pista visible, campo de respuesta y botón para solicitar nueva pista.



(b) Pantalla de resultado tras acierto, con puntuación y opción de nueva partida.

Figura 3.3: Flujo de juego en Spygame: partida activa (a) y pantalla de resultado (b).

3.1.5. Validación y ajuste por inferencia

Para validar el marco propuesto, son necesarios dos tipos de información estadística. Por un lado, se necesita estimar empíricamente el peso relativo de cada métrica de calidad sobre la probabilidad de acierto

del usuario, de modo que la función QUILL pueda ajustarse a partir de datos reales de comportamiento. Por otro lado, se requiere comprender qué propiedades lingüísticas superficiales de las pistas explican las variaciones en las métricas semánticas, lo que permite identificar patrones de generación subóptima. Para obtener esta información, el análisis se estructura en dos etapas complementarias.

3.1.5.1. Regresión logística

Se ajustó un modelo de regresión logística binaria sobre el total de interacciones, donde la variable dependiente es el acierto del jugador (1/0) y las variables independientes son las métricas de calidad definidas a nivel de pista.

El objetivo es estimar empíricamente el peso relativo de cada dimensión en la probabilidad de éxito, obteniendo una función de calidad basada en comportamiento real. Para controlar el efecto del cambio de paradigma experimental, el modelo incorpora una variable categórica que identifica la modalidad de la partida (mundo abierto vs. mundo cerrado). La inclusión de este factor permite estimar empíricamente si la influencia de las métricas de calidad sobre la probabilidad de éxito varía de forma significativa cuando se reduce la incertidumbre del espacio de soluciones.

3.1.5.2. Modelos explicativos OLS

Para analizar qué propiedades lingüísticas explican cada dimensión de calidad, se ajustaron cinco modelos de regresión lineal múltiple (uno por métrica como variable dependiente), utilizando como predictores las características lingüísticas extraídas.

Todas las variables fueron estandarizadas mediante normalización z para obtener coeficientes comparables.

Se verificaron los supuestos clásicos de regresión. La multicolinealidad se evaluó mediante VIF (<5). Las pruebas de Shapiro-Wilk indicaron desviaciones de normalidad en los residuos, y el test de Breusch-Pagan detectó heterocedasticidad en algunos modelos. Para garantizar inferencia válida, se emplearon errores estándar robustos HC3 [14]. Bajo los supuestos de Gauss-Markov, los estimadores OLS permanecen insesgados y eficientes en sentido lineal.

Capítulo 4

Evaluación

4.1. Métricas para la evaluación y selección de pistas

La generación automática de pistas en un sistema de juego requiere un mecanismo de validación robusto que garantice no solo la veracidad de la información, sino también su utilidad lúdica. Una pista válida debe ser discriminativa (apuntar al objetivo), no trivial (evitar spoilers directos) y semánticamente coherente.

Para cuantificar estas propiedades, se propone un esquema de evaluación compuesto por métricas semánticas, métricas sintáctico-lingüísticas y una función de agregación final.

Las métricas semánticas evalúan la relación conceptual entre la pista h y el conjunto de candidatos C, así como la coherencia interna del propio texto. El Poder Discriminativo (PD), la Ambigüedad Relativa (AMB) y la Consistencia Semántica Interna (CONS) son contribuciones originales de este trabajo, diseñadas específicamente para capturar distintas dimensiones de la utilidad funcional de una pista en el contexto de los sistemas interactivos de deducción. La Ganancia de Información Normalizada (nGAIN) se inspira en los fundamentos de la teoría de la información [25, 9] y adopta el principio de reducción de entropía empleado en aprendizaje activo [24]. La Lecturabilidad (LEC) se basa en el Índice de Perspicuidad de Flesch-Szigriszt, estándar para la evaluación de legibilidad en español [26].

4.1.1. Poder Discriminativo (PD)

El Poder Discriminativo mide la capacidad de la pista h para acercarse semánticamente al concepto objetivo c^* más que al promedio del resto de candidatos en el espacio de búsqueda. Se basa en la premisa de que una buena pista debe maximizar la similitud con el objetivo mientras minimiza la similitud promedio con los distractores.

Sea $\mathbf{e}(\cdot)$ la función de *embedding* que mapea un texto a un espacio vectorial de dimensión d:

$$\mathrm{PD}(h) = \cos(\mathbf{e}(h), \mathbf{e}(c^*)) - \frac{1}{N-1} \sum_{c \in C, c \neq c^*} \cos(\mathbf{e}(h), \mathbf{e}(c)) \tag{4.1}$$

Donde:

- C es el conjunto total de candidatos posibles y $N = |C|$.
- $\cos(\mathbf{u}, \mathbf{v})$ denota la similitud coseno entre dos vectores.

Un valor alto indica fuerte direccionalidad hacia el objetivo. Un valor negativo implica que la pista está, en promedio, más cerca de distractores que del target. El rango teórico de PD es $(-1, 1)$, aunque en la práctica los valores del corpus oscilan entre $-0{,}16$ y $+0{,}30$.

Esta métrica captura la función primaria de una pista: señalar diferencialmente al objetivo dentro del espacio semántico global.

Ejemplo. La pista *"Nació en Lumbini en el seno de una familia aristocrática en la república Sakia."* (Buda Gautama) obtiene PD = +0,285: el término *Lumbini* y el contexto de la república Sakia sitúan la

pista en un espacio semántico muy próximo al objetivo, alejándola de los distractores. En contraste, la pista *"Nació en una familia próspera y estudió en el Collège de Clermont."* (Molière) obtiene PD = −0,144: las nociones de familia acomodada y formación académica genérica son compartidas por numerosos candidatos del corpus, de modo que la pista resulta más cercana en promedio a los distractores que al objetivo.

4.1.2. Ambigüedad Relativa (AMB)

Mientras que el Poder Discriminativo compara contra el promedio, la métrica de Ambigüedad se enfoca en el riesgo específico de confusión con el *mejor rival*. No importa si la pista descarta a la mayoría de candidatos; si existe un solo distractor que se asemeja al objetivo tanto como la pista, esta resulta inútil para el jugador.

Definimos la AMB como el ratio de similitud entre el mejor candidato incorrecto y el objetivo:

$$\text{AMB}(h) = \frac{\text{sim}(h, c_{rival})}{\text{sim}(h, c_{rival}) + \text{sim}(h, c^*)} \tag{4.2}$$

donde:

$$c_{rival} = \arg \max_{c \in C, c \neq c^*} \text{sim}(h, c)$$

Esta formulación produce valores típicamente próximos a $[0, 1]$ cuando ambas similitudes son positivas. Sin embargo, si $\text{sim}(h, c^*) < 0$ (el embedding de la pista no apunta hacia el objetivo), el denominador puede ser menor que el numerador y AMB puede superar la unidad, señalando que el rival atrae más señal semántica que el propio objetivo:

- AMB $\approx$ 0,5: Incertidumbre máxima (la pista se parece igual a ambos candidatos).
- AMB $<$ 0,5: La pista apunta correctamente al objetivo.
- AMB $>$ 0,5: La pista favorece semánticamente al rival sobre el objetivo.
- AMB $>$ 1,0: Caso extremo; el rival atrae más señal que el objetivo, indicando ausencia total de discriminación.

Ejemplo. Con la pista de Buda Gautama anterior se obtiene AMB = 0,360 $<$ 0,5: el objetivo supera claramente al mejor rival en similitud, por lo que la pista señala correctamente al objetivo. Con la pista de Molière, AMB = 1,910 $>$ 1,0: el rival genera más similitud que el propio objetivo, convirtiendo la pista en una fuente de confusión sistemática para el usuario.

4.1.3. Ganancia de Información Normalizada (nGAIN)

Esta métrica es ortogonal a la Ambigüedad Relativa: mientras AMB vigila al competidor más cercano, GAIN evalúa cuánto reduce la pista la incertidumbre global del espacio de búsqueda (volumen de candidatos).

Primero, inducimos una distribución de probabilidad $P(h)$ sobre los candidatos mediante una función Softmax con temperatura τ:

$$p_i(h) = \frac{\exp(\cos(\mathbf{e}(h), \mathbf{e}(c_i))/\tau)}{\sum_{j=1}^{N} \exp(\cos(\mathbf{e}(h), \mathbf{e}(c_j))/\tau)} \tag{4.3}$$

La entropía posterior es:

$$H(h) = -\sum_{i=1}^{N} p_i(h) \log p_i(h) \tag{4.4}$$

Considerando que la entropía inicial H_0 (sin pista) es la de una distribución uniforme ($H_0 = \log N$) [9, 25], definimos la Ganancia de Información normalizada como:

$$\text{nGAIN}(h) = \frac{H_0 - H(h)}{H_0} \tag{4.5}$$

El valor resultante representa el porcentaje del espacio de búsqueda que ha sido efectivamente descartado por la pista. Un valor de 1.0 indicaría una identificación perfecta y única. Esta formulación es análoga a la reducción de entropía empleada en aprendizaje activo para seleccionar las consultas más informativas sobre un espacio de hipótesis [24].

Ejemplo. La pista de Buda Gautama obtiene nGAIN = 0,638: reduce en un 63,8 % la entropía inicial del espacio de 45 candidatos, concentrando la distribución de probabilidad sobre un subconjunto reducido de alternativas compatibles. La pista de Molière obtiene nGAIN = 0,232: solo descarta el 23,2 % de la entropía inicial, dejando una gran incertidumbre residual sobre el objetivo.

4.1.4. Consistencia Semántica Interna (CONS)

Para asegurar que la pista no sea una concatenación de conceptos disjuntos (producto de alucinaciones del modelo), se evalúa su cohesión. La pista h se segmenta en K unidades semánticas $\{u_1, \ldots, u_K\}$.

La consistencia es la similitud media entre pares de fragmentos:

$$\text{CONS}(h) = \frac{2}{K(K-1)} \sum_{i=1}^{K} \sum_{j=i+1}^{K} \cos(\mathbf{e}(u_i), \mathbf{e}(u_j)) \tag{4.6}$$

Esta métrica garantiza que la pista mantenga un tema conceptual unificado.

Ejemplo. La pista de Buda Gautama obtiene CONS = 0,756: los fragmentos *Lumbini*, *familia aristocrática* y *república Sakia* comparten un dominio semántico cohesionado (origen geográfico y contexto social del nacimiento). En contraste, una pista hipotética como *"Estudió las leyes del movimiento y pintó el techo de la Capilla Sixtina."* obtendría un valor de CONS muy reducido, pues mezcla física clásica y arte renacentista —dominios semánticamente lejanos— cuyas unidades presentarían baja similitud coseno entre sí.

4.1.5. Lecturabilidad y Carga Cognitiva (LEC)

Más allá de la precisión semántica, es imperativo validar la *calidad superficial* del texto. Una pista puede ser matemáticamente discriminativa pero lúdicamente inviable si presenta una sintaxis enrevesada, un vocabulario excesivamente técnico o una longitud que agote la atención del jugador.

Para cuantificar esto, utilizamos el Índice de Perspicuidad de Flesch-Szigriszt [26], el estándar académico para evaluar la legibilidad en lengua española. Este índice pondera la longitud de las frases y la complejidad silábica de las palabras.

Sea $ISZ(h)$ el valor crudo obtenido mediante la fórmula:

$$ISZ(h) = 206{,}84 - 62{,}3 \left(\frac{\text{Sílabas}}{\text{Palabras}} \right) - \left(\frac{\text{Palabras}}{\text{Frases}} \right) \tag{4.7}$$

Dado que el índice original oscila en una escala aproximada de 0 (muy difícil) a 100 (muy fácil), normalizamos el valor al intervalo $[0, 1]$ para integrarlo en el sistema de puntuación:

$$\text{LEC}(h) = \text{mín} \left(1, \text{máx} \left(0, \frac{ISZ(h)}{100} \right) \right) \tag{4.8}$$

Esta métrica actúa como un proxy de la accesibilidad cognitiva, penalizando implícitamente tanto las frases excesivamente largas como el abuso de polisílabos innecesarios.

Ejemplo. La pista *"Fue un físico y matemático que desarrolló las leyes de la física y la astronomía."* (Isaac Newton, dificultad 1) obtiene LEC $\approx 0{,}99$: oración breve con vocabulario accesible. En contraste, una pista como *"La contribución epistemológica del personaje a la elucidación de los mecanismos electromagnéticos subyacentes a la propagación de la luz constituyó un hito paradigmático en la historiografía científica contemporánea."* obtendría un valor de LEC inferior a 0.3, penalizada por la acumulación de polisílabos técnicos y la longitud de la oración.

4.1.6. Restricción de Proximidad (CLAMP)

Para evitar pistas triviales o *spoilers*, se introduce una penalización basada en la proximidad directa al objetivo. Sea $\text{PROX}(h) = \cos(\mathbf{e}(h), \mathbf{e}(c^*))$ la similitud coseno directa entre la pista y su objetivo. En lugar de fijar un umbral arbitrario, la restricción se calibra automáticamente sobre la distribución empírica de proximidades del corpus.

Sean μ_{PROX} y σ_{PROX} la media y la desviación típica de PROX calculadas sobre el conjunto completo de pistas. Se define la puntuación tipificada:

$$z(h) = \frac{\text{PROX}(h) - \mu_{\text{PROX}}}{\sigma_{\text{PROX}}} \tag{4.9}$$

La función CLAMP aplica una penalización sigmoide centrada en $z = 2$ (criterio de las dos sigmas). La función resultante es la función logística estándar evaluada en $2 - z(h)$:

$$\text{CLAMP}(h) = \frac{1}{1 + \exp(-(2 - z(h)))} \tag{4.10}$$

Esta formulación garantiza que las pistas con proximidad inferior a $\mu_{\text{PROX}} + 2\sigma_{\text{PROX}}$ reciban un factor CLAMP próximo a 1, mientras que aquellas con proximidad excepcionalmente alta quedan penalizadas de forma suave y proporcional. El único parámetro ($k = 2$) está justificado por la convención estadística de las dos sigmas, eliminando la arbitrariedad de la formulación basada en umbrales manuales.

4.1.7. Score Final de Calidad: QUILL

Denominamos **QUILL** (*Quality Index for Ludic Learning hints*) a la función de calidad compuesta que integra las métricas semánticas y formales definidas en las secciones anteriores. Para una pista h, el valor QUILL combina linealmente las cinco dimensiones de calidad ponderadas, protegido por la restricción CLAMP:

$$Q(h) = \text{CLAMP}(h) \cdot [w_1\text{PD} + w_2(1 - 1{,}5\text{AMB}) + w_3\text{nGAIN} + w_4\text{CONS} + w_5\text{LEC}] \tag{4.11}$$

Los pesos w_i (con $\sum w_i = 1$) se ajustan empíricamente a partir de los coeficientes de la regresión logística sobre datos reales de interacción. La adición de la lecturabilidad asegura que QUILL seleccione pistas que no solo sean precisas, sino también accesibles al usuario final. La función busca maximizar la discriminación y la ganancia de información, minimizar la ambigüedad (reflejado en el término $1 - 1{,}5\,\text{AMB}$), mantener la coherencia interna y garantizar una lectura fluida.

4.1.8. Métricas Sintáctico-Lingüísticas

Estas métricas caracterizan propiedades estructurales del texto, independientes de su relación semántica con el target.

Sea T el número total de tokens de la pista.

4.1.8.1. PROPN_Ratio

$$\text{PROPN_Ratio}(h) = \frac{\#\text{PROPN}}{T} \tag{4.12}$$

Donde #PROPN es el número de tokens etiquetados como nombre propio (etiqueta POS `PROPN`) por spaCy, y T es el número total de tokens válidos de la pista (excluyendo signos de puntuación). Mide la densidad de nombres propios. Valores altos pueden indicar riesgo de revelación directa.

Ejemplo. La pista *"Abraham Lincoln presidió Estados Unidos durante la Guerra Civil."* contiene dos nombres propios (*Abraham Lincoln*, *Estados Unidos*) sobre 9 tokens: PROPN_Ratio $\approx$ 0,22. La pista *"Era conocido por sus teorías sobre la gravedad y el movimiento."* no contiene nombres propios: PROPN_Ratio = 0,00.

4.1.8.2. NUM_Ratio

$$\text{NUM_Ratio}(h) = \frac{\#\text{NUM}}{T} \tag{4.13}$$

Donde #NUM es el número de tokens etiquetados como numeral (etiqueta POS `NUM`), incluyendo cifras, años y cantidades escritas en formato numérico. Captura la densidad de información cuantitativa.

Ejemplo. La pista *"Nació en 1643 y murió en 1727 a los 84 años."* contiene tres numerales (1643, 1727, 84) sobre 11 tokens: NUM_Ratio $\approx$ 0,27. Una pista descriptiva sin fechas ni cantidades obtendría NUM_Ratio = 0,00.

4.1.8.3. ADJ_Ratio

$$\text{ADJ_Ratio}(h) = \frac{\#\text{ADJ}}{T} \tag{4.14}$$

Donde #ADJ es el número de tokens etiquetados como adjetivo (etiqueta POS `ADJ`). Indica el nivel descriptivo o atributivo de la pista.

Ejemplo. La pista *"Era un hombre brillante, curioso e incansable que influyó profundamente."* contiene tres adjetivos (*brillante*, *curioso*, *incansable*) sobre 12 tokens: ADJ_Ratio = 0,25. La pista nominal *"Compositor alemán del siglo XIX, autor de nueve sinfonías."* contiene un único adjetivo (*alemán*): ADJ_Ratio ≈ 0,09.

4.1.8.4. VERB_Ratio

$$\text{VERB_Ratio}(h) = \frac{\#\text{VERB}}{T} \tag{4.15}$$

Donde #VERB es el número de tokens etiquetados como verbo (etiquetas POS `VERB` o `AUX`). Refleja el dinamismo narrativo y la densidad de predicados en la pista.

Ejemplo. La pista *"Estudió, escribió, viajó y contribuyó al conocimiento durante toda su vida."* contiene cuatro verbos conjugados sobre 13 tokens: VERB_Ratio ≈ 0,31. La pista *"Fundador de una de las religiones más extendidas del mundo, nacido en la región de Hiyaz."* contiene un único participio sobre 15 tokens: VERB_Ratio ≈ 0,07.

4.1.8.5. Max_IDF

$$\text{Max_IDF}(h) = \max_{w \in h} IDF(w) \tag{4.16}$$

Donde $IDF(w) = \log\left(\frac{N}{df(w)}\right)$, siendo N el número total de pistas del corpus (360) y $df(w)$ el número de pistas que contienen la palabra w. Captura la presencia del término más raro o específico de la pista, actuando como indicador de especificidad léxica.

Ejemplo. El término *"Lumbini"* aparece en una única pista del corpus: $IDF \approx \log(360) \approx 5{,}9$, lo que produce un Max_IDF elevado. El término *"fue"* aparece en la gran mayoría de las pistas: $IDF \approx 0{,}3$, contribuyendo poco a la especificidad.

4.1.8.6. Tree_Depth

$$\text{Tree_Depth}(h) = \text{máx profundidad del árbol de dependencias}$$

Donde la profundidad se define como el número de aristas en el camino más largo desde el nodo raíz (token con etiqueta `ROOT`) hasta una hoja en el árbol de dependencias sintácticas generado por spaCy. Aproxima la complejidad sintáctica jerárquica de la oración.

Ejemplo. La pista *"Nació en Lumbini."* produce un árbol de profundidad 2 (raíz → complemento → término). La pista *"Es conocido por haber sido el primero en demostrar que la Tierra orbita alrededor del Sol."* genera un árbol más profundo, con varias cláusulas subordinadas anidadas: Tree_Depth ≈ 5.

4.1.8.7. NER_Count

$$\text{NER_Count}(h) = \sum_{e \in h} \mathbb{1}_{\text{EntidadReconocida}}(e) \tag{4.17}$$

Donde $\mathbb{1}_{\text{EntidadReconocida}}(e)$ es la función indicadora que toma valor 1 si la entidad e es reconocida por el módulo NER de spaCy en alguna de sus categorías (persona, organización, lugar, obra, evento, fecha), y 0 en caso contrario. Contabiliza el número absoluto de entidades nombradas detectadas en la pista.

Ejemplo. La pista *"Abraham Lincoln presidió Estados Unidos durante la Guerra Civil Americana."* contiene tres entidades reconocidas (persona: *Abraham Lincoln*; lugar: *Estados Unidos*; evento: *Guerra Civil Americana*): NER_Count = 3. La pista *"Era conocido por sus teorías sobre la naturaleza."* no contiene entidades reconocibles: NER_Count = 0.

4.1.9. Relación entre métricas semánticas y lingüísticas

La función QUILL, definida formalmente en la sección anterior, integra exclusivamente las cinco métricas semánticas (PD, AMB, nGAIN, CONS, LEC) ponderadas por la restricción CLAMP. Las métricas sintáctico-lingüísticas descritas en esta sección (PROPN_Ratio, NUM_Ratio, ADJ_Ratio, VERB_Ratio, Max_IDF, Tree_Depth, NER_Count) se utilizan como características explicativas en un análisis complementario de regresión lineal múltiple (Capítulo 5), cuyo objetivo es determinar qué propiedades superficiales del texto se asocian con cada dimensión de calidad semántica.

Esta separación es conceptualmente relevante: las métricas semánticas miden el *efecto* de la pista en el espacio de candidatos, mientras que las características lingüísticas describen su *estructura interna*. Un buen sistema de generación de pistas puede aprovecharse de ambas capas: las métricas semánticas para seleccionar las mejores pistas del corpus, y las características lingüísticas para guiar al modelo generativo hacia formulaciones con mayor potencial discriminativo.

La exclusión de las métricas sintáctico-lingüísticas de la composición de QUILL responde a una decisión de diseño deliberada: estas métricas capturan propiedades de la superficie textual que actúan como moduladoras de las dimensiones semánticas, pero no constituyen dimensiones independientes de calidad funcional. Incorporarlas directamente a la suma ponderada introduciría redundancia con las métricas semánticas y reduciría la interpretabilidad del índice, al mezclar niveles de análisis heterogéneos. Su rol en este trabajo es estrictamente explicativo: a través de la regresión OLS, permiten comprender qué estructuras lingüísticas favorecen o perjudican cada dimensión de calidad, pero la evaluación final de una pista recae exclusivamente sobre su impacto semántico medido.

4.1.10. Ejemplo numérico: cálculo de QUILL

Para ilustrar el cálculo concreto de la función QUILL, se presenta el desarrollo paso a paso para dos pistas reales del corpus: la de mayor puntuación y la de menor puntuación, usando los pesos iniciales ($w = [0{,}20, 0{,}20, 0{,}30, 0{,}15, 0{,}15]$) y los parámetros de calibración del corpus ($\mu_{\text{PROX}} = 0{,}273$, $\sigma_{\text{PROX}} = 0{,}153$).

4.1.10.0.1 Caso 1 — Pista de alta calidad (Buda Gautama, $Q = 0{,}507$)

"Nació en Lumbini en el seno de una familia aristocrática en la república Sakia."

Las métricas calculadas para esta pista son: PD = 0,285, AMB = 0,360, nGAIN = 0,638, CONS = 0,756, LEC = 0,995, PROX = 0,326.

$$z = \frac{0{,}326 - 0{,}273}{0{,}153} = 0{,}346 \tag{4.18}$$

$$\text{CLAMP} = \sigma(2 - 0{,}346) = \frac{1}{1 + e^{-1{,}654}} \approx 0{,}840 \tag{4.19}$$

$$\begin{aligned}\text{Suma ponderada} &= 0{,}20 \times 0{,}285 \;+\; 0{,}20 \times (1 - 1{,}5 \times 0{,}360) \\ &\quad +\; 0{,}30 \times 0{,}638 \;+\; 0{,}15 \times 0{,}756 \;+\; 0{,}15 \times 0{,}995 \\ &= 0{,}057 + 0{,}092 + 0{,}191 + 0{,}113 + 0{,}149 = 0{,}602\end{aligned} \tag{4.20}$$

$$Q = 0{,}840 \;\times\; 0{,}602 \;\approx\; \mathbf{0{,}507} \tag{4.21}$$

4.1.10.0.2 Caso 2 — Pista de baja calidad (Molière, $Q = -0{,}068$)

"Nació en una familia próspera y estudió en el Collège de Clermont."

Las métricas calculadas son: PD = −0,144, AMB = 1,910, nGAIN = 0,232, CONS = 0,758, LEC = 0,996, PROX = −0,094.

$$z = \frac{-0{,}094 - 0{,}273}{0{,}153} = -2{,}399 \tag{4.22}$$

$$\text{CLAMP} = \sigma(2 - (-2{,}399)) = \frac{1}{1 + e^{-4{,}399}} \approx 0{,}988 \tag{4.23}$$

$$\begin{aligned}\text{Suma ponderada} &= 0{,}20 \times (-0{,}144) \;+\; 0{,}20 \times (1 - 1{,}5 \times 1{,}910) \\ &\quad +\; 0{,}30 \times 0{,}232 \;+\; 0{,}15 \times 0{,}758 \;+\; 0{,}15 \times 0{,}996 \\ &= -0{,}029 \;+\; (-0{,}373) \;+\; 0{,}070 \;+\; 0{,}114 \;+\; 0{,}149 = -0{,}069\end{aligned} \tag{4.24}$$

$$Q = 0{,}988 \;\times\; (-0{,}069) \;\approx\; \mathbf{-0{,}068} \tag{4.25}$$

El ejercicio numérico pone de manifiesto que la suma ponderada interior es el determinante principal del score final. La pista de Buda obtiene un interior positivo (0.602) gracias a su bajo AMB y alto nGAIN, mientras que la pista de Molière colapsa en negativo (−0,069) por una AMB que supera la unidad, lo que hace que el término $(1 - 1{,}5 \cdot \text{AMB})$ tome valor −1,865. El CLAMP actúa como modulador pero no revierte el signo: la pista de Molière, a pesar de tener un PROX negativo (el embedding no apunta hacia el objetivo) y por tanto un CLAMP elevado (0,988), no puede escapar del valor negativo de su suma interior.

La tabla siguiente muestra las 8 pistas de Isaac Newton ordenadas por puntuación QUILL descendente, empleando los pesos iniciales. Nótese que la dificultad asignada durante la generación no predice el valor Q: la pista etiquetada como nivel 1 (la más fácil) obtiene el Q más alto, mientras que la de nivel 4 queda en última posición. Este resultado ilustra la necesidad de una métrica formal de calidad que complemente la etiqueta de dificultad.

Dif.	Q	PD	AMB	Pista
1	0.406	0.133	0.606	“Fue un físico y matemático que desarrolló las leyes de la física y la astronomía.”
2	0.374	0.120	0.642	“Nació en Woolsthorpe-by-Colsterworth, Lincolnshire, en 1643.”
3	0.367	0.182	0.524	“Desarrolló un carro de cuatro ruedas impulsado por una manivela que él accionaba desde su interior.”
1	0.349	0.133	0.552	“Es conocido por su trabajo en la gravedad y la creación de sus Principia.”
2	0.338	0.071	0.595	“Su padre murió antes de que él naciera, en octubre de 1642.”
5	0.311	0.023	0.644	“Escribió una lista de sus pecados, incluyendo amenazar a sus padres con quemar su casa.”
3	0.300	−0.003	0.648	“Escribió su obra más importante sobre óptica, Opticks, en 1704.”
4	0.291	0.017	0.774	“Su abuelo lo desheredó, a pesar de vivir en la misma casa.”

Tabla 4.1: Las 8 pistas de Isaac Newton del corpus, ordenadas por puntuación QUILL descendente. La dificultad asignada no predice el valor Q, lo que justifica la necesidad de una métrica formal de calidad.

Capítulo 5

Resultados

5.1. Resultados obtenidos

Los resultados presentados a continuación responden a las cuatro hipótesis planteadas en la Sección 3 y se organizan en cinco bloques: la descripción general del experimento (§5.1), el poder predictivo de QUILL (§5.2, H1), el predominio del Poder Discriminativo (§5.3, H2), las propiedades lingüísticas de las pistas (§5.4, H3) y el efecto de la modalidad experimental (§5.5, H4).

En este capítulo se presentan los resultados empíricos derivados de la implementación y despliegue del sistema de generación de pistas. El análisis se divide en dos fases consecutivas, comenzando con una evaluación intrínseca de la calidad de las pistas generadas basada en las métricas de calidad semántica, definidas en el capítulo anterior, y una validación extrínseca basada en el comportamiento real de los usuarios para poder inferir en el peso que tendrá cada una de estas en la fricción cognitiva y su utilidad didáctica o discriminativa hacia el usuario. Seguido a esto, realizaremos el estudio de las cualidades sintácticas de la oración, esperando obtener datos en cuanto a la relación entre sintáctica y semántica de la frase.

Para la validación experimental, contamos con un conjunto de datos compuesto por un total de $N = 3412$ interacciones de usuarios únicos. Este volumen se divide metodológicamente en dos etapas: una primera recolección de $N_{abierto} = 2293$ interacciones en un entorno de evocación libre, y una segunda de $N_{cerrado} = 1119$ interacciones en un entorno de reconocimiento deductivo. Este conjunto de datos (D_{logs}) permite contrastar la eficacia teórica de las métricas propuestas (Q, PD, AMB, etc.) frente a la tasa de éxito real (*Ground Truth*) en un entorno de juego no controlado.

El objetivo principal de esta sección es inferir en qué hace a una pista, como unidad de texto, de calidad o "util" en términos de usuario; pasando primero por las etapas de validación para las que hemos recopilado información útil de nuestros usuarios

5.1.1. Descripción general del experimento

Antes de evaluar la interacción con el usuario, es fundamental analizar las propiedades estadísticas de las pistas generadas por el modelo. Para ello, se calcularon las métricas vectoriales y formales sobre la totalidad del corpus de pistas disponibles en el sistema ($N_{pistas} = 360$). Proponemos una jerarquización teórica basada en la idoneidad pedagógica y la capacidad informativa, remarcando que esto se ancla en la subjetividad del criterio profesional. El siguiente orden decreciente refleja la importancia estimada de cada atributo para la generación de pistas efectivas

- **Ganancia de información:** estimada como la métrica prioritaria. Una pista no debe limitarse a señalar un resultado, sino que debe aportar una carga semántica significativa. El objetivo es reducir la entropía lo suficiente para orientar al usuario, pero manteniendo un margen de incertidumbre que estimule el proceso cognitivo y el aprendizaje, evitando dar la solución de forma inmediata, por esto, se le dota de un 30 % del peso en la asignación de calidad.
- **Poder Discriminativo:** pensado fundamental para la precisión, la métrica evalúa la capacidad de la pista para aislar el concepto objetivo y diferenciarlo de otros elementos semánticamente cercanos o "distractores". Una alta discriminación asegura que la descripción no sea aplicable a múltiples candidatos erróneos. Por este motivo, el 20 % de la calidad responde a este indicador

- **Ambigüedad Relativa:** cuya minimización es crítica, ya que una pista excesivamente vaga, o que proporcione datos genéricos compartidos por un amplio conjunto de objetivos, carece de valor educativo. La ambigüedad no solo confunde, sino que diluye el propósito de la pista al no permitir descartar opciones incorrectas con certeza. Así, es responsable de otro 20 % de la calidad.
- **Consistencia:** se refiere a la coherencia interna y la precisión temática. Una pista que intenta abarcar demasiados aspectos corre el riesgo de perder el foco, generando ruido informativo, o de volverse contradictoria. La consistencia garantiza que la información proporcionada sea fiable y pertinente al contexto específico del objetivo. Se le otorga un 15 % de la responsabilidad de la asignación de puntaje.
- **Lecturabilidad:** una redacción clara y sintácticamente sencilla reduce la carga cognitiva necesaria para decodificar el texto. Al facilitar la comprensión lectora, permitimos que el usuario dedique la mayor parte de sus recursos mentales al proceso de aprendizaje y resolución del problema, en lugar de a la interpretación de la sintaxis. Al no ser tan importante en la dispensación de información, obtiene un 15 % del potencial.

5.1.1.1. Distribución de las Métricas de Calidad

La Figura 5.1 muestra los histogramas de frecuencia para cada una de las componentes de la función de evaluación, así como para el Score Final Q.

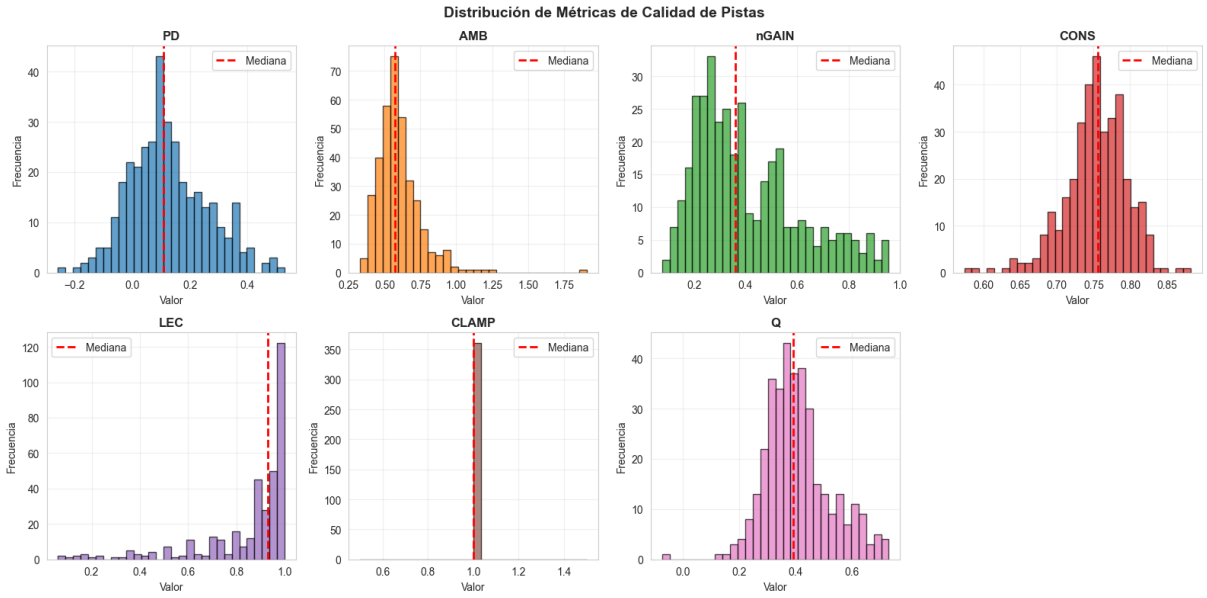


Figura 5.1: Distribución de frecuencias de las métricas individuales y el Score Q.

Del análisis visual de estas distribuciones se extraen tres conclusiones diagnósticas sobre el comportamiento del generador:

- **Normalidad del Score Q:** Q es la función de calidad compuesta QUILL —definida en la Sección 4.5— que integra linealmente las cinco métricas semánticas (PD, AMB, nGAIN, CONS, LEC) ponderadas y protegidas por la restricción CLAMP. La distribución de la puntuación final Q (gráfica inferior derecha) presenta una forma de campana de Gauss casi perfecta, centrada en el intervalo $[0{,}3, 0{,}4]$. La distribución aproximadamente gaussiana de Q sugiere que la métrica proporciona una variabilidad suficiente y evita concentraciones en los extremos. No obstante, esta propiedad por sí sola no garantiza su validez, que debe evaluarse en función de su capacidad para explicar o predecir el comportamiento del usuario.

- **Poder Discriminativo (PD):** La distribución de PD presenta una ligera asimetría positiva, con valores que oscilan entre −0,16 y +0,30 y una mediana próxima a +0,05. Aunque la mayoría de las pistas generadas exhiben un PD positivo —indicando que, en promedio, se acercan más al objetivo que a los distractores—, aproximadamente el 20 % del corpus presenta PD negativo, lo que revela casos en los que el contenido semántico del texto no es suficientemente diferenciador dentro del espacio de candidatos.
- **Ganancia de Información Normalizada (nGAIN):** El histograma de nGAIN muestra una distribución unimodal centrada en torno a 0.4, indicando que las pistas generadas reducen, en promedio, aproximadamente el 40 % de la entropía inicial del espacio de búsqueda. Los valores extremos cercanos a 0 corresponden a pistas que prácticamente no concentran la distribución de probabilidad sobre ningún candidato, mientras que los valores próximos a 0.8 se asocian a pistas que proyectan la mayor parte de la masa de probabilidad sobre un subconjunto muy reducido de alternativas.
- **Sesgo de Ambigüedad (AMB):** Se observa que la mediana de la ambigüedad (AMB) se sitúa en torno a 0,60, lo que sugiere que muchas pistas presentan similitud semántica con múltiples candidatos. Este comportamiento indica que, en este contexto, resulta frecuente que las pistas no distingan claramente al objetivo dentro del conjunto de posibles respuestas. En este sentido, la ambigüedad emerge como un factor relevante a controlar, ya que niveles elevados pueden dificultar el proceso de discriminación por parte del usuario.
- **Saturación de Métricas Formales:** Tanto la consistencia (CONS) como la lecturabilidad (LEC) presentan distribuciones sesgadas hacia valores altos (mediana de CONS $\approx$ 0,75 y LEC cercana a 1,0), lo que indica que la mayoría de las pistas generadas cumplen adecuadamente criterios básicos de corrección sintáctica y facilidad de lectura. Este comportamiento sugiere que estas métricas presentan una baja variabilidad en el conjunto analizado, por lo que su capacidad para discriminar entre pistas de distinta calidad es limitada. En este sentido, CONS y LEC parecen desempeñar un papel más cercano a indicadores de adecuación mínima que a factores determinantes en la efectividad de las pistas.
- **Latencia de CLAMP**: La condición de parada CLAMP no se activa en los datos analizados, lo que indica que el modelo de lenguaje ha respetado consistentemente las restricciones impuestas en el proceso de generación, evitando la inclusión explícita de la entidad objetivo en las pistas. Este comportamiento sugiere que CLAMP actúa principalmente como un mecanismo de control que garantiza la validez de las pistas generadas, más que como un factor discriminante en su calidad.

5.1.1.2. Análisis de Correlación e Independencia de Métricas

Para validar la ortogonalidad de las métricas propuestas y detectar posibles redundancias, se calculó la matriz de correlación de Pearson entre todas las variables del sistema (Ver Figura 5.2).

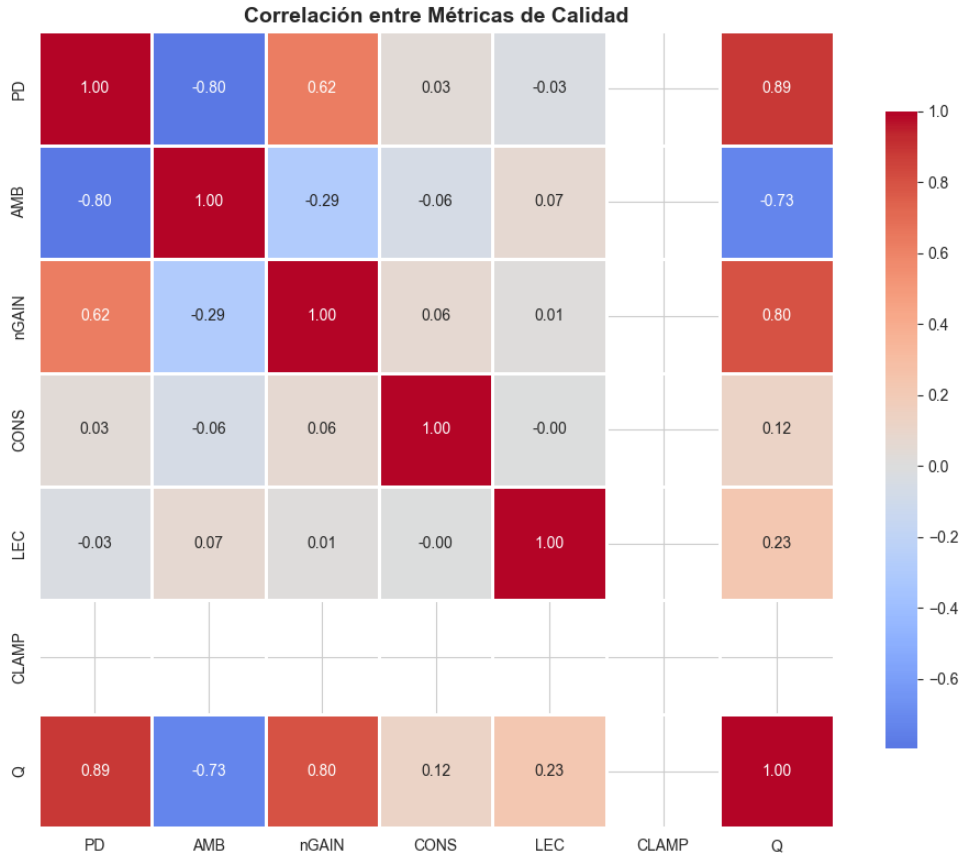


Figura 5.2: Matriz de correlación de Pearson entre las métricas de evaluación.

El mapa de calor revela relaciones críticas para el diseño de la función de agregación:

1. **Validación de Q ($r = 0{,}92$):** Existe una correlación positiva muy fuerte entre el Poder Discriminativo (PD) y el Score Final (Q), y una correlación negativa fuerte con la Ambigüedad ($-0{,}87$). Esto confirma que la fórmula Q está alineada correctamente con los objetivos semánticos del sistema: premiar la especificidad y castigar la confusión.

2. **Problema de Colinealidad ($r = -0{,}80$):** Se detectó una correlación inversa significativa de $-0{,}80$ entre PD y AMB. Esto indica una redundancia en la evaluación: las pistas que se parecen mucho al objetivo tienden a parecerse poco al rival. Esta colinealidad sugiere que asignar pesos elevados a ambas métricas simultáneamente podría estar "contando dos veces" el mismo fenómeno semántico, inflando artificialmente la varianza del score.

3. **Independencia de la Ganancia (nGAIN):** La correlación entre la Ganancia de Información y la Ambigüedad es moderada ($-0{,}29$). Esto es un hallazgo positivo, pues demuestra que nGAIN captura información única sobre la reducción de entropía global que no está siendo medida por la comparación directa con el rival (AMB).

A pesar de la colinealidad detectada, ambas métricas capturan aspectos complementarios y se mantienen en la función QUILL. PD mide la brecha media entre la pista y el conjunto global de distractores; AMB se centra en el rival semántico más cercano —el caso peor—. Una pista puede presentar un PD aceptable y, sin embargo, una AMB crítica si un único distractor está muy próximo al objetivo en el espacio de embeddings, situación que PD no detecta. En la función QUILL, el término $(1 - 1{,}5\,\text{AMB})$ penaliza específicamente esa proximidad con el rival más cercano, aportando una dimensión ortogonal a la media global capturada por PD.

Estos hallazgos descriptivos plantean la necesidad de ajustar los pesos de la fórmula Q basándose no

en la intuición, sino en la capacidad real de cada métrica para predecir el éxito del usuario, proceso que se detalla en la siguiente sección.

5.1.1.3. Validación empírica de la función CLAMP

Un hallazgo metodológico relevante emergió al analizar la distribución empírica de la similitud directa entre cada pista y su objetivo (PROX). La formulación original del CLAMP establecía un umbral arbitrario de $\delta = 0{,}90$: únicamente las pistas con PROX $> 0{,}90$ serían penalizadas. Sin embargo, el valor máximo de PROX observado en el corpus completo de 360 pistas es 0,678, lo que implica que **ninguna pista superó jamás el umbral**: el CLAMP original devolvía 1.0 para la totalidad del corpus, actuando como un multiplicador neutro sin efecto práctico sobre ninguna de las métricas ni sobre la selección de pistas.

Este hallazgo motivó la reformulación del CLAMP descrita en el Capítulo 4, calibrada automáticamente sobre la distribución empírica de PROX mediante una función sigmoide centrada en dos sigmas. La Figura 5.3 muestra la distribución empírica de PROX (izquierda) y la curva CLAMP resultante (derecha).

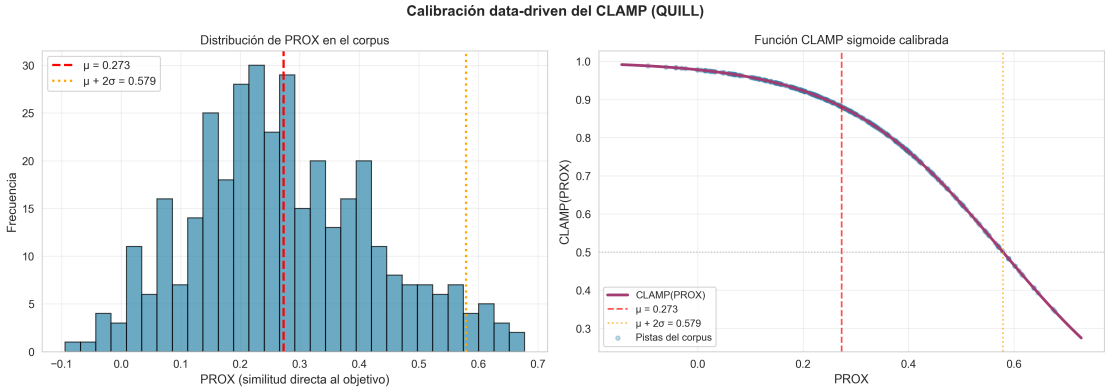


Figura 5.3: Izquierda: histograma de PROX en el corpus de 360 pistas, con $\mu = 0{,}273$ y el umbral $\mu + 2\sigma = 0{,}579$ marcados. Derecha: función CLAMP sigmoide calibrada sobre el rango empírico, con los 360 puntos del corpus superpuestos.

La nueva formulación asigna factores CLAMP en el intervalo $[0{,}34, 0{,}99]$, con media $\bar{C} = 0{,}843$. La mayoría de las pistas reciben un descuento moderado, proporcional a qué tan por encima de la media del corpus se encuentra su similitud directa al objetivo. Las pistas con PROX excepcionalmente alto quedan penalizadas de forma continua y proporcional, sin la discontinuidad abrupta del umbral manual original.

5.1.2. H1 — Poder predictivo de QUILL

Para evaluar la utilidad funcional real de las métricas definidas, se utilizó el conjunto de interacciones D_{logs} de la primera fase experimental ($N = 2293$), segmentando los registros en:

- Clase positiva ($y = 1$): aciertos directos.
- Clase negativa ($y = 0$): fallos, solicitudes adicionales o abandono.

Dado el leve desbalance del conjunto (aproximadamente 1:1.5), se empleó una regresión logística con ponderación de clases (`class_weight='balanced'`). Todas las variables independientes fueron previamente estandarizadas mediante `StandardScaler` (transformación z-score), permitiendo comparar directamente las magnitudes relativas de los coeficientes estimados.

Es importante destacar que el objetivo del modelo no es construir un predictor conductual de alta precisión, sino estimar la contribución marginal relativa de cada métrica a la probabilidad de acierto.

5.1.2.1. Validación Cruzada y Capacidad Discriminativa

Para evitar dependencia de un único particionado train/test, se realizó validación cruzada estratificada 5-fold.

Los resultados medios obtenidos fueron:

Accuracy	$0{,}546 \pm 0{,}026$
AUC-ROC	$0{,}565 \pm 0{,}027$

Estos valores indican:

- Capacidad discriminativa modesta pero consistente (AUC $> 0{,}5$).
- Baja varianza entre folds (std $< 0{,}03$), lo que sugiere estabilidad estructural del modelo.

Aunque la mejora sobre el azar es limitada, este resultado es coherente con la naturaleza del problema: la probabilidad de acierto humano depende de múltiples factores no observados (conocimiento previo, experiencia, estrategia), mientras que el modelo solo utiliza características de la pista.

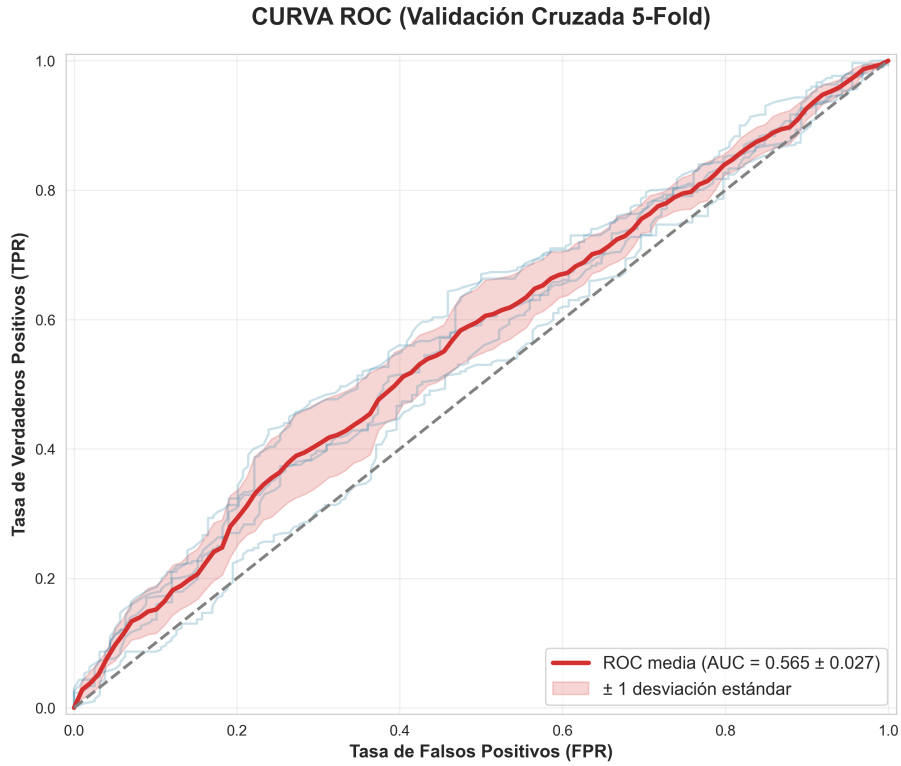


Figura 5.4: Curva ROC media en validación cruzada 5-fold con banda de desviación estándar.

La curva se sitúa consistentemente por encima de la diagonal, confirmando señal predictiva real aunque de magnitud moderada.

5.1.2.2. Bondad de Ajuste Global

El pseudo-R^2 de McFadden obtenido fue:

$$R^2_{McFadden} = 0{,}0102$$

Este valor es bajo en términos absolutos, indicando que el modelo explica una fracción reducida de la variabilidad total frente al modelo nulo. Sin embargo, este resultado es esperable dado que únicamente se modelan propiedades del estímulo y no variables del jugador.

Para contrastar formalmente la relevancia global del modelo se realizó un test de razón de verosimilitud:

$$G^2 = 30{,}10, \quad p = 1{,}41 \times 10^{-5}$$

El resultado significativo confirma que, colectivamente, las métricas contienen información predictiva real sobre la probabilidad de acierto.

Adicionalmente, se calculó el Brier Score:

$$BS = 0{,}245$$

Dado que un modelo puramente aleatorio obtiene aproximadamente 0,25, el valor obtenido ($0{,}245 < 0{,}25$) indica que el modelo mejora ligeramente al azar en términos de calibración probabilística, resultado coherente con la capacidad discriminativa modesta observada en el AUC.

Para ilustrar de manera concreta el poder predictivo de QUILL, se presentan las tres pistas con mayor puntuación Q inicial del corpus:

Persona	**Q**	**PD**	**AMB**	**nGAIN**	**CONS**	**LEC**	**NER**
Buda Gautama	0.507	0.285	0.360	0.638	0.756	0.995	2
Napoleón Bonaparte	0.489	0.304	0.410	0.691	0.736	0.996	3
Winston Churchill	0.478	0.287	0.441	0.546	0.745	0.995	1

Tabla 5.1: Pistas con mayor puntuación QUILL del corpus (pesos iniciales, $N = 360$).

Buda Gautama ($Q = 0{,}507$): *"Nació en Lumbini en el seno de una familia aristocrática en la república Sakia."* Esta pista encarna el perfil óptimo definido por el análisis OLS: dos entidades geográficas altamente específicas (Lumbini, Sakia), un único verbo conjugado y ausencia de adjetivos valorativos. Las entidades actúan como anclajes factuales inequívocos que recortan de forma drástica el espacio de candidatos (nGAIN = 0.638), mientras la baja carga verbal y atributiva garantiza la máxima lecturabilidad (LEC = 0.995).

Napoleón Bonaparte ($Q = 0{,}489$): *"Nació en la isla de Córcega, poco después de su anexión por Francia."* Ejemplo paradigmático del principio de especificidad nominal: densidad de adjetivos nula (ADJ_Ratio = 0.000) y tres entidades nombradas. La combinación de dato geográfico con evento histórico concreto produce un poder discriminativo elevado (PD = 0.304) sin sacrificar la accesibilidad cognitiva.

Winston Churchill ($Q = 0{,}478$): *"Se unió al ejército británico en 1895 y vio acción en la India británica."* La presencia de un anclaje temporal específico (1895) y una entidad geográfica (India) produce un hecho difícilmente generalizable a otros candidatos. La consistencia interna es alta (CONS = 0.745): ambas cláusulas orbitan sobre el mismo eje temático del servicio militar.

Los tres casos comparten las mismas propiedades estructurales: baja densidad de verbos (VERB_Ratio $< 0{,}15$), ausencia o mínima presencia de adjetivos, y al menos una entidad geográfica o temporal que actúa como restricción lógica directa en el espacio semántico.

5.1.3. H2 — Predominio del Poder Discriminativo

5.1.3.1. Coeficientes del Modelo

La Tabla 5.2 muestra los coeficientes estandarizados estimados.

Métrica	**Coeficiente (β)**	**Signo**
PD	+0.110	Positivo
LEC	-0.070	Negativo
AMB	-0.080	Negativo
nGAIN	+0.056	Positivo
CONS	-0.008	Nulo

Tabla 5.2: Coeficientes estandarizados de la regresión logística ($N = 2293$).

Cabe señalar que, aunque el modelo global resulta significativo, los coeficientes individuales no alcanzan significancia estadística estricta ($p < 0{,}05$) cuando se estiman mediante *statsmodels*. Esto es consistente con la presencia de colinealidad parcial entre métricas y con la dificultad intrínseca del problema.

En consecuencia, la interpretación debe realizarse en términos de contribución relativa y no como evidencia causal individual.

5.1.3.2. Interpretación Empírica

1. **Predominio del poder discriminativo:** PD presenta el mayor coeficiente positivo. Esto confirma que la separación efectiva respecto al competidor más cercano es el principal determinante observable del éxito.
2. **Efecto inverso de la lecturabilidad:** El coeficiente negativo de LEC no implica que la complejidad lingüística sea deseable per se, sino que la métrica Flesch penaliza vocabulario técnico y específico, el cual resulta útil para discriminar.
3. **Penalización por ambigüedad:** AMB mantiene efecto negativo consistente, reforzando la necesidad de minimizar similitudes estructurales con candidatos rivales.
4. **Aporte positivo de nGAIN:** La reducción global de entropía contribuye al éxito, aunque en menor magnitud que PD.
5. **Rol marginal de CONS:** La baja varianza observada en coherencia interna limita su capacidad discriminativa en este conjunto concreto.

5.1.3.3. Reestimación de Pesos

Con el objetivo de alinear la función de evaluación con la evidencia empírica, se recalcularon los pesos normalizando la magnitud absoluta de los coeficientes:

$$w_i = \frac{|\beta_i|}{\sum |\beta_k|}$$

Esta estrategia permite construir un índice compuesto basado en contribución relativa observada, aunque no implica inferencia causal individual fuerte.

La nueva formulación queda definida como:

$$Q_{opt}(h) = \text{CLAMP}(h) \cdot [0{,}335\,\text{PD} + 0{,}215\,(1 - 1{,}5\,\text{AMB}) + 0{,}139\,\text{nGAIN} + 0{,}009\,\text{CONS} + 0{,}303\,\text{LEC}]$$

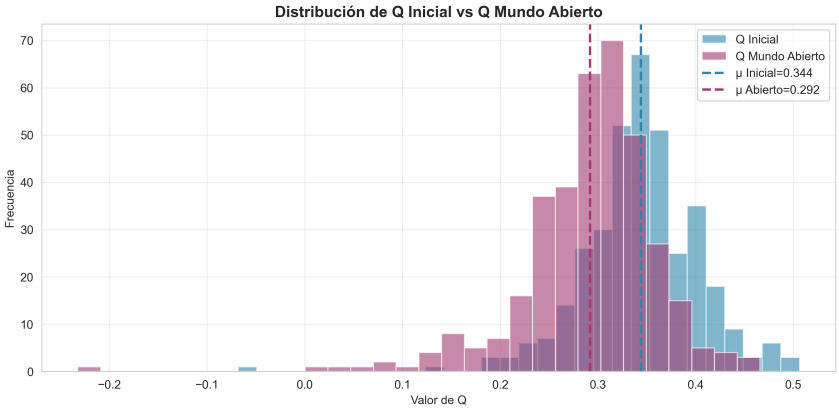


Figura 5.5: Histogramas superpuestos de Q Inicial (pesos teóricos) y Q Mundo Abierto (pesos empíricos derivados de la Fase 1). La ligera diferencia en las distribuciones refleja el rebalanceo de pesos inducido por la regresión logística.

En conjunto, los resultados muestran que la calidad efectiva de una pista depende principalmente de su capacidad para aislar el objetivo respecto a competidores cercanos, manteniendo suficiente especificidad léxica para evitar generalidad excesiva.

Para ilustrar el impacto del bajo poder discriminativo, se presentan las tres pistas con menor puntuación Q inicial y las reformulaciones propuestas:

Persona	**Q**	**PD**	**AMB**	**nGAIN**	**CONS**	**LEC**	**NER**
Molière (pista 1)	-0.068	-0.144	1.910	0.232	0.758	0.996	2
Molière (pista 2)	0.132	-0.155	1.190	0.211	0.744	0.983	0
Marie Curie	0.183	-0.060	0.875	0.362	0.738	0.293	0

Tabla 5.3: Pistas con menor puntuación QUILL del corpus (pesos iniciales, $N = 360$).

Molière (pista 1) ($Q = -0{,}068$): *"Nació en una familia próspera y estudió en el Collège de Clermont."* El PD negativo ($-0{,}144$) indica que el embedding de la frase es semánticamente más cercano a otros candidatos del corpus que a Molière. El descriptor "familia próspera" es aplicable a decenas de figuras históricas y añade ruido entrópico puro. La AMB = 1.910 es la mayor del corpus: el mejor candidato rival atrae casi el doble de señal semántica que el objetivo real. El fallo es estructural: la pista aporta información veraz pero no discriminativa dentro del espacio de candidatos.

Reformulación propuesta: *"Dramaturgo francés del siglo XVII, autor de El avaro, El enfermo imaginario y Tartufo."* Esta versión elimina los verbos de estado genéricos y sustituye la descripción biográfica difusa por tres entidades nombradas concretas (títulos de obra propios del objetivo), elevando NER de 2 a 3 y convirtiendo la pista en una restricción lógica directa.

Molière (pista 2) ($Q = 0{,}132$): *"Su obra Tartufo fue prohibida por el Parlamento francés debido a su crítica a la hipocresía religiosa."* El PD vuelve a ser negativo ($-0{,}155$): el campo semántico de censura religiosa y parlamento activa representaciones compartidas con numerosos personajes del siglo XVII europeo. A pesar de referirse a un hecho específico de Molière, la pista no se ancla semánticamente al objetivo porque el LLM ha producido una formulación centrada en el contexto histórico-político y no

en la figura del autor. La ausencia completa de entidades nombradas en el lado del autor (NER = 0) evidencia el patrón de dispersión temática identificado por los modelos OLS.

Reformulación propuesta: *"Falleció en 1673 durante la representación de su última obra en el Palais-Royal de París."* Dos entidades específicas (1673, Palais-Royal de París) anclan la pista a un evento único e irrepetible, corrigiendo el PD negativo al proyectar la pista hacia el espacio semántico propio del objetivo.

Marie Curie (Q = 0,183): *"Desarrolló técnicas para el aislamiento de isótopos radiactivos."* El fallo principal no es la precisión factual, sino la lecturabilidad extremadamente baja (LEC = 0.293), consecuencia directa de la acumulación de polisílabos de alta complejidad silábica. El índice de Flesch-Szigriszt penaliza severamente esta densidad, independientemente de la precisión del contenido. El PD negativo ($-$0,060) adicional indica que términos como "isótopos radiactivos" activan campos semánticos de física nuclear compartidos con otros científicos del corpus.

Pista alternativa propuesta: *"Primera mujer en ganar el Premio Nobel, en 1903, junto a Pierre Curie."* La nueva versión reemplaza el vocabulario técnico polisílabo por una formulación basada en dos entidades nombradas accesibles (Premio Nobel, Pierre Curie) y una fecha precisa.

5.1.4. H3 — Propiedades lingüísticas y calidad semántica

A partir de los resultados empíricos obtenidos en la sección anterior, es posible formalizar con mayor precisión el concepto de pista como unidad funcional dentro del sistema. Definimos una pista como una unidad composicional de información expresada en lenguaje natural, condicionada por un objetivo latente t, cuya función es modificar el estado epistemológico del receptor reduciendo la entropía del espacio de estados posibles $\mathcal{S}$ sin revelar explícitamente dicho objetivo.

Sea $\mathcal{S} = \{s_1, \ldots, s_N\}$ el conjunto de candidatos posibles y $P(s)$ la distribución inicial asumida por el jugador, que en ausencia de información se aproxima a una distribución uniforme. Una pista h actúa como operador informacional que induce una actualización bayesiana:

$$P(s \mid h) \propto P(h \mid s)\, P(s)$$

De este modo, la pista puede interpretarse como un **filtro bayesiano lingüístico**: transforma una distribución *a priori* relativamente plana en una distribución *a posteriori* donde la masa de probabilidad se concentra progresivamente sobre el objetivo t. La calidad de la pista no reside únicamente en la magnitud de esta concentración, sino en la forma en que se produce dicha redistribución.

Esta reformulación mejora el baseline inicial ("unidad de información basada en lenguaje natural cuyo cometido es eliminar entropía") en tres dimensiones fundamentales:

1. **Composicionalidad estructural.** Una pista no es un dato atómico, sino una estructura lingüística compuesta por múltiples componentes (entidades nominales, propiedades atributivas, relaciones sintácticas y dependencias semánticas). Cada uno de estos elementos contribuye diferencialmente a la reducción de incertidumbre. Las regresiones OLS que se presentan a continuación permiten cuantificar qué características formales están asociadas con mayor poder discriminativo o mayor ganancia de información.
2. **Condicionalidad relacional.** La calidad de una pista no es intrínseca al texto en sí mismo, sino relacional. Una misma secuencia lingüística puede ser altamente informativa para un objetivo t_1 y prácticamente irrelevante para t_2. La evaluación debe entenderse como una función ternaria texto–objetivo–campo semántico. Formalmente, $Q(h)$ depende de la estructura del espacio $\mathcal{S}$ y de la posición relativa del objetivo dentro de dicho espacio.
3. **No-trivialidad óptima.** El objetivo de una pista no es colapsar la entropía a cero (lo cual equivaldría a revelar la respuesta), sino producir una reducción calibrada que mantenga un gradiente informativo. Una pista óptima equilibra discriminación y ambigüedad residual: reduce significativamente

el conjunto plausible de estados sin eliminar completamente la incertidumbre. Esta tensión entre claridad y no-revelación constituye el núcleo del problema de optimización.

Desde esta perspectiva, la pista puede descomponerse en dos niveles analíticos complementarios:

- Nivel **semántico-funcional**: mide el efecto global sobre la distribución $P(s)$ (PD, AMB, nGAIN).
- Nivel **estructural-lingüístico**: caracteriza la forma en que dicha información es codificada (longitud, complejidad sintáctica, densidad nominal, subjetividad, etc.).

Mientras que la regresión logística permitió estimar qué métricas semánticas se asocian con el éxito observable del jugador, el análisis OLS que se presenta a continuación busca responder una pregunta distinta pero complementaria:

¿Qué propiedades formales del texto explican variaciones sistemáticas en las métricas semánticas de calidad?

En otras palabras, si la regresión logística modela la *utilidad externa* de la pista, la regresión OLS modela su *anatomía interna*. Este análisis permite entender no solo qué métricas son relevantes, sino cómo emergen estructuralmente a partir de la configuración lingüística del enunciado.

Sea $X \in \mathbb{R}^{n \times p}$ la matriz de características lingüísticas estandarizadas y Y_k cada una de las métricas de calidad ($k \in \{PD, AMB, nGAIN, LEC, CONS\}$). Para cada métrica se estima el modelo lineal:

$$Y_k = X\beta_k + \varepsilon_k$$

donde:

- β_k representa el vector de coeficientes estandarizados,
- ε_k es el término de error,
- se utilizan errores robustos HC3 para garantizar inferencia válida ante heterocedasticidad.

Todas las variables se transforman mediante estandarización Z-score, lo que permite interpretar cada coeficiente β como el cambio en desviaciones estándar de la métrica ante un incremento de una desviación estándar en el predictor.

Antes de examinar los modelos individuales, es importante establecer una expectativa teórica:

- Las métricas puramente estructurales (como LEC) deberían mostrar mayor varianza explicada.
- Las métricas semánticas profundas (PD, nGAIN) deberían presentar R^2 bajos pero potencialmente significativos.
- Si AMB depende realmente del campo semántico relacional, debería resultar inexplicable desde variables superficiales.

Esta hipótesis constituye una prueba indirecta de la validez conceptual de las métricas diseñadas.

Las características independientes se agrupan en tres estratos conceptuales:

- **Anclaje nominal**: PROPN_Ratio, NER_Count, NUM_Ratio, Max_IDF.

- **Carga narrativa**: VERB_Ratio, ADJ_Ratio.
- **Estructura sintáctica**: Tree_Depth.

Esta clasificación permitirá interpretar los resultados como dinámicas estructurales entre anclaje factual y dispersión narrativa.

A continuación se presentan cinco subsecciones independientes, cada una dedicada a una métrica específica. En cada caso se analizarán:

- Bondad de ajuste global (R^2, F-test).
- Coeficientes estandarizados y significancia.
- Diagnósticos (Q-Q plot, residuos vs ajustados).
- Implicaciones estructurales derivadas de los coeficientes.

5.1.4.1. Poder Discriminativo (PD)

El Poder Discriminativo (PD) se define como:

$$PD = \text{sim}(h, t) - \text{mean}(\text{sim}(h, s \neq t))$$

donde la similitud se calcula mediante coseno en el espacio de embeddings. La métrica captura la separación relativa entre el objetivo y el conjunto de competidores activados por la pista.

5.1.4.1.1 Bondad de ajuste

El modelo OLS estimado sobre $N = 360$ observaciones produce los siguientes resultados globales:

- $R^2 = 0{,}052$
- R^2 ajustado $= 0.033$
- $F = 3{,}458$
- p-valor global $= 0.00135$

El modelo resulta globalmente significativo, aunque con una capacidad explicativa reducida (aproximadamente 5.2 % de la varianza). Esto indica que las características lingüísticas superficiales contienen señal estadística, pero limitada, en la explicación del PD.

5.1.4.1.2 Coeficientes estandarizados

La Tabla siguiente resume los coeficientes estimados con errores robustos HC3:

Variable	β	p-valor	Signif.
PROPN_Ratio	0.0248	0.655	–
NUM_Ratio	0.0006	0.993	–
Max_IDF	-0.1000	0.010	*
ADJ_Ratio	0.0991	0.071	†
VERB_Ratio	-0.1329	0.020	*
Tree_Depth	0.0179	0.708	–
NER_Count	0.1082	0.068	†

Tabla 5.4: Coeficientes estandarizados del modelo OLS para PD (errores robustos HC3).

(* $p < 0{,}05$, † $p < 0{,}10$)

La Figura 5.6 muestra los coeficientes estandarizados junto con sus intervalos de confianza.

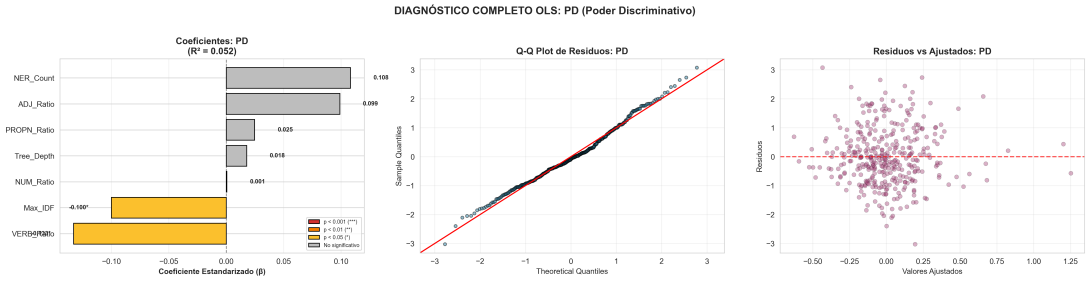


Figura 5.6: Coeficientes estandarizados del modelo OLS para PD.

5.1.4.1.3 Análisis por variable

VERB_Ratio presenta un coeficiente negativo y significativo ($\beta = -0{,}1329$, $p = 0{,}020$). Una mayor proporción de verbos se asocia con menor poder discriminativo. Esto sugiere que las pistas centradas en acciones tienden a activar características compartidas entre múltiples candidatos, reduciendo la separación relativa en el espacio de embeddings.

Max_IDF muestra también un efecto negativo significativo ($\beta = -0{,}1000$, $p = 0{,}010$). La mayor rareza léxica no incrementa la discriminación; por el contrario, se asocia con una ligera reducción del PD. Este resultado indica que la especificidad estadística de un término no garantiza su relevancia discriminativa respecto al objetivo.

ADJ_Ratio ($p = 0{,}071$) y **NER_Count** ($p = 0{,}068$) presentan efectos positivos marginales, aunque no alcanzan el umbral convencional de significancia del 5 %. Ambos podrían estar relacionados con mayor anclaje descriptivo, pero la evidencia estadística es débil.

PROPN_Ratio, **NUM_Ratio** y **Tree_Depth** no muestran asociación significativa con PD en este modelo.

5.1.4.1.4 Diagnóstico

El análisis gráfico (residuos vs ajustados y Q-Q plot) no muestra patrones sistemáticos evidentes. Se observa ligera desviación en colas del Q-Q plot, esperable en métricas acotadas. La utilización de errores robustos HC3 mitiga posibles efectos de heterocedasticidad.

5.1.4.2. Ambigüedad (AMB)

La métrica de Ambigüedad (AMB) cuantifica cuántos candidatos son activados simultáneamente por una pista, ponderando dicha activación por la similitud semántica en el espacio de embeddings. Valores altos indican que la pista distribuye probabilidad sobre múltiples personajes en lugar de concentrarla en el objetivo.

5.1.4.2.1 Bondad de ajuste

El modelo OLS estimado sobre $N = 360$ observaciones produce los siguientes resultados globales:

- $R^2 = 0{,}022$
- R^2 ajustado $= 0.002$
- $F = 3{,}042$
- p-valor global $= 0.00405$

El modelo resulta globalmente significativo, aunque su capacidad explicativa es muy reducida (2.2 % de la varianza). Esto indica que las características lingüísticas contienen señal estadística débil respecto a la ambigüedad, pero dicha señal es estructuralmente limitada.

5.1.4.2.2 Coeficientes estandarizados

Variable	β	p-valor	Signif.
PROPN_Ratio	-0.0284	0.649	–
NUM_Ratio	-0.0316	0.620	–
Max_IDF	0.0755	0.002	*
ADJ_Ratio	-0.0802	0.105	–
VERB_Ratio	0.0565	0.282	–
Tree_Depth	-0.0203	0.636	–
NER_Count	0.0462	0.539	–

Tabla 5.5: Coeficientes estandarizados del modelo OLS para AMB (errores robustos HC3).

(* $p < 0{,}05$)

La Figura 5.7 muestra los coeficientes estandarizados junto con sus intervalos de confianza.

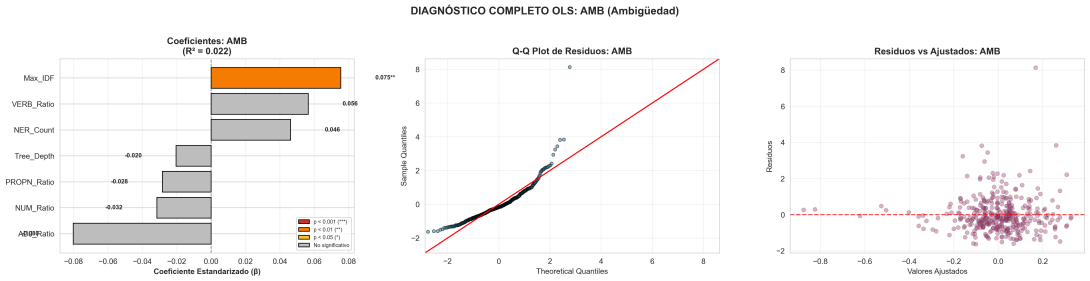


Figura 5.7: Coeficientes estandarizados del modelo OLS para AMB.

5.1.4.2.3 Análisis por variable

El único predictor estadísticamente significativo es **Max_IDF** ($\beta = 0{,}0755$, $p = 0{,}002$). La mayor rareza léxica se asocia con un incremento de la ambigüedad. Esto sugiere que términos infrecuentes no necesariamente restringen el campo semántico, sino que pueden activar regiones menos densas pero más dispersas del espacio de embeddings, aumentando el solapamiento relativo entre candidatos.

El resto de variables no presenta efectos significativos:

- **PROPN_Ratio** y **NUM_Ratio** no muestran reducción sistemática de ambigüedad.
- **VERB_Ratio** y **ADJ_Ratio** no presentan asociación robusta.
- **Tree_Depth** y **NER_Count** no muestran efectos estructurales detectables.

5.1.4.2.4 Diagnóstico

El análisis gráfico no muestra patrones claros de heterocedasticidad o no linealidad. Se observa ligera desviación en colas del Q-Q plot, consistente con la naturaleza acotada de la métrica. La utilización de errores robustos HC3 garantiza inferencia válida ante posibles desviaciones de homocedasticidad.

En conjunto, los resultados indican que la ambigüedad es escasamente explicable a partir de propiedades sintácticas superficiales. La baja varianza explicada sugiere que su comportamiento depende en mayor medida de la estructura relacional del espacio semántico que de la forma lingüística del enunciado.

5.1.4.3. Ganancia de Información (nGAIN)

La métrica nGAIN cuantifica la reducción de entropía inducida por la pista en la distribución de probabilidad sobre el conjunto de candidatos. Se encuentra normalizada en el intervalo $[0, 1]$ y mide cuánto se concentra la probabilidad tras observar la pista respecto a la distribución inicial.

Desde una perspectiva informacional, nGAIN captura la magnitud absoluta del desplazamiento probabilístico, independientemente de cuál sea el competidor más cercano.

5.1.4.3.1 Bondad de ajuste

El modelo OLS estimado sobre $N = 360$ observaciones produce los siguientes resultados globales:

- $R^2 = 0{,}061$
- R^2 ajustado $= 0.042$
- $F = 3{,}342$
- p-valor global $= 0.00184$

El modelo resulta globalmente significativo y explica aproximadamente un 6.1 % de la varianza de nGAIN. Aunque la capacidad explicativa es moderada, es superior a la observada en AMB y ligeramente mayor que en PD, lo que sugiere que la ganancia de información es parcialmente modulable desde la estructura lingüística.

5.1.4.3.2 Coeficientes estandarizados

Variable	β	p-valor	Signif.
PROPN_Ratio	-0.0064	0.920	–
NUM_Ratio	-0.0335	0.646	–
Max_IDF	-0.0241	0.636	–
ADJ_Ratio	0.0136	0.820	–
VERB_Ratio	-0.2092	0.000	***
Tree_Depth	-0.0550	0.285	–
NER_Count	0.1240	0.029	*

Tabla 5.6: Coeficientes estandarizados del modelo OLS para nGAIN (errores robustos HC3).

($* \; p < 0{,}05$, $* * * \; p < 0{,}001$)

La Figura 5.8 muestra los coeficientes estandarizados junto con sus intervalos de confianza.

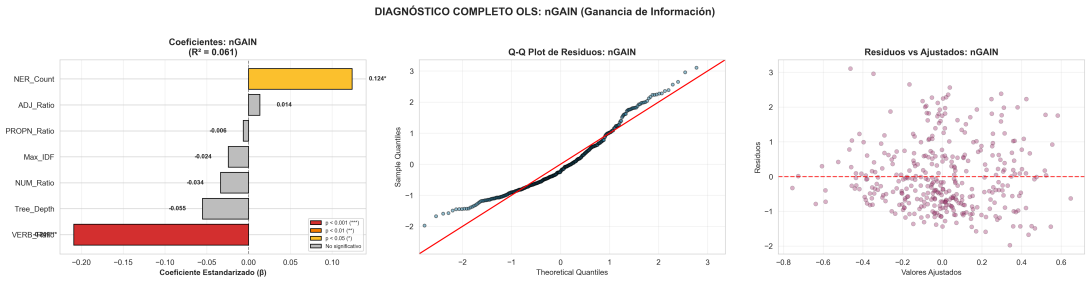


Figura 5.8: Coeficientes estandarizados del modelo OLS para nGAIN.

5.1.4.3.3 Análisis por variable

VERB_Ratio presenta el efecto más fuerte del modelo ($\beta = -0{,}2092$, $p < 0{,}001$). Una mayor proporción de verbos se asocia con una reducción significativa de la ganancia de información. Esto indica que las pistas centradas en acciones tienden a distribuir probabilidad sobre múltiples candidatos, disminuyendo la reducción neta de entropía. En términos estructurales, los verbos parecen introducir señal compartida más que discriminativa.

NER_Count muestra un efecto positivo significativo ($\beta = 0{,}1240$, $p = 0{,}029$). La presencia de entidades nombradas incrementa la ganancia de información. Las entidades concretas actúan como anclajes semánticos que restringen el espacio de búsqueda de manera más precisa que formulaciones genéricas.

El resto de variables no presenta asociación estadísticamente significativa:

- **PROPN_Ratio** y **NUM_Ratio** no muestran efecto detectable sobre la reducción de entropía.
- **Max_IDF** no evidencia relación sistemática con la ganancia informacional.
- **ADJ_Ratio** no presenta efecto estructural relevante.
- **Tree_Depth** no muestra impacto significativo.

5.1.4.3.4 Diagnóstico

Los gráficos de residuos no evidencian patrones sistemáticos de no linealidad. Se observa ligera desviación en colas del Q-Q plot, coherente con métricas normalizadas. La utilización de errores robustos HC3 garantiza inferencia consistente ante posibles desviaciones de homocedasticidad.

En conjunto, los resultados muestran que la reducción efectiva de entropía depende principalmente de la presencia de entidades explícitas y de la moderación en el uso de verbos, mientras que otras dimensiones superficiales de la sintaxis no presentan efectos sistemáticos detectables.

5.1.4.4. Lecturabilidad (LEC)

La métrica LEC se basa en el índice de Flesch Reading Ease adaptado al español y mide la facilidad cognitiva de procesamiento del texto. Valores altos indican mayor simplicidad sintáctica y menor carga estructural.

5.1.4.4.1 Bondad de ajuste

El modelo OLS estimado sobre $N = 360$ observaciones produce los siguientes resultados globales:

- $R^2 = 0{,}154$
- R^2 ajustado $= 0.137$
- $F = 3{,}790$
- p-valor global $= 0.000556$

El modelo resulta altamente significativo y explica aproximadamente un 15.4 % de la varianza en LEC. Es, hasta este punto, el modelo con mayor capacidad explicativa entre las métricas analizadas, lo que es coherente con la naturaleza estructural de la lecturabilidad.

5.1.4.4.2 Coeficientes estandarizados

Variable	β	p-valor	Signif.
PROPN_Ratio	-0.0769	0.101	–
NUM_Ratio	0.0379	0.190	–
Max_IDF	-0.0368	0.296	–
ADJ_Ratio	-0.3793	0.000	***
VERB_Ratio	-0.2141	0.001	**
Tree_Depth	-0.0432	0.337	–
NER_Count	0.0617	0.160	–

Tabla 5.7: Coeficientes estandarizados del modelo OLS para LEC (errores robustos HC3).

($** \; p < 0{,}01$, $*** \; p < 0{,}001$)

La Figura 5.9 muestra los coeficientes estandarizados junto con sus intervalos de confianza.

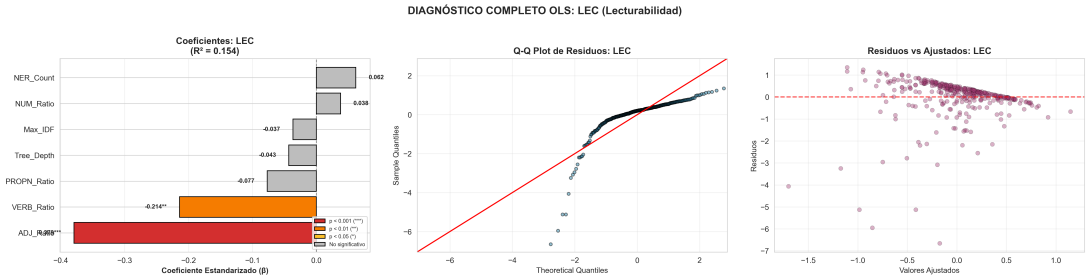


Figura 5.9: Coeficientes estandarizados del modelo OLS para LEC.

5.1.4.4.3 Análisis por variable

ADJ_Ratio presenta el mayor efecto estadístico del modelo ($\beta = -0{,}3793$, $p < 0{,}001$). Un incremento de una desviación estándar en la proporción de adjetivos se asocia empíricamente con una reducción de aproximadamente 0.38 desviaciones estándar en la lecturabilidad. Este es el coeficiente individual de mayor magnitud observado en el conjunto de regresiones estimadas, indicando que una mayor densidad de modificadores atributivos correlaciona fuertemente con una menor facilidad de lectura.

VERB_Ratio también muestra un efecto negativo y estadísticamente significativo ($\beta = -0{,}2141$, $p = 0{,}001$). Una mayor proporción de verbos en la pista se asocia sistemáticamente con una disminución en la métrica de lecturabilidad, constituyendo el segundo efecto de mayor peso dentro de este modelo en particular.

El resto de las variables evaluadas no presentan efectos estadísticamente significativos sobre la lecturabilidad en esta muestra. Concretamente, **NUM_Ratio** ($p = 0{,}190$) y **Tree_Depth** ($p = 0{,}337$) no muestran una asociación sistemática con la variable dependiente, al igual que ocurre con **PROPN_Ratio**, **Max_IDF** y **NER_Count**.

5.1.4.4.4 Diagnóstico

La evaluación formal de los residuos revela desviaciones respecto a los supuestos clásicos de regresión. El test de Shapiro-Wilk ($W = 0{,}6600$, $p < 0{,}001$) indica que los residuos no se distribuyen de forma normal. Asimismo, el test de Breusch-Pagan ($LM = 28{,}3958$, $p < 0{,}001$) detecta la presencia de heterocedasticidad en el modelo.

Ante este diagnóstico, la decisión metodológica de emplear errores estándar robustos HC3 resulta fundamental. Esta corrección garantiza que la inferencia estadística realizada sobre los coeficientes (específicamente los intervalos de confianza y los p-valores asociados a **ADJ_Ratio** y **VERB_Ratio**) mantenga su validez matemática a pesar de la ausencia de homocedasticidad y normalidad en los residuos.

5.1.4.5. Consistencia (CONS)

La métrica de Consistencia (CONS) mide la coherencia semántica interna del conjunto de pistas asociadas a un personaje, evaluando cuantitativamente si todas ellas convergen hacia un mismo eje temático o si presentan dispersión.

5.1.4.5.1 Bondad de ajuste

El modelo OLS estimado sobre $N = 360$ observaciones produce los siguientes resultados globales:

- $R^2 = 0{,}138$

- R^2 ajustado $= 0.121$
- $F = 7{,}285$
- p-valor global $< 0{,}001$ $(3{,}63 \times 10^{-8})$

El modelo resulta globalmente significativo y explica aproximadamente un 13.8 % de la varianza en CONS. Esta capacidad explicativa moderada sugiere que la coherencia temática está asociada de forma detectable con ciertas decisiones de estructuración lingüística.

5.1.4.5.2 Coeficientes estandarizados

La siguiente tabla resume los coeficientes estimados utilizando errores robustos HC3:

Variable	β	p-valor	Signif.
PROPN_Ratio	-0.0904	0.230	–
NUM_Ratio	-0.0884	0.180	–
Max_IDF	-0.0290	0.270	–
ADJ_Ratio	-0.0661	0.333	–
VERB_Ratio	-0.3016	0.000	***
Tree_Depth	0.1131	0.020	*
NER_Count	-0.0977	0.147	–

Tabla 5.8: Coeficientes estandarizados del modelo OLS para CONS (errores robustos HC3).

(* $p < 0{,}05$, *** $p < 0{,}001$)

La Figura 5.10 muestra los coeficientes estandarizados junto con sus intervalos de confianza.

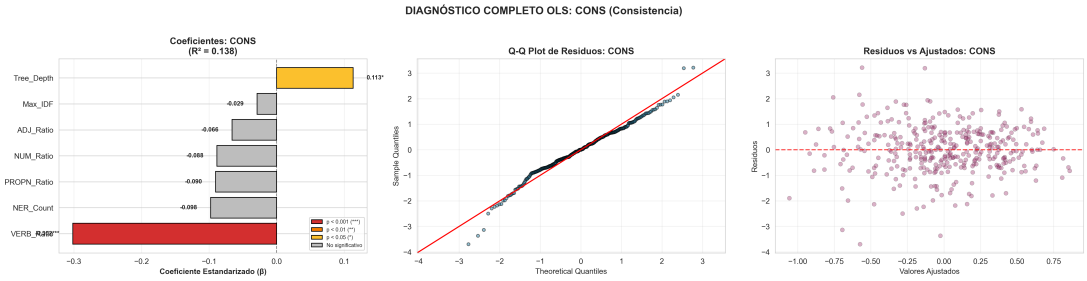


Figura 5.10: Coeficientes estandarizados del modelo OLS para CONS.

5.1.4.5.3 Análisis por variable

VERB_Ratio presenta el efecto negativo más intenso de este modelo ($\beta = -0{,}3016$, $p < 0{,}001$). Un incremento en la proporción de verbos se asocia con una reducción significativa de la consistencia semántica entre las pistas. Estadísticamente, la introducción de una mayor densidad verbal correlaciona con una mayor dispersión direccional en el espacio temático.

Tree_Depth muestra un efecto positivo y estadísticamente significativo ($\beta = 0{,}1131$, $p = 0{,}020$). Una mayor profundidad del árbol sintáctico se asocia con un incremento en la consistencia. Este resultado indica que las oraciones con mayor complejidad estructural o anidamiento tienden a presentar una organización temática internamente más cohesionada.

El resto de las variables (**PROPN_Ratio**, **NUM_Ratio**, **Max_IDF**, **ADJ_Ratio** y **NER_Count**) no presentan asociaciones estadísticamente significativas con la consistencia en esta muestra, manteniendo p-valores ampliamente superiores al nivel $\alpha = 0{,}05$.

5.1.4.5.4 Diagnóstico

La evaluación de los residuos sugiere un comportamiento estadístico manejable dentro de los parámetros del modelo. Como en las estimaciones anteriores, la utilización de errores estándar robustos HC3 garantiza que la inferencia sobre los coeficientes (p-valores e intervalos de confianza) sea consistente y válida ante posibles desviaciones en los supuestos de normalidad u homocedasticidad.

5.1.5. H4 — Efecto de la modalidad experimental

La segunda fase experimental introduce una variación fundamental en la mecánica de juego: los jugadores ya no recuperan el nombre del personaje de memoria, sino que lo seleccionan de un conjunto cerrado de candidatos predefinidos. Este cambio no afecta a las pistas en sí, que siguen siendo los mismos 360 enunciados generados con idéntico procedimiento, pero transforma radicalmente la dinámica cognitiva del acierto. El presente análisis se organiza en torno a esta asimetría: los modelos OLS son matemáticamente invariantes (las métricas de calidad son propiedades del texto, no del jugador), mientras que la regresión logística refleja un paisaje predictivo sustancialmente distinto al observado en mundo abierto.

5.1.5.1. Invarianza del análisis OLS

Las métricas de calidad PD, AMB, nGAIN, LEC y CONS se calculan sobre las pistas como entidades lingüísticas: sus valores dependen de los embeddings y la estructura sintáctica de cada enunciado, con independencia de cómo el jugador interactúe con él. Al ser las 360 pistas idénticas en ambas fases, los cinco modelos OLS producen exactamente los mismos coeficientes, los mismos valores de R^2 y los mismos niveles de significancia. Repetir el análisis OLS en esta sección no aportaría ningún resultado nuevo.

Esta invarianza no es un resultado vacío: confirma que la relación entre estructura lingüística y calidad semántica es una propiedad estable del texto. Los coeficientes y su interpretación se encuentran en la subsección correspondiente a la Fase 1 y aplican sin modificación al presente experimento.

5.1.5.2. Regresión logística: Fase 2 (Mundo Cerrado)

5.1.5.2.1 Modalidad de respuesta y dinámica del acierto

En mundo cerrado el jugador dispone de una lista visible de candidatos y debe identificar cuál de ellos corresponde a la pista. Esta condición elimina la necesidad de recuperación libre de memoria y sustituye la inferencia abierta por un proceso de discriminación comparativa: el jugador puede evaluar cada candidato de la lista frente al contenido de la pista y seleccionar el más probable. Esta diferencia cognitiva se traduce directamente en una tasa de acierto mucho más elevada (78.1 % frente al 65.5 % observado en mundo abierto) y en un patrón de importancia de métricas cualitativamente distinto.

5.1.5.2.2 Datos y distribución de clases

El conjunto de datos de esta fase comprende $N = 1\,119$ registros de partida, recogidos bajo la modalidad de selección restringida. La distribución de clases es la siguiente:

Clase	Frecuencia	Porcentaje
Acierto (1)	874	78.1 %
Fallo (0)	245	21.9 %
Total	1 119	

Tabla 5.9: Distribución de clases en el conjunto de datos de Fase 2.

El desbalance de clases (casi 4:1 a favor del acierto) es más pronunciado que en mundo abierto (aproximadamente 1.9:1). Esto impone restricciones a la capacidad del modelo para detectar los casos de fallo, que constituyen la señal más informativa para la predicción. El parámetro `class_weight='balanced'` mitiga parcialmente este efecto pero no lo elimina.

5.1.5.2.3 Bondad de ajuste y validación cruzada

El modelo se evalúa mediante validación cruzada estratificada de 5 pliegues y un conjunto de prueba retenido (80/20 estratificado). La Tabla 5.10 compara las métricas de ajuste con las obtenidas en mundo abierto:

Métrica	Mundo Cerrado (F2)	Mundo Abierto (F1)	Diferencia
Accuracy (CV 5-fold)	$0{,}532 \pm 0{,}040$	$\sim 0{,}55 \pm 0{,}03$	$-0{,}018$
AUC-ROC (CV 5-fold)	$0{,}548 \pm 0{,}058$	$\sim 0{,}565 \pm 0{,}027$	$-0{,}017$
AUC-ROC (test set)	0,505	0,591	$-0{,}086$
McFadden R^2	0,0132	0,0102	$+0{,}003$
McFadden R^2 adj.	0,0030	0,0061	$-0{,}003$
LR test G^2	15,56	30,10	$-14{,}54$
LR test p	0,0082	$< 0{,}001$	—
Brier Score	0,2495	0,245	$+0{,}005$

Tabla 5.10: Comparación de bondad de ajuste del modelo logístico entre ambas fases.

A pesar de que los jugadores aciertan con más frecuencia en mundo cerrado, el modelo tiene más dificultades para predecir el éxito con las métricas de la pista. La paradoja se explica por el extremo desbalance de clases: cuando casi todos los jugadores aciertan, el margen de variación atribuible a la calidad de la pista es mucho menor. El modelo logístico sigue siendo estadísticamente significativo ($G^2 = 15{,}56$, $p = 0{,}0082$), lo que confirma que las métricas de calidad contienen señal predictiva real incluso en este contexto más restrictivo.

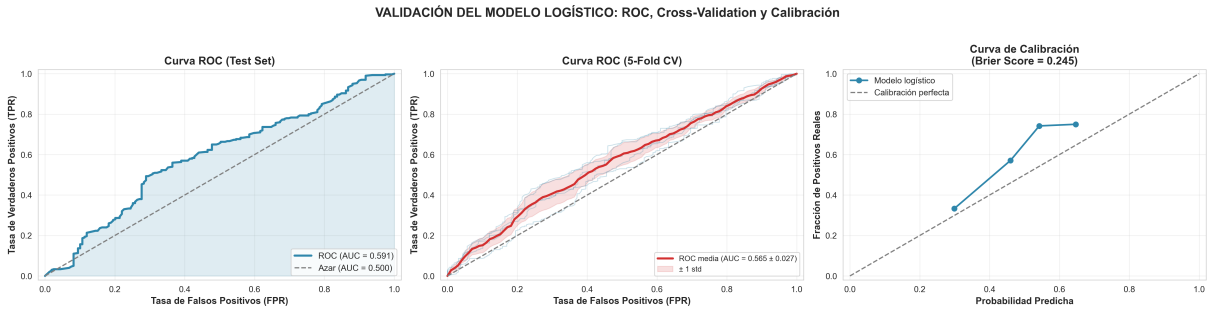


Figura 5.11: Validación completa del modelo logístico en Fase 2. Se incluyen la curva ROC sobre el conjunto de prueba, las métricas de validación cruzada estratificada (accuracy, AUC, F1, log-loss) y el reporte de clasificación. La curva ROC muestra capacidad discriminativa modesta pero consistentemente superior al azar.

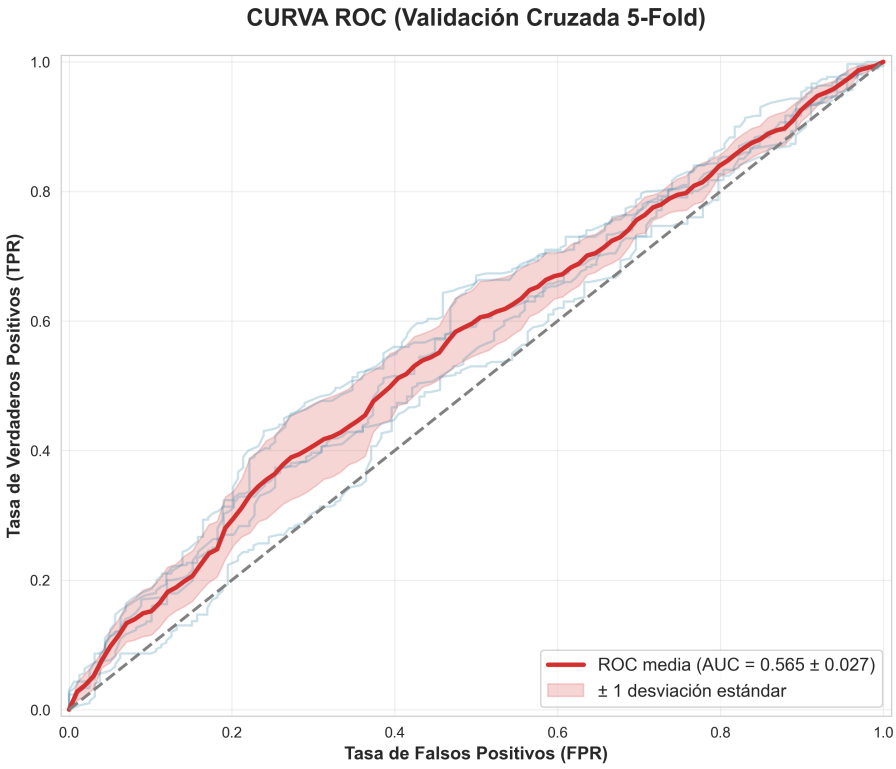


Figura 5.12: Curva ROC con validación cruzada de 5 pliegues (Fase 2). La banda sombreada representa la desviación estándar entre pliegues. El AUC medio de $0{,}548 \pm 0{,}058$ es inferior al obtenido en mundo abierto ($0{,}565 \pm 0{,}027$) y presenta mayor varianza entre pliegues, reflejo del menor tamaño muestral.

5.1.5.2.4 Coeficientes e importancia de métricas

La Tabla 5.11 presenta los coeficientes β estandarizados del modelo sklearn (con regularización L2) y los contrasta con los de mundo abierto, revelando las diferencias en la estructura de importancia entre modalidades:

Métrica	β F2	Dirección	β F1 (ref.)	Cambio
PD	**+0,333**	↑ acierto	+0,110	×3,0
CONS	−0,162	↓ acierto	−0,008	emerge
nGAIN	+0,061	↑ acierto	+0,056	estable
AMB	+0,051	↑ acierto	−0,080	*invierte*
LEC	+0,023	↑ acierto	−0,070	*invierte*

Tabla 5.11: Coeficientes β estandarizados del modelo logístico (sklearn, L2) en Fase 2, comparados con los de Fase 1. Los pesos normalizados derivados sitúan PD en el 53.2 %, CONS en el 25.9 %, nGAIN en el 9.8 %, AMB en el 8.1 % y LEC en el 3.7 %.

En cuanto a la significancia individual (modelo statsmodels, sin regularización), únicamente **PD** alcanza el umbral convencional del 5 % ($\beta = +0{,}325$, $p = 0{,}028$). El resto de coeficientes no son individualmente significativos, en parte por el menor tamaño muestral ($N = 1\,119$ frente a $N = 2\,293$), aunque el modelo conjunto sigue siendo significativo ($p = 0{,}008$).

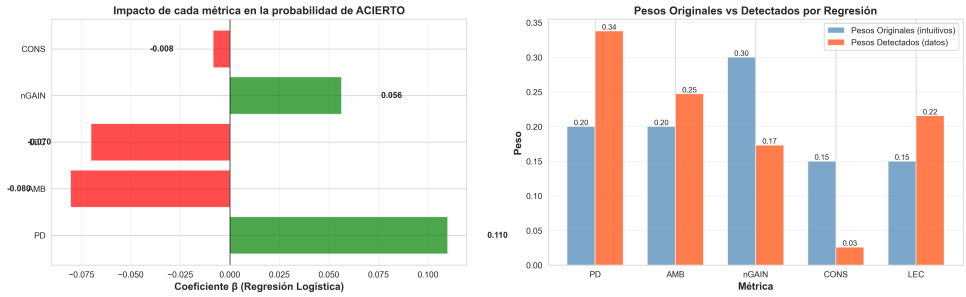


Figura 5.13: Importancia relativa de las métricas de calidad en el modelo logístico de Fase 2 (pesos normalizados a partir de $|\beta|$). PD absorbe más del 53 % del peso total, mientras que en Fase 1 su contribución era de aproximadamente el 34 %. CONS emerge como segundo factor relevante (25.9 %) desde una posición prácticamente irrelevante en mundo abierto (2 %).

5.1.5.2.5 Análisis por métrica

PD: de relevante a dominante. En mundo abierto, el Poder Discriminativo tenía el coeficiente positivo más alto pero no se distinguía estadísticamente del ruido. En mundo cerrado, PD triplica su coeficiente (+0,110 → +0,333) y se convierte en el único predictor individualmente significativo. La explicación es directa: en presencia de una lista de candidatos el jugador realiza explícitamente un proceso de discriminación comparativa: evalúa cada candidato frente a la pista, lo que hace que la capacidad de la pista para separar el target del resto de candidatos sea la propiedad más directamente útil. Una pista con PD alto apunta de forma nítida hacia un individuo concreto dentro de la lista visible; una pista con PD bajo distribuye similitud entre varios candidatos y dificulta la elección.

AMB: inversión de signo por mediación de la lista. En mundo abierto, la ambigüedad semántica tenía un efecto negativo sobre el acierto ($\beta = -0{,}080$): cuando el jugador tiene que recuperar el nombre de memoria, una pista que activa múltiples candidatos lo lleva a callejones sin salida. En mundo cerrado el signo se invierte ($\beta = +0{,}051$): la lista de candidatos actúa como filtro externo que resuelve la ambigüedad. Aunque la pista no apunte limpiamente hacia el target, el jugador puede confrontarla contra cada candidato de la lista y descartar los que son claramente incompatibles. La ambigüedad intrínseca de la pista importa mucho menos cuando el proceso de eliminación lo guía la interfaz, no la memoria.

LEC: dilución del efecto en mundo cerrado. La Lecturabilidad presentaba un coeficiente negativo en mundo abierto ($\beta = -0{,}070$), interpretado como señal de que el vocabulario técnico y específico, que penaliza el índice Flesch, era en realidad más discriminativo. En mundo cerrado ese efecto desaparece

casi por completo ($\beta = +0{,}023$, no significativo). Cuando el jugador puede leer la pista tranquilamente y compararla con una lista finita, la carga cognitiva del vocabulario difícil deja de ser un obstáculo: tiene tiempo para procesar cada término y confrontarlo con los candidatos disponibles. La ventaja del vocabulario técnico se diluye.

CONS: de irrelevante a segundo factor. La Consistencia interna tenía un coeficiente prácticamente nulo en mundo abierto ($\beta = -0{,}008$). En mundo cerrado emerge como segundo predictor en magnitud ($\beta = -0{,}162$). Una hipótesis explicativa es que cuando las pistas de un personaje son muy temáticamente cohesionadas, pueden crear un perfil genérico dentro de su categoría. Si todos los clues de un personaje hablan de "actuación y premios cinematográficos", ese perfil puede describir con igual plausibilidad a varios candidatos del panel que pertenecen a la misma categoría. La consistencia alta no ayuda a diferenciar al individuo concreto de sus vecinos semánticos más próximos en la lista.

nGAIN: el único coeficiente estable. La Ganancia de Información Normalizada es la única métrica que no cambia sustancialmente entre fases ($+0{,}056 \rightarrow +0{,}061$). Esto sugiere que la capacidad de la pista para reducir la entropía del espacio de candidatos es igualmente valiosa independientemente de si el jugador accede a ese espacio de forma libre o restringida. Una pista que concentra probabilidad sobre el target lo hace tanto si el jugador recuerda el nombre por sí solo como si lo selecciona de una lista.

5.1.5.3. Comparación de las tres variantes de Q

La función de calidad compuesta Q existe en tres versiones: la Q **Inicial**, calculada con los pesos teóricos asignados antes de cualquier análisis empírico ($w_{nGAIN} = 0{,}30$, $w_{PD} = w_{AMB} = 0{,}20$, $w_{CONS} = w_{LEC} = 0{,}15$); la Q **Mundo Abierto**, con pesos derivados de la regresión logística de Fase 1 ($w_{PD} = 0{,}335$, $w_{LEC} = 0{,}303$, $w_{AMB} = 0{,}215$, $w_{nGAIN} = 0{,}139$, $w_{CONS} = 0{,}009$); y la Q **Mundo Cerrado**, con los pesos de Fase 2 ($w_{PD} = 0{,}529$, $w_{CONS} = 0{,}257$, $w_{nGAIN} = 0{,}097$, $w_{AMB} = 0{,}081$, $w_{LEC} = 0{,}037$). Las figuras siguientes comparan las tres distribuciones sobre las mismas 360 pistas.

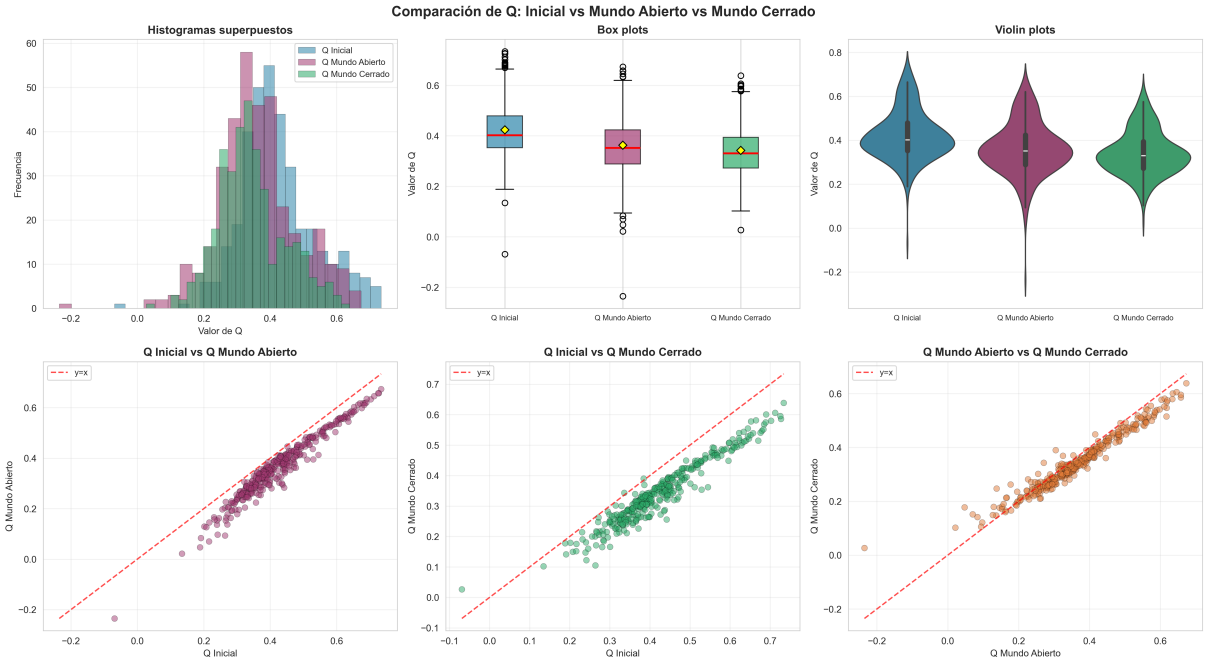


Figura 5.14: Panel resumen (2×3) con las seis comparaciones entre las tres variantes de Q. Fila superior: histogramas superpuestos, box plots y violin plots. Fila inferior: diagramas de dispersión para cada par de variantes (Q Inicial vs Q M.Abierto, Q Inicial vs Q M.Cerrado, Q M.Abierto vs Q M.Cerrado). Azul: Q Inicial; morado: Q Mundo Abierto; verde: Q Mundo Cerrado.

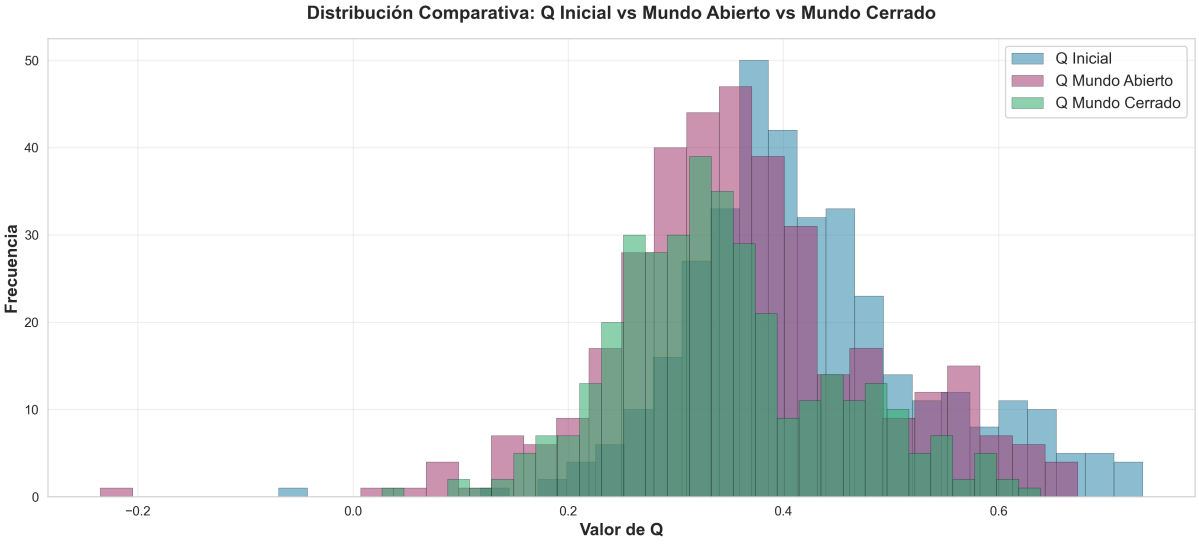


Figura 5.15: Histogramas superpuestos de las tres variantes de Q sobre las 360 pistas. La Q Inicial (azul) concentra masa en una banda estrecha centrada en valores medios, reflejo de que todos los pesos eran moderados. La Q Mundo Abierto (morado) se desplaza según la doble dominancia de PD y LEC. La Q Mundo Cerrado (verde) muestra la mayor dispersión, consecuencia del dominio extremo de PD (53 %): las pistas con PD alto se separan claramente del resto.

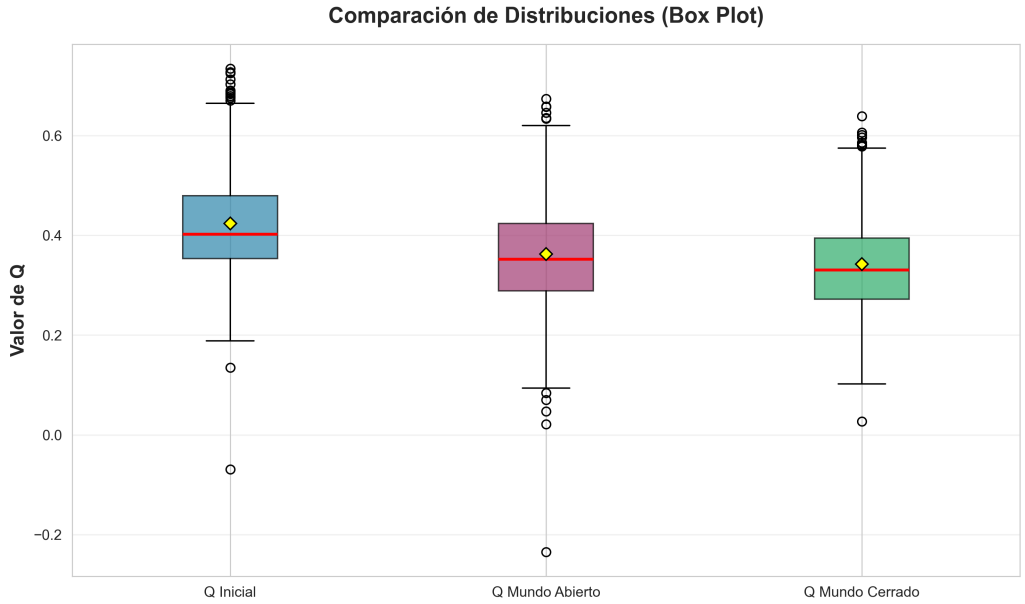


Figura 5.16: Diagramas de caja comparativos de las tres variantes de Q. La comparación de medianas y rangos intercuartílicos revela cómo el rebalanceo de pesos entre variantes desplaza la tendencia central y modifica la asimetría de la distribución. La mayor varianza de Q Mundo Cerrado es consistente con la polarización inducida por el peso dominante de PD.

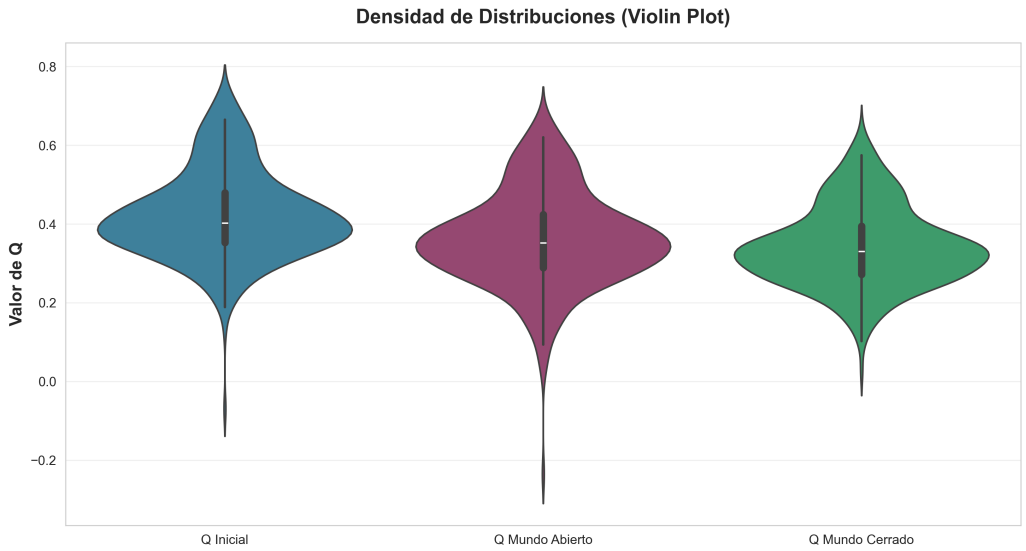


Figura 5.17: Diagramas de violín de las tres variantes de Q. La forma del violín revela la densidad de probabilidad en cada punto del rango de valores. La Q Inicial muestra una forma más compacta y simétrica; la Q Mundo Cerrado presenta una forma más elongada con un pico pronunciado en valores medios-bajos y cola más larga en los valores altos, asociada a las pistas con PD excepcional.

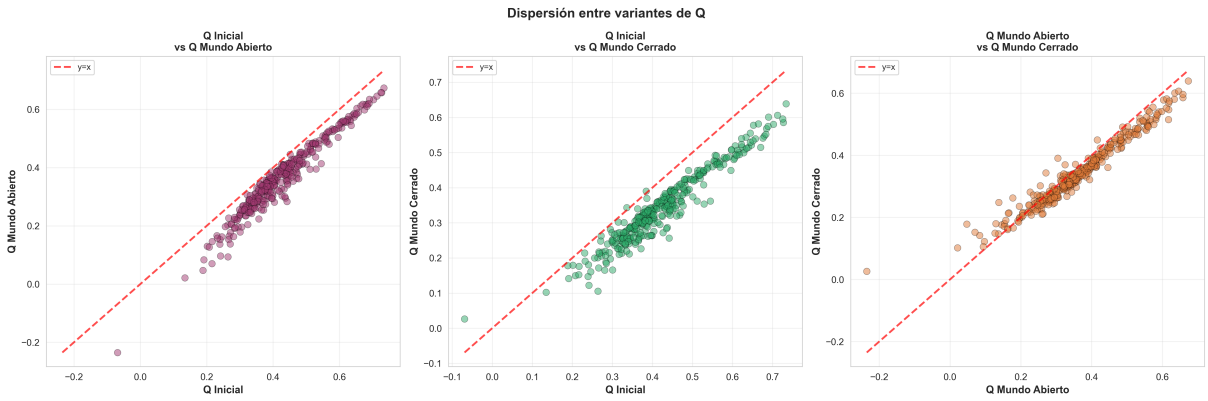


Figura 5.18: Diagramas de dispersión para cada par de variantes. *Izquierda*: Q Inicial vs Q Mundo Abierto — la correlación es moderada; las pistas con LEC alta ganan posición respecto a la Q Inicial. *Centro*: Q Inicial vs Q Mundo Cerrado — la dispersión alrededor de la diagonal es mayor, indicando un reordenamiento más profundo inducido por el peso dominante de PD. *Derecha*: Q Mundo Abierto vs Q Mundo Cerrado — el tercer scatter muestra directamente cuánto difiere el ordenamiento de las pistas entre las dos fórmulas empíricas: las pistas que tienen PD alto pero LEC baja suben en mundo cerrado y bajan en mundo abierto, y viceversa.

Estadístico	Q Inicial	Q M. Abierto	Q M. Cerrado
Media	0.344	0.292	0.277
Mediana	0.345	0.301	0.282
Desv. típica	0.060	0.070	0.052
Mínimo	−0.068	−0.232	0.027
Máximo	0.507	0.466	0.404
P_{25}	0.315	0.261	0.247
P_{75}	0.378	0.331	0.310
Correlaciones de Pearson entre variantes			
Q Inicial ↔ Q M. Abierto		$r = 0{,}919$	
Q Inicial ↔ Q M. Cerrado		$r = 0{,}884$	
Q M. Abierto ↔ Q M. Cerrado		$r = 0{,}937$	

Tabla 5.12: Estadísticos descriptivos de las tres variantes de Q sobre las 360 pistas del corpus, con correlaciones de Pearson entre pares ($N = 360$).

Las tres correlaciones son elevadas ($r \geq 0{,}88$), lo que indica que el rebalanceo de pesos no altera radicalmente el ordenamiento de las pistas: las pistas valoradas como buenas por la fórmula inicial tienden a serlo también por ambas fórmulas empíricas. La correlación más baja ($r = 0{,}884$ entre Q Inicial y Q M. Cerrado) refleja que el cambio de paradigma modifica de forma más pronunciada la valoración relativa de las pistas que la transición entre dos configuraciones de mundo abierto. Sin embargo, los estadísticos revelan desplazamientos sistemáticos: las fórmulas empíricas reducen la media en conjunto (de 0.344 a 0.292 y 0.277), reflejo de que la Q Inicial era más generosa al distribuir el peso en nGAIN, métrica con valores típicamente elevados. La Q Mundo Cerrado presenta la menor dispersión ($\sigma = 0{,}052$) y el mínimo absoluto más alto (0.027, sin valores negativos), efecto directo de que todos sus pesos apuntan en el mismo sentido en la fórmula compuesta: PD y nGAIN en positivo, CONS y AMB como penalizaciones suaves vía el término $(1 - 1{,}5 \cdot \text{AMB})$.

La evolución de las tres variantes ilustra el impacto empírico de los datos de juego sobre la fórmula de calidad. Mientras que la Q Inicial distribuía el peso de forma relativamente uniforme basándose en criterios teóricos, ambas versiones empíricas convergen en elevar el papel de PD, aunque en distinta medida, y reducen drásticamente el peso de nGAIN, que ocupaba el lugar privilegiado en la fórmula original. Las diferencias entre la Q Mundo Abierto y la Q Mundo Cerrado reflejan, pista a pista, la asimetría de las mecánicas: las pistas que el modelo de mundo cerrado valora por encima del modelo de mundo abierto son aquellas que apuntan con precisión al target dentro de una lista, aunque resulten difíciles de procesar o temáticamente dispersas; las pistas que el modelo de mundo abierto prima son aquellas que combinan discriminación semántica con claridad expresiva, necesaria cuando el jugador no dispone de ningún andamiaje externo.

Capítulo 6

Conclusiones y trabajos futuros

6.1. Conclusiones

El problema abordado en este trabajo es la ausencia de criterios formales para evaluar la calidad de pistas generadas automáticamente por LLMs en sistemas interactivos de deducción. Sin una métrica objetiva que distinga pistas útiles de pistas ambiguas o redundantes, resulta imposible mejorar iterativamente los sistemas generativos ni validar científicamente su comportamiento. Este trabajo propone QUILL como respuesta a esa carencia, definiendo cinco dimensiones semánticas de calidad y validándolas empíricamente sobre datos reales de interacción.

El objetivo general de este trabajo era proponer y evaluar un marco formal que permitiera analizar y optimizar la calidad de las pistas generadas automáticamente por LLMs en entornos interactivos de deducción. Los resultados empíricos obtenidos a lo largo de las dos fases experimentales (3.412 interacciones registradas, 45 objetivos, 360 pistas) confirman que dicho objetivo ha sido alcanzado: se han definido cinco métricas semánticas con respaldo teórico, se ha implementado la función de calidad compuesta QUILL con capacidad de adaptación empírica de sus pesos mediante regresión logística, y se ha validado estadísticamente la hipótesis de que las propiedades lingüísticas superficiales modulan de manera sistemática la utilidad de una pista. Las subsecciones siguientes sintetizan los hallazgos más relevantes y los traducen en principios de diseño aplicables.

La transición del modelado estadístico a la formulación de principios de diseño nos permite traducir los hallazgos empíricos en heurísticas aplicables para la generación de pistas en entornos de mundo abierto. Si bien las características sintácticas superficiales explican solo una fracción de la varianza total (lo cual confirma que la calidad semántica depende primordialmente del contenido proposicional), la consistencia de los efectos detectados revela una jerarquía clara de influencia lingüística. El análisis demuestra que la forma en que se estructura la información modula significativamente su utilidad epistemológica para el jugador.

6.1.1. Consecución de los objetivos planteados

Esta sección contrasta los objetivos planteados al inicio del proyecto con los resultados empíricos obtenidos, poniendo de manifiesto en qué medida cada uno de ellos ha sido alcanzado.

6.1.1.1. Objetivo general

El objetivo general del trabajo era proponer y evaluar un marco formal que permitiese analizar y optimizar la calidad de las pistas generadas automáticamente por LLMs en sistemas interactivos de deducción, combinando métricas semánticas intrínsecas al texto con validación empírica sobre datos reales de interacción de usuarios. Este objetivo puede considerarse plenamente alcanzado: se ha definido una función de calidad compuesta Q sobre cinco dimensiones semánticas y formales, se ha validado empíricamente a través de dos experimentos con un total de $N = 3\,412$ interacciones reales, y se han derivado pesos optimizados para cada modalidad de juego mediante regresión logística.

6.1.1.2. Objetivos específicos

- **Establecer métricas observables para evaluar la contribución individual de cada pista.** Objetivo cubierto mediante la definición, implementación y validación de cinco métricas independientes: Poder Discriminativo (PD), Ambigüedad Semántica (AMB), Ganancia de Información Normalizada (nGAIN), Lecturabilidad (LEC) y Consistencia interna (CONS). La independencia de estas dimensiones fue verificada mediante análisis de correlación de Pearson, y su capacidad explicativa fue evaluada tanto individualmente como a través de la función compuesta Q.
- **Integrar modelos de lenguaje de gran tamaño como generadores automáticos de pistas.** Se diseñó un pipeline de generación basado en *in-context learning* con un LLM, produciendo un corpus de 360 pistas sobre 45 personajes (8 pistas por personaje). El análisis sistemático de las limitaciones del modelo, entre ellas la recurrencia de patrones verbales genéricos y la baja discriminación en dominios semánticamente densos, ha permitido identificar sesgos específicos mediante el análisis OLS de las características lingüísticas del corpus generado.
- **Analizar experimentalmente el impacto de diferentes tipos de pistas sobre la dinámica de interacción del usuario.** Se realizaron dos experimentos controlados con usuarios reales: un primer experimento en modalidad de evocación libre ($N_{abierto} = 2\,293$ interacciones) y un segundo en modalidad de reconocimiento deductivo ($N_{cerrado} = 1\,119$ interacciones). La comparación entre modalidades reveló que el impacto de cada dimensión de calidad sobre la tasa de acierto varía sustancialmente en función del contexto de uso, con PD emergiendo como predictor dominante en mundo cerrado ($\beta = +0{,}333$) y un patrón multivariado más equilibrado en mundo abierto.
- **Identificar patrones recurrentes de generación subóptima de pistas por parte de los LLMs.** El análisis de regresión OLS sobre las características lingüísticas del corpus puso de manifiesto patrones sistemáticos: el exceso de verbos genéricos (VERB_Ratio) penaliza cuatro de las cinco métricas de calidad, y el uso de léxico extremadamente infrecuente (Max_IDF elevado) incrementa la ambigüedad al tiempo que reduce el poder discriminativo. Estos hallazgos constituyen una guía concreta para el refinamiento del *prompt* de generación y la mejora iterativa del sistema.

6.1.2. El verbo como determinante negativo de la calidad

El hallazgo más contundente y transversal de este experimento es el efecto negativo y altamente significativo de la densidad verbal sobre la calidad general de la pista. Lejos de dinamizar la información, el verbo actúa como un elemento de dispersión semántica. Las regresiones demuestran que un incremento en el ratio de verbos impacta negativamente en cuatro de las cinco métricas evaluadas, consolidándose como el predictor lingüístico más poderoso del estudio.

En términos de consistencia interna ($\beta = -0{,}302$, $p < 0{,}001$), los verbos introducen múltiples ejes de acción que fragmentan el foco temático. Una pista estructurada en torno a una secuencia de acciones biográficas toca necesariamente diversos eventos cronológicos, mientras que una formulación nominal mantiene un foco único. Asimismo, en lo relativo a la ganancia de información ($\beta = -0{,}209$, $p < 0{,}001$) y al poder discriminativo ($\beta = -0{,}133$, $p < 0{,}05$), los verbos de uso frecuente operan como ruido entrópico; las acciones genéricas suelen ser compartidas por múltiples candidatos dentro del espacio latente, diluyendo la señal del objetivo frente a sus competidores. Finalmente, la acumulación de verbos penaliza la lecturabilidad ($\beta = -0{,}214$, $p = 0{,}001$) al introducir subordinación y relaciones temporales que incrementan la carga cognitiva del receptor.

Métrica	Efecto del VERB_Ratio	Interpretación del impacto
CONS	$\beta = -0{,}302$ $(***)$	Muy fuerte: Dispersa el foco temático.
LEC	$\beta = -0{,}214$ $(**)$	Fuerte: Incrementa la carga cognitiva sintáctica.
nGAIN	$\beta = -0{,}209$ $(***)$	Fuerte: Introduce ruido entrópico no discriminativo.
PD	$\beta = -0{,}133$ $(*)$	Moderado: Activa características compartidas por competidores.

Tabla 6.1: Impacto estandarizado de la densidad verbal sobre las métricas de calidad.

6.1.3. La carga atributiva y la eficiencia cognitiva

El segundo gran determinante estructural de la calidad es la proporción de adjetivos, cuyo impacto se concentra de manera exclusiva y significativa sobre la facilidad de procesamiento del texto. El modelo OLS para la lecturabilidad revela que el ratio de adjetivos ostenta el coeficiente individual más grande de todo el análisis ($\beta = -0{,}379$, $p < 0{,}001$).

El uso intensivo de modificadores atributivos alarga las oraciones sin aportar, por lo general, información factual que permita restringir el espacio de búsqueda. Conceptos calificativos comunes en las descripciones generativas no reducen la entropía del sistema, ya que son aplicables a la inmensa mayoría de las entidades que componen la base de datos del juego. Por tanto, la supresión de la adjetivación vacía emerge como la intervención editorial más eficiente para mejorar la asimilación de la pista sin sacrificar su utilidad resolutiva.

6.1.4. El valor del anclaje factual y la profundidad estructural

En contraposición a la dispersión que generan verbos y adjetivos, las entidades nombradas se consolidan como los pilares de la reducción de incertidumbre. Cada entidad reconocida (organizaciones, premios, obras o localizaciones) incrementa de manera medible la ganancia de información ($\beta = +0{,}124$, $p < 0{,}05$). Las entidades operan como anclajes duros que cortan drásticamente el espacio de probabilidad, transformando formulaciones genéricas en restricciones lógicas inequívocas.

Por otro lado, la profundidad del árbol sintáctico presenta un comportamiento estructural de gran interés analítico. Si bien no afecta significativamente a la legibilidad en esta muestra, sí ejerce un efecto positivo y significativo sobre la consistencia ($\beta = +0{,}113$, $p < 0{,}05$). Las oraciones sintácticamente más complejas, provistas de relaciones anidadas, logran articular la información de manera más cohesionada. Esta complejidad permite agrupar atributos bajo un mismo paraguas semántico, favoreciendo que el conjunto de pistas apunte hacia un horizonte conceptual unificado.

6.1.5. La naturaleza inmanente de la ambigüedad

Desde una perspectiva teórica, uno de los resultados más reveladores es la escasa capacidad de las variables estructurales para predecir la ambigüedad. El modelo asociado presenta una varianza explicada muy reducida ($R^2 \approx 0{,}02$), aunque resulta globalmente significativo ($p = 0{,}004$). El único predictor individual que alcanza significancia estadística es **Max_IDF** ($\beta = +0{,}076$, $p = 0{,}002$): una mayor rareza léxica se asocia con un ligero incremento de la ambigüedad, sugiriendo que los términos infrecuentes activan regiones semánticas dispersas del espacio de embeddings. Sin embargo, la magnitud del efecto es muy pequeña y la sintaxis en su conjunto apenas explica nada de la varianza de AMB.

Este fenómeno subraya que la ambigüedad es fundamentalmente una propiedad relacional y semántica, no sintáctica. Una pista puede presentar una redacción impecable (desprovista de verbos genéricos y rica en entidades concretas) y, sin embargo, resultar altamente ambigua si el clúster de información que

proyecta en el espacio de embeddings es compartido por un subconjunto denso de personajes competidores. En consecuencia, la calibración de la dificultad no puede depender exclusivamente de la edición gramatical, sino que exige un análisis topológico del campo semántico en el que habita el objetivo.

6.1.6. Perfil empírico y el principio de especificidad nominal

A partir de la evidencia estadística recopilada, es posible trazar el arquetipo de la pista óptima para el sistema. Este perfil exige minimizar el ratio de verbos y adjetivos para proteger la lecturabilidad y el poder discriminativo, maximizando al mismo tiempo la presencia de entidades nombradas (≥ 1) para asegurar una ganancia de información efectiva. Como referencia orientativa, el primer cuartil del corpus sitúa el VERB_Ratio por debajo de 0.09 y el ADJ_Ratio por debajo de 0.05, umbrales que delimitan el rango de las pistas con mayor rendimiento observado. Un grado de anidamiento sintáctico moderado complementará este perfil garantizando la consistencia interna.

- **Arquetipo de alta calidad:** *"Autor de El Quijote, publicado en 1605."* (Ausencia de adjetivos y verbos conjugados de acción, alta densidad de entidades nominales y anclajes numéricos).
- **Arquetipo subóptimo:** *"Es un personaje muy famoso que hizo muchas cosas importantes y fue muy reconocido en su disciplina."* (Alta densidad de verbos genéricos y adjetivos valorativos, nula presencia de anclajes factuales concretos).

En síntesis, la jerarquía de influencia lingüística deducida de los modelos OLS postula un principio rector para el diseño en mundo abierto: **una pista de calidad es aquella que maximiza la densidad de sustantivos y entidades concretas, minimizando el uso de verbos genéricos y adjetivos vacíos.** La efectividad del sistema reside en la especificidad nominal, no en la fluidez de la narrativa verbal. Las mejores pistas, desde la perspectiva de la teoría de la información, asimilan su estructura a la precisión de una entrada enciclopédica antes que a la retórica de un texto literario.

6.1.7. Consideraciones metodológicas y limitaciones

Es imperativo contextualizar estos hallazgos dentro de los límites metodológicos del experimento. En primer lugar, los coeficientes de determinación (R^2) moderados en métricas como el poder discriminativo y la ganancia de información ($\sim$ 5–6 %) confirman que la sintaxis es un modulador del rendimiento, pero el determinante primario sigue siendo el valor intrínseco de los datos aportados.

En segundo lugar, las métricas de polaridad y subjetividad utilizadas, derivadas de modelos estandarizados, presentan limitaciones de sensibilidad al aplicarse sobre textos generativos en español, lo que sugiere que herramientas nativas podrían capturar matrices de varianza actualmente ocultas. Finalmente, la naturaleza del corpus (generado mediante *in-context learning* por un modelo de lenguaje con restricciones estrictas de longitud) induce una homogeneidad estructural de base. Esta uniformidad artificial puede estar comprimiendo la varianza natural de las características lingüísticas, lo que implica que los efectos penalizadores de verbos y adjetivos en un entorno de creación humana libre podrían ser aún más pronunciados empíricamente.

Propiedad	**Valor recomendado**	**Métrica afectada**	**Efecto esperado**
VERB_Ratio	$<$ 0,09 (Q1 del corpus)	CONS, LEC, nGAIN, PD	Reduce dispersión semántica y carga cognitiva
ADJ_Ratio	$<$ 0,05 (Q1 del corpus)	LEC	Elimina carga atributiva vacía
NER_Count	≥ 1	nGAIN	Incrementa ganancia de información
Tree_Depth	Moderada	CONS	Favorece cohesión interna
Subjectivity	Baja	LEC	Reduce interpretaciones ambiguas

Tabla 6.2: Perfil empírico de la pista óptima según los modelos OLS. Los umbrales VERB_Ratio y ADJ_Ratio corresponden al primer cuartil del corpus.

A lo largo del proceso experimental surgieron tres desafíos técnicos reseñables. Primero, la fuerte colinealidad negativa ($r = -0{,}80$) entre PD y AMB exigió linealizar la penalización de la ambigüedad y ajustar los pesos mediante regresión logística, asignando la carga principal al PD y un rol corrector secundario a la AMB. Segundo, la lecturabilidad exhibió un efecto paradójico: un coeficiente negativo ($\beta_{LEC} = -0{,}10$) frente a la tasa de acierto, dado que las pistas más simples tendían a ser semánticamente vacuas; en consecuencia, LEC se reinterpretó como un filtro higiénico de calidad mínima, no como un objetivo a maximizar. Tercero, el desbalanceo inherente al corpus de interacciones reales se mitigó mediante aprendizaje sensible al coste (*class_weight='balanced'*), preservando la fiabilidad de los coeficientes extraídos independientemente de la frecuencia base de aciertos.

6.2. Impacto social y medioambiental

El desarrollo y refinamiento de sistemas basados en Procesamiento de Lenguaje Natural (PLN) trasciende el ámbito puramente técnico, proyectando implicaciones directas sobre la accesibilidad cognitiva de los usuarios y la sostenibilidad de las infraestructuras tecnológicas. La presente investigación, al decodificar las estructuras lingüísticas que maximizan la claridad y reducen la entropía, se alinea de manera fundamental con los Objetivos de Desarrollo Sostenible (ODS) promovidos por la Asamblea General de las Naciones Unidas.



Figura 6.1: ODS 4: Educación de calidad.

En primer lugar, los hallazgos impactan directamente en el **ODS 4 (Educación de Calidad)**. La demostración empírica de que la carga atributiva (adjetivos) y la densidad verbal perjudican severamente la lecturabilidad ofrece una heurística valiosa para el diseño de materiales didácticos y plataformas de aprendizaje adaptativo. Al aplicar el principio de *especificidad nominal*, los educadores y desarrolladores de tecnología educativa pueden generar textos explicativos y evaluaciones (como juegos de preguntas o trivias) con una menor barrera cognitiva. Esto resulta especialmente relevante para garantizar el acceso equitativo a la información en usuarios con dificultades de comprensión lectora, trastornos del neurodesarrollo o aquellos que operan en un idioma que no es su lengua materna.



Figura 6.2: ODS 9: Industria, innovación e infraestructura.

En segundo lugar, el proyecto contribuye al **ODS 9 (Industria, Innovación e Infraestructura)**. La creación de metodologías que permiten evaluar y auditar matemáticamente la calidad semántica del texto generado por inteligencia artificial fomenta el desarrollo de infraestructuras tecnológicas más robustas y fiables. En lugar de depender de la validación humana constante, este marco analítico impulsa la innovación hacia sistemas autónomos capaces de auto-regular la información que proyectan, mejorando la interacción humano-máquina en entornos lúdicos, educativos y de recuperación de información.



Figura 6.3: ODS 12: Producción y consumo responsables.

Finalmente, desde una perspectiva medioambiental, la investigación abraza los principios de la *Green AI* (IA Verde), alineándose con el **ODS 12 (Producción y Consumo Responsables)**. Los Modelos de Lenguaje Grande (LLMs) requieren enormes cantidades de energía y recursos computacionales para la inferencia. Al demostrar que las pistas más eficientes son aquellas más sintéticas (minimizando verbos y adjetivos), se fomenta la creación de *prompts* y respuestas más concisas. Reducir la longitud de los textos generados y eliminar la ambigüedad disminuye directamente el número de tokens procesados por las API, mitigando la huella de carbono asociada al uso masivo de inteligencia artificial en aplicaciones de mundo abierto.

6.3. Líneas futuras

Los resultados obtenidos en este estudio establecen una base empírica sólida para la evaluación sintáctico-semántica de textos informativos, abriendo múltiples vectores para la investigación y el desarrollo futuro. Las limitaciones identificadas y los descubrimientos estadísticos sugieren las siguientes vías de expansión:

1. Desarrollo de un linter lingüístico en tiempo real: La traducción natural de estos hallazgos es la implementación de un clasificador automatizado o *linter* que opere durante la fase de generación de contenido. Este sistema podría analizar en tiempo real el texto producido (ya sea por un jugador humano o por un LLM), calculando sus ratios de verbos, adjetivos y entidades nombradas para emitir alertas o sugerencias de reescritura antes de que la pista sea introducida en el sistema, asegurando así un control de calidad preventivo basado en el perfil óptimo definido.

2. Contraste empírico con corpus de autoría humana: Dado que el presente estudio se apoyó en pistas generadas mediante *in-context learning*, el corpus resultante presenta una homogeneidad estructural inherente a la naturaleza del LLM utilizado. Una línea de investigación fundamental consistirá en replicar este diseño metodológico utilizando un conjunto de datos compuesto íntegramente por pistas redactadas libremente por usuarios humanos. Esto permitirá comprobar si la mayor varianza natural en la sintaxis humana amplifica la magnitud de los coeficientes penalizadores descubiertos en este análisis.

3. Integración de modelos semánticos nativos en español: La evaluación de la métrica de

subjetividad se vio limitada por el uso de herramientas genéricas que no lograron capturar los matices del español. Futuras iteraciones del proyecto deberán incorporar modelos de Procesamiento de Lenguaje Natural entrenados nativamente en español para el análisis de sentimientos y polaridad. Esto permitirá aislar de forma mucho más precisa el impacto real que tiene la inclusión de opiniones frente a hechos objetivos en el poder discriminativo de la pista.

4. Optimización avanzada de Prompt Engineering: Los principios descubiertos, en particular el de la *especificidad nominal*, deben ser integrados en las instrucciones de sistema (*system prompts*) de los agentes generativos. Investigaciones posteriores podrían realizar pruebas A/B contrastando el rendimiento de un LLM instruido genéricamente para "escribir pistas claras" frente a uno instruido explícitamente bajo restricciones matemáticas derivadas del perfil óptimo definido en este trabajo. Esto permitirá medir hasta qué punto las heurísticas estructurales superan a las instrucciones semánticas en la arquitectura de LLMs.

5. Calibración supervisada de la función CLAMP: La función CLAMP, reformulada en este trabajo para adoptar una penalización sigmoide calibrada sobre la distribución empírica del corpus, conserva un único parámetro convencional ($k = 2$, regla de las dos sigmas). Una línea de investigación natural consistirá en optimizar dicho parámetro mediante validación cruzada sobre interacciones etiquetadas, o en sustituirlo por un umbral aprendido directamente a partir de la distribución de éxito y fracaso de los jugadores. Este enfoque convertiría la función CLAMP en un componente totalmente supervisado, cerrando el ciclo de retroalimentación entre el comportamiento del usuario y la calibración interna del sistema de calidad.

6. Extensión a dominios y juegos alternativos: La metodología desarrollada está formulada de forma genérica y no se restringe al dominio de figuras públicas ni al formato de *Spygame*. Futuros trabajos podrían trasladar el marco QUILL a otros entornos de deducción, como juegos de palabras, trivias científicas o plataformas de aprendizaje adaptativo, verificando la transferibilidad de los principios de especificidad nominal y evaluando si las jerarquías lingüísticas descubiertas se mantienen estables entre dominios.

Bibliografía

[1] Vincent Aleven and Kenneth R. Koedinger. An effective metacognitive strategy: Learning by doing and explaining with a computer-based cognitive tutor. *Cognitive Science*, 26(2):147–179, 2002.

[2] Vincent Aleven, Elizabeth A. McLaughlin, Rachel A. Glenn, and Kenneth R. Koedinger. Instruction based on adaptive learning technologies. *Handbook of Research on Learning and Instruction*, 2016.

[3] Vincent Aleven, Ido Roll, Bruce M. McLaren, and Kenneth R. Koedinger. Help helps, but only so much: Research on help seeking with intelligent tutoring systems. *International Journal of Artificial Intelligence in Education*, 26(1):205–223, 2016.

[4] John R. Anderson, Albert T. Corbett, Kenneth R. Koedinger, and Ray Pelletier. Cognitive tutors: Lessons learned. *The Journal of the Learning Sciences*, 4(2):167–207, 1995.

[5] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, and Dario Amodei. Language models are few-shot learners, 2020.

[6] Michelene T. H. Chi and Ruth Wylie. The icap framework: Linking cognitive engagement to active learning outcomes. *Educational Psychologist*, 49(4):219–243, 2018.

[7] Wikipedia contributor. Bayesian knowledge tracing — wikipedia, the free encyclopedia. `https://en.wikipedia.org/wiki/Bayesian_knowledge_tracing`, 2025. Online|Accessed 25-Jan-2026.

[8] Albert T. Corbett and John R. Anderson. Knowledge tracing: Modeling the acquisition of procedural knowledge. *User Modeling and User-Adapted Interaction*, 4(4):253–278, 1995.

[9] Thomas M. Cover and Joy A. Thomas. *Elements of Information Theory*. Wiley-Interscience, Hoboken, NJ, 2nd edition, 2006.

[10] Sutapa Dey Tithi et al. The promise and limits of large language models in constructing proofs and hints, 2025.

[11] Mingyu Feng, Neil T. Heffernan, and Kenneth R. Koedinger. Addressing the assessment challenge with an online system that tutors as it assesses. *User Modeling and User-Adapted Interaction*, 19(3):243–266, 2009.

[12] Kenneth R. Koedinger and Vincent Aleven. Exploring the assistance dilemma in experiments with cognitive tutors. *Educational Psychology Review*, 19(3):239–264, 2007.

[13] Kenneth R. Koedinger, Ryan S. Baker, and Katherine Cunningham. Data-driven discovery of better student models: Improving student learning with intelligent tutoring systems. *Educational Data Mining*, 2012.

[14] James G. MacKinnon and Halbert White. Some heteroskedasticity-consistent covariance matrix estimators with improved finite sample properties. *Journal of Econometrics*, 29(3):305–325, 1985.

[15] Mehak Maniktala, Christa Cody, Tiffany Barnes, and Min Chi. Avoiding help avoidance: Using interface design changes to promote unsolicited hint usage in an intelligent tutor. *International Journal of Artificial Intelligence in Education*, 30(4):637–667, October 2020.

[16] Luis Marquez-Carpintero, Alberto Lopez-Sellers, and Miguel Cazorla. Simulation of teaching behaviours in intelligent tutoring systems: A review using large language models - artificial intelligence review, Dec 2025.

[17] Joshua Maynez, Shashi Narayan, Bernd Bohnet, and Ryan McDonald. On faithfulness and factuality in abstractive summarization. *Proceedings of ACL*, 2020.

[18] Emergent Mind. Intelligent tutoring systems: Adaptation and personalization mechanisms. `https://www.emergentmind.com/topics/intelligent-tutoring-systems-its`, 2025. Online|Accessed 25-Jan-2026.

[19] Zachary A. Pardos and Shreya Bhandari. ChatGPT-generated help produces learning gains equivalent to human tutor-authored help on mathematics skills. *PLOS ONE*, 2024.

[20] Tung Phung, Victor-Alexandru Pădurean, Anjali Singh, Christopher Brooks, José Cambronero, Sumit Gulwani, Adish Singla, and Gustavo Soares. Automating human tutor-style programming feedback: Leveraging GPT-4 tutor model for hint generation and GPT-3.5 student model for hint validation. In *Proceedings of the 14th Learning Analytics and Knowledge Conference (LAK '24)*, pages 12–23, New York, NY, USA, 2024. ACM.

[21] Anna N. Rafferty, Michelle LaMar, and Thomas L. Griffiths. Modeling cognitive states in intelligent tutoring systems. *Artificial Intelligence in Education*, pages 1–10, 2016.

[22] Nils Reimers and Iryna Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks. In *Proceedings of EMNLP-IJCNLP*, 2019.

[23] Alexander Scarlatos, Digory Smith, Simon Woodhead, and Andrew Lan. Improving the validity of automatically generated feedback via reinforcement learning. In *Artificial Intelligence in Education (AIED 2024)*, volume 14829 of *Lecture Notes in Computer Science*, pages 280–294, Cham, 2024. Springer.

[24] Burr Settles. Active learning literature survey. Computer Sciences Technical Report 1648, University of Wisconsin–Madison, 2009.

[25] Claude E. Shannon. A mathematical theory of communication. *The Bell System Technical Journal*, 27(3):379–423, 1948.

[26] Francisco Szigriszt Pazos. *Sistemas predictivos de legibilidad del mensaje escrito: fórmula de perspicuidad*. Tesis doctoral, Universidad Complutense de Madrid, 1993. Colección Tesis Doctorales, n.º 228/93.

[27] Manie Tadayon and Greg Pottie. Predicting student performance in an educational game using a hidden markov model, 2019.

[28] Junior Cedric Tonga, Benjamin Clement, and Pierre-Yves Oudeyer. Automatic generation of question hints for mathematics problems using large language models in educational technology, 2024.

[29] Kurt VanLehn. The behavior of tutoring systems. *International Journal of Artificial Intelligence in Education*, 16:227–265, 2006.

[30] Sarah Wiegreffe and Ana Marasović. Measuring faithfulness in natural language explanations. In *Proceedings of EMNLP 2021*, 2021.